HyMEM 个人阅读章节

第 8 队　lanshuheng9-oss　个人过稿版本

本文为小组报告中的个人模块；未包含全组总结与贡献比例。

1　HyMEM：电脑操作智能体的混合自演化记忆

HyMEM[1]面向需要观察截图并连续操作网页的电脑操作智能体。历史经验既包含可复用策略，也包含难以写成文字的界面与动作细节；任务推进后，最初检索的经验又可能失效。因此，系统结合离散策略与连续轨迹表示，分别更新长期记忆和当前任务的工作记忆。以下数据均为作者实验，不能作为本组复现结果。原文为 ACL 2026 Findings，印刷页 11287–11304；下述 PDF 页码从论文首页起计。

1.1　问题背景与混合表示

输入包括任务描述、当前截图及历史成功操作轨迹，输出为下一步可执行操作。例如，搜索商品和结账所需经验不同，但可能需要保留同一预算约束。纯文本总结容易丢失视觉细节，单纯连续表示则缺少清晰的策略组织和可解释索引；一次性检索也难以覆盖交互阶段变化。这些问题构成混合表示与两种更新机制的动机（PDF 第 1–3 页，表 1）。

论文在图 $G = (V, E)$ 中组织经验，将一条轨迹的逻辑表示写为

$$v_i = (c_i, A_i, m_i), \tag{1}$$

其中 c_i 为高层策略，A_i 为动作、界面元素或领域标签等属性集合，m_i 为连续轨迹表示。共享相同属性的轨迹间建立无向边，并通过策略、属性与轨迹的关联支持跨经验检索。三元组描述经验的内容层次，不意味着实际图只有一种同质节点。策略与属性提供语义锚点；借鉴 CoMEM 的连续编码保留难以用文本概括的视觉及动作细节，每条轨迹压缩为 8 个嵌入向量并接入智能体输入（PDF 第 3–5 页，§3.1–3.3、图 1）。

另一个容易混淆的表示是**检索索引向量**：归一化的任务文本 CLIP 表示与起始截图 CLIP 表示拼接后，通过 FAISS 进行相似度检索。它用于寻找经验，不等同于送入智能体的连续记忆 m_i（PDF 第 3 页，式 (1)）。

1.2　全局记忆演化与结构化检索

更新长期图时，新轨迹先检索相关经验，再由视觉语言模型判断信息增量。相似度仅决定候选集合，不能直接决定经验是否重复。三种更新为（PDF 第 4 页，图 1 与 Memory Update）：

- **ADD**：出现新策略或属性，增加对应节点与连接。
- **MERGE**：已有策略获得互补证据，如界面变体或另一条操作路径，将证据并入相应策略及属性关联。
- **REPLACE**：在同等条件下，新轨迹以更少步骤、更高成功率或更低风险实现相同策略，用其替换过时证据并刷新关联。

这些操作改变跨任务复用的长期图，目的是减少冗余、积累可迁移经验。更新质量依赖模型的冗余与优劣判断，不能理解为图规模必然受控或每次替换必然正确。

推理时，系统依据任务和截图寻找相似种子，再沿图扩展邻居并按相似度排序。主实验每次使用 10 条轨迹：5 条语义相似种子，加上从种子的 1 跳邻居中选出的 5 条轨迹。“5+5” 是实验配置，不能表述为任意任务的最优预算。一般算法允许重复扩展，主实验采用上述具体配置（PDF 第 4–5 页，Structured Retrieval 及 Memory Settings）。

1.3　混合工作记忆及局部刷新

检索后形成两个互补视图：策略与属性归纳为指导指令（Guidance Instructions），作为文本写入系统提示；轨迹连续嵌入则与模型输入连接。前者帮助规划，后者提供细粒度视觉和动作信息，二者构成当前任务的工作记忆。

每个动作后，视觉语言模型比较前后观测与当前指导，判断是否发生阶段转换。若任务由搜索转入结账，先保留长期目标和约束，丢弃不相关内容，再按新状态检索，合并指导并刷新连续嵌入。这是**任务内部的上下文更新**，与长期图的 ADD/MERGE/REPLACE 属于不同层次（PDF 第 5 页，On-the-fly Working Memory Refresh）。此例仅用于机制说明，不是本组运行案例。

1.4 实验条件及作者结果

实验覆盖 WebVoyager、Multimodal-Mind2Web 和 MMInA 三个多模态网页智能体基准。前两者根据任务描述与截图轨迹进行模型判分；MMInA 比较最终回答和标准答案。主指标是任务成功率，表 2 的 Overall 为可用领域的平均值，并非将所有测试样本合并后的统一样本准确率。作者声明表 2 各方法均为其在统一环境、抽样和评价口径下的实现（PDF 第 5–7 页，§4.1–4.2 与表 2）。

记忆来源为 GUIAct、Mind2Web 训练集及作者智能体生成的成功轨迹，共 2883 条；主表所用图为 1858 个节点、超过 100 万条边。执行采用 ReAct 式接口，包含 SOM 界面标记及 UI-INS-7B 定位回退。训练更新记忆编码器的 Q-Former 和 LoRA 层，作者称可训练参数约占总参数的 1.2%，通常训练 1 个 epoch。因此，HyMEM 不只是拼接提示词；定位系统、记忆数据和编码器训练也是结果成立的条件（PDF 第 5 页，§4.1）。

表 1 作者表 2 的 Overall 成功率节选（%）；来自 PDF 第 7 页

基础模型	无记忆	离散记忆	连续记忆	HyMEM
Qwen2.5-VL-7B	12.5	17.0	21.7	35.0
Qwen3-VL-8B	21.9	21.3	23.3	33.8
UI-TARS-1.5-7B	17.1	15.4	28.7	31.2

Qwen2.5-VL-7B 由 12.5% 升至 35.0%，提高 22.5 个**百分点**，不能写为相对提高 22.5%。混合记忆在该模型上高于单独离散或连续记忆，但不能证明所有任务均有相同收益。例如，Qwen3-VL-8B 离散记忆的 21.3% 低于无记忆 21.9%；部分领域也未随 HyMEM 改善。

作者另在 Amazon 与 Google Maps 比较静态记忆和自演化记忆。图 2 中，全局演化使成功率分别由 48.8% 升至 61.0%、43.9% 升至 51.2%；局部刷新分别达到 56.1% 和 48.8%（静态参照分别为 48.8% 和 43.9%）。这是特定分析设置的结果，不能与表 2 不同模型、领域配置直接拼接，也不能将两种提升相加（PDF 第 7 页，§4.3.1、图 2）。

1.5 优缺点、可比性及与课设的联系

HyMEM 把可解释策略、连续视觉细节、跨任务图更新和任务内工作记忆刷新组合为闭环，主表与自演化分析给出相应证据。其代价包括构建、编码器训练、图扩展和执行期间的模型判断；本节未据成功率推导端到端成本优势。图关联与更新依赖标签质量及模型判断，仍需考察错误记忆传播、阶段误判和跨网站迁移。

本组 StructMem D 负责文本事件记忆的综合与检索；HyMEM 实证任务则为基于截图的网页操作，数据、输出、接口和评价均不同。因此，不能将 35.0% 与本组 LongMemEval 结果并排排名，也不能声称本组已实现连续多模态记忆或局部刷新。可作为**后续假设**借鉴的设计是：区分语义种子与结构邻居；区分跨任务更新和任务内刷新；在固定检索预算下分别评估覆盖、噪声和调用成本。以上为本节阅读分析，尚非全组共识或已完成实验结论。

References:

[1] Zhu S, WU W, Zhou K, et al. Hybrid self-evolving structured memory for computer-use agents. In: Proceedings of Liakata M, Moreira V P, Zhang J, et al., editors, Findings of the Association for Computational Linguistics: ACL 2026, San Diego, California, United States: Association for Computational Linguistics, 2026. 11287–11304