MetaMem 个人阅读章节

第 8 队　YaoYang-123456

1　MetaMem：由事实存储转向事实利用

MetaMem[1]研究检索后的事实利用：模型即使找到相关记忆，仍可能误解时间、数量或从属关系。该方法将可复用的知识使用经验保存为元记忆，并通过答案反馈迭代优化。

1.1　研究问题与两种记忆

长期对话包含时间、人物、地点、数量及其从属关系。例如，一次旅行总里程为 1200 英里，其中第一天的 300 英里已包含在总数中；若另三次旅行合计 1800 英里，四次旅行应为 3000 英里，而非 3300 英里。错误不仅可能来自遗漏证据，也可能来自取回后对“整体与部分”关系的误判。

论文区分事实记忆 M 与元记忆 E：前者保存具体经历与知识，后者保存**可迁移的知识使用经验**，例如在计数前检查是否重复包含。设问题为 q，主方法可抽象为

$$\hat{y} = \mathrm{LLM}\big(\mathrm{Prompt}(q, M, E)\big). \tag{1}$$

普通记忆问答主要提供 (q, M)，MetaMem 进一步将 E 写入提示词。优化对象是自然语言规则，基础语言模型的权重保持不变。

1.2　从反馈到规则的自反思优化

方法包含规则学习与冻结后的问答两个阶段。训练时，给定带标准答案的样本 (q, a, M)，模型在当前元记忆下多次生成回答，再利用标准答案评价。反思模块归纳成功与失败原因，提出规则的添加、删除或修改，并合并批内重复与冲突的提案。验证集用于选择规则版本，测试时使用固定规则和独立问题。

训练数据与候选回答 $\longrightarrow$ 正误反馈与反思 $\longrightarrow$ 规则编辑与合并 $\longrightarrow$ 冻结后的元记忆 E $\longrightarrow$ 新问题的事实利用

规则学习的主要成本来自多次回答采样、反馈、反思与编辑；冻结后的问答阶段读取事实记忆和规则。

1.3　实验设置与结果

主要数据集 LongMemEval 包含 500 道问题，采用五折划分，每折 350 题训练、50 题验证、100 题测试。生成模型为 Qwen3-30B-A3B-Instruct 与 Llama3.1-70B-Instruct，事实记忆基座主要为 LightMem，默认评价模型为 Qwen3-235B-A22B。规则学习默认运行 5 个 epoch，每批 50 题，每题采样 5 次。

表 1　LongMemEval 平均准确率（%）

生成模型	LightMem	MetaMem	增量（百分点）
Qwen3-30B-A3B-Instruct	67.50	71.90	+4.40
Llama3.1-70B-Instruct	66.17	69.08	+2.91

两种生成模型的平均准确率分别提高 4.40 和 2.91 个百分点。Qwen 配置下，完整方法为 71.90%，去除反思后为 70.02%，去除规则演化后为 68.33%，说明两个环节均有贡献。

1.4　方法局限与课设启发

元记忆将事实召回与事实利用分开处理。自然语言规则便于检查、合并与迁移，可用于分析时间推理、计数和跨事件引用中的重复错误。

规则学习依赖带答案样本与评价模型，错误评判可能污染更新；多次采样和编辑增加优化成本。规则过度泛化、彼此冲突或积累过长也会影响回答。方法发挥作用的前提是关键事实已进入上下文，其在小模型、小样本和其他任务上的适用性仍需检验。

StructMem 侧重事实与关系的组织，MetaMem 侧重检索结果的使用。课程设计可据此将失败题分为证据缺失与证据利用错误，并在固定证据的条件下检查重复计数、时间误读等问题。这样的诊断有助于判断下一步应调整检索还是回答策略。

References:

[1] Xin H, Li X, Liu Z, et al. MetaMem: Evolving meta-memory for knowledge utilization through self-reflective symbolic optimization. In: Proceedings of Liakata M, Moreira V P, Zhang J, et al., editors, Findings of the Association for Computational Linguistics: ACL 2026, San Diego, California, United States: Association for Computational Linguistics, 2026. 5473–5492