长上下文场景结构化记忆建模：六篇论文阅读与比较

hycx233，onlysonder，oioioi-521，lanshuheng9-oss，YaoYang-123456，ngocnamd93-spec

(天津大学)

摘　要: 长期交互中的记忆系统需要保留人物、事件与时间关联，准确检索相关证据，并随新信息更新状态。本文围绕 StructMem、Hindsight、Semantic XPath、HyMEM、MetaMem 和 Text2Mem 六篇论文，系统梳理事件组织、多通道检索、结构化访问、混合经验更新、事实利用与操作验证六类核心机制。通过对比各方法在记忆形成、访问、维护与利用环节的设计，本文分析了不同结构化表示在保留语境关联、收敛检索范围以及控制抽取与维护开销之间的权衡，并结合对照实验与行程变更案例探讨各机制的互补关系与错误定位思路，为以 StructMem 为主线的课程设计提供参考。

关键词: 大语言模型；长上下文；结构化记忆；论文综述

中图法分类号: TP18

Structured Memory for Long-Context Scenarios: A Review of Six Papers

hycx233, onlysonder, oioioi-521, lanshuheng9-oss, YaoYang-123456, ngocnamd93-spec

(Tianjin University)

Abstract: Memory systems for long-term interaction must preserve relations among people, events, and time, retrieve relevant evidence accurately, and update their state as new information arrives. This report reviews six papers—StructMem, Hindsight, Semantic XPath, HyMEM, MetaMem, and Text2Mem—covering event organization, multi-channel retrieval, structured access, hybrid experience updating, knowledge utilization, and operation verification. By comparing how these methods act on memory formation, access, maintenance, and use, we analyze the trade-offs among preserving contextual relations, constraining retrieval scope, and managing extraction and maintenance costs. Drawing on experimental findings and an itinerary-change case study, we further examine the complementarity of these mechanisms and error diagnosis strategies to inform a course project centered on StructMem.

Key words: large language models; long context; structured memory; literature review

1　背景与阅读范围

在长期对话、持续任务与跨会话交互中，智能体需要持续积累并调用历史信息。随着交互历史增长，计划变更、证据跨轮分散以及用户陈述与模型推断相混淆等问题日益突出。直接输入完整历史会导致上下文开销迅速膨胀；仅将历史切分为独立片段做扁平检索，又容易割裂人物、时间、事件归属与状态变更之间的联系。因此，记忆系统需要协同解决信息的组织、访问、更新与利用问题。

结构化记忆通过显式定义记忆单元、关联关系、访问范围或操作语义，使历史信息更易于定位和维护。常见表示形式包括事件条目与整合摘要、多类型记忆网络、层级树、离散策略与连续轨迹混合表示，以及事实利用规则和结构化操作规范（Schema）。这些表示分别作用于记忆生命周期的不同环节，在信息粒度、关联表达与维护方式上各有侧重。

本文围绕课程专题中的六篇代表性论文展开综述：StructMem 与 Hindsight 重点探索长期对话记忆的组织与检索；Semantic XPath 聚焦树形层级记忆的结构化访问；HyMEM 面向依赖屏幕截图与动作轨迹的电脑操作智能体构建混合自演化记忆；MetaMem 关注检索后如何正确利用事实进行推理；Text2Mem 则定义统一的记忆操作规范并核验执行后的状态变化。

下文第 2 至 7 节依次介绍六篇论文的研究问题、核心机制、实验结果与局限；第 8 节从模型定位、机制衔接、设计权衡与具体案例四个方面展开横向比较，并探讨其对课程设计的启发；第 9 节总结全文。

2 StructMem：面向长程对话的结构化记忆

StructMem[1]针对长程对话中的上下文碎片化问题，提出事件级绑定与跨事件整合相结合的记忆组织方法。系统在抽取具体事实的同时保留人物互动关系与来源时间，并将新事件与相关历史汇总为跨事件摘要，在问答阶段联合细粒度条目与高层摘要提供互补证据。

2.1 研究问题与方法定位

在长程多会话对话中，同一事件的信息往往跨越多个话轮逐步展开：用户可能先提及初步计划，随后补充同行人员、具体时间或变更原因，对话同伴也会在回应中表达态度与偏好。若直接将对话切分为独立的原子事实，向量检索虽能命中局部关键词，却容易丢失事件归属、人际互动与状态演变脉络，导致模型在回答涉及共同经历或相对时间的问题时难以还原完整语境。

针对这一问题，StructMem 将语境关联的构建前移至记忆形成阶段。在事件内部，系统同步抽取客观事实与人际互动关系，并以来源时间戳将同一话轮下的条目相互绑定；在事件之间，系统检索与近期缓存相关的历史条目，还原完整事件上下文后生成跨事件整合摘要。这种“细粒度条目＋整合摘要”的双层表示无需微调基础模型参数，即可兼顾局部细节检索与跨期叙事线索。

相较于扁平事实库，StructMem 完整保留了事实周边的互动背景；相较于显式图结构记忆，它以带时间戳的自然语言条目和叙事摘要表达关联，仍通过向量相似度进行检索，从而避免了复杂的图谱构建与多跳遍历开销。

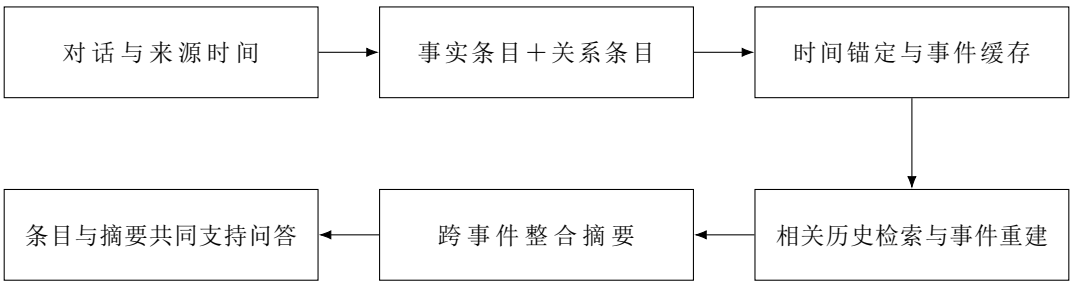


图 1 StructMem 的记忆构建与问答流程

2.2 事件绑定与跨事件整合

对于原始话轮 m_i，语言模型分别按照事实提示与关系提示抽取条目集合 Φ_i 和 Ψ_i。其中，事实条目记录客观事件、计划与偏好，关系条目记录人物之间的支持、回应、兴趣或评价。例如，当 Alice 分享录取消息、Bob 表示祝贺并询问研究方向时，事实条目记录录取结果与研究方向，关系条目则记录 Bob 对 Alice 的支持与关注。

每个条目 x 均包含自然语言文本、语义向量 $\mathbf{e}_x$ 与来源时间 τ_i，整体记忆库可表示为

$$\mathcal{M} = \bigcup_i \{\langle x, \mathbf{e}_x, \tau_i \rangle \mid x \in \Phi_i \cup \Psi_i\}. \tag{1}$$

当检索命中某一条目时，系统可通过共享时间戳 τ_i 一并取回同属该事件的其他条目，从而还原当时的事实与互动语境。每个条目同时保留 source_id 以关联原始话轮。由于来源时间 τ_i 记录的是话轮发生时间，回答相对时间问题时需以此为基准进行换算（如在 2023 年的对话中提及“去年参加活动”，对应事件实际发生于 2022 年）。

新抽取的条目按来源时间暂存于缓存中，默认在对话时间跨度满 1 小时后触发一次跨事件整合。此时，系统以缓存条目的向量检索历史记忆中的前 K 个相似种子条目（默认 $K = 15$），再沿共享时间戳扩展出这些种子所在的完整历史事件。设种子集合为 S_K，当前缓存为 C_{buf}，则跨事件整合的输入集合为

$$C_{\text{cross}} = C_{\text{buf}} \cup \bigcup_{x \in S_K} \{x' \in \mathcal{M} \mid \tau(x') = \tau(x)\}. \tag{2}$$

通过将语义相似检索（跨事件召回）与同时间戳扩展（事件内还原）相结合，与当前话题相关的历史事实及其周边回应、参与者和计划得以完整汇入整合上下文。

整合模型据此生成 200–350 个英文词的跨事件摘要，在提示词约束下保留人物、日期、地点、行动计划及来源编号，并在证据明确时建立跨期关联。生成的整合摘要与原始细粒度条目并存；在问答阶段，系统分别检索前 60 个细粒度条目与前 5 条整合摘要，一并送入回答模型完成人物核对、相对日期换算与答案生成。

论文中的共同经历案例直观展示了该机制的作用。当询问“Caroline 与 Melanie 何时一起参加过 Pride festival”时，相关线索分散在 2023 年的近期活动记录与同年对话中对“去年”结伴经历的追忆里。平面记忆因丢失伴随互动关系而误答“两人没有一起去过”，图记忆则混淆时间锚点而误答“2023 年 6 月”。StructMem 借助事件绑定还原了两人结伴讨论的语境，并通过跨事件摘要串联相对时间线索，准确推算出 2022 年。

2.3 实验设置与主要结果

论文在长程对话基准 LoCoMo 上开展评测。该数据集包含 10 段多会话长对话，平均每段 588 轮、16,618 tokens，共设单跳、多跳、时间推理与开放域四类问题 1,540 道（其中单跳题约占 54.6%），分别考察局部事实定位、跨轮证据联合、时间推算及外部知识结合能力。主实验以 gpt-4o-mini 作为基础模型，采用 text-embedding-3-small 提取向量，并由 LLM-as-a-judge 评判答案正确性（允许同义表述与等价日期格式）。表1对比了全量上下文（FullContext）与代表性记忆系统的表现。

表 1 LoCoMo 问答准确率（节选，%；加粗为列最大值）

方法	总分	单跳	多跳	时间	开放域
FullContext	73.83	**86.56**	68.79	50.16	56.25
Mem0g	68.44	75.71	65.71	58.13	47.19
Zep	75.14	79.79	**74.11**	67.71	**66.04**
Memobase	75.78	77.17	70.92	**85.05**	46.88
StructMem	**76.82**	81.09	68.77	81.62	46.88

实验结果显示，StructMem 取得 76.82% 的最高总体准确率，较 Memobase 与 FullContext 分别提升 1.04 和 2.99 个百分点。与直接输入全量历史相比，StructMem 在时间推理题上大幅提升 31.46 个百分点，多跳题基本持平，但在单跳题上低 5.47 个百分点；与其他外部记忆系统相比，StructMem 在占比较高的单跳题上明显占优，而 Zep 在多跳与开放域题型上表现更好，Memobase 则在时间推理上略高。可见不同记忆结构在局部事实保持与跨期关系建模上各有所长。

为剥离系统配置差异，表2进一步给出了同一框架下的组件消融结果。仅保留事件内绑定（去掉跨事件整合）时，单跳与时间推理准确率已优于扁平记忆（Flat Memory）与图记忆（Graph Memory）；在此基础上引入跨事件整合后，多跳与时间推理准确率进一步提升 2.46 和 2.18 个百分点，单跳微增 0.23 个百分点。这表明事件内绑定有助于稳固局部事实与时间锚点，而跨事件摘要则重点强化了分散证据的联合推理。

表 2 记忆组织消融的准确率（%）

配置	单跳	多跳	时间	开放域
Flat Memory	78.83	66.31	78.50	46.88
Graph Memory	80.50	66.67	76.64	48.96
去掉跨事件整合	80.86	66.31	79.44	46.88
StructMem	81.09	68.77	81.62	46.88

2.4 构建代价与生成可靠性

在记忆构建开销方面，StructMem 处理整个数据集共消耗 1.937M tokens、1,056 次 API 调用，耗时 22,854 秒；相较于图记忆系统 Mem0g，其构建 tokens 与 API 调用次数分别减少约 94.6% 和 98.0%，不过总耗时仍高于采用

轻量索引的 MiniRAG（2,566 秒）。在首段对话的受控对比中，平面记忆、StructMem 与图记忆分别消耗约 77.6k、226.1k（其中条目抽取约 151.0k、跨事件整合约 75.1k）和 402.3k 构建 tokens。通过按小时批量触发跨事件整合，StructMem 将构建开销控制在平面记忆与多阶段图构建之间。

检索范围消融表明，上下文规模并非越大越好。跨事件整合的历史种子数取 $K = 15$ 时总体准确率为 76.82%，增至 $K = 20$ 时反而回落至 76.23%；平面检索条数由 10 条增至 60 条时准确率从 70.91% 升至 75.78%，但继续增至 100 条时准确率停留在 75.71%，而 token 消耗则由 3.65M 增至 5.62M。适度扩大检索范围有助于提高证据覆盖率，但过度放宽阈值会引入无关历史噪声并推高推理成本。

在生成记忆的忠实性方面，三个独立裁判模型测得事件抽取阶段的平均幻觉率为 2.36%（1.61%–2.84%）。在跨事件整合阶段，保留时间戳与来源编号约束时，错误关联比例仅为 0.61%–3.63%；一旦移除上述约束，错误关联比例便激增至 7.45%–20.00%，证明显式的时间锚定与来源溯源能够有效抑制摘要过程中的跨期拼凑。此外，在更换问答裁判模型的复核中，三个裁判的 Fleiss' κ 达 0.8341，StructMem 均保持领先，与 Memobase 的总分差值在 0.06–1.04 个百分点之间波动。

2.5 方法局限与课设启发

StructMem 通过“事件内绑定＋跨事件摘要”在保留语境关联与控制构建成本之间取得了良好平衡，但当前框架尚未建立显式的冲突消解与状态覆盖机制。当用户在后续会话中更改计划或偏好时，旧条目与旧摘要仍会留在记忆库中参与检索，仅靠问答提示词中的“优先近期记忆”难以彻底避免新旧信息混杂。若能利用 source_id 追踪摘要所依赖的底层条目，便可在事实更新时精准定位并刷新受影响的摘要。

围绕这一思路，本组课程设计以 LoCoMo 数据集上的 StructMem 复现为主线，在固定基础模型与检索预算的条件下，依次对比扁平事实检索、事件内绑定以及引入跨事件整合的三组配置，并结合关系条目消融、时间锚点消融与计划变更案例，深入分析记忆组织方式对证据召回、时间推理及状态维护的具体影响。

3 Hindsight：保留、召回与反思的结构化智能体记忆

Hindsight[2]面向跨多轮对话与多会话交互的智能体，将长期记忆划分为四类逻辑网络，并通过 retain、recall 和 reflect 三种操作分别管理信息写入、多通道检索与基于证据的推理生成。

3.1 研究问题与四类记忆

长程对话智能体在记忆管理上通常面临三方面挑战：如何在持续增长的历史中提炼高价值信息、如何跨会话准确召回多跳证据，以及如何在生成回答时保持全局一致性。传统的扁平向量检索将所有历史片段同等对待，不仅容易混淆用户陈述的客观事实与智能体派生的主观推断，也难以显式表达实体关联与时间演变脉络。

为此，Hindsight 在每个记忆库（memory bank）中构建了四类逻辑网络（表3）：其中，World 与 Experience 分

表 3 Hindsight 的四类记忆

网络	保存内容	例子或作用
World	关于外部环境的客观事实	Alice 在 Google 的 Mountain View 团队工作。
Experience	智能体自身采取过的行动	智能体曾向 Alice 推荐徒步旅行。
Observation	根据多条事实整合出的实体摘要	Alice 是专长于机器学习的软件工程师。
Opinion	带置信度、可随证据变化的主观判断	“Python 适合数据科学”，并记录置信度。

别记录外部客观事实与智能体自身经历，Observation 汇总跨会话的实体画像，Opinion 则单独维护带置信度的主观判断。通过将客观事实、综合概括与主观观点显式隔离，系统能够针对不同性质的信息采取差异化的检索与更新策略。所有记忆单元均记录事件发生时间区间与系统获知时间，并通过时间、语义、实体及因果关系连接成图。

3.2 三种操作：写入、检索与生成

Retain 负责接收对话或文档，调用语言模型提取较粗粒度的叙事事实（每段对话通常提取 2–5 条），以减轻文本切分过碎造成的语境割裂。随后，系统对提取出的条目执行网络分类、实体识别与消歧、双时间标注（区分事件发生时间与系统获知时间）以及关系建图。

Recall 根据查询与预设的 token 预算检索相关记忆，返回预算上限内重排后的条目。该过程并行启用四条检索通道：HNSW 向量语义检索、BM25 关键词匹配、沿实体 / 时间 / 因果边的 2–3 跳图遍历，以及事件时间区间过滤（优先使用规则解析常见时间表达，复杂表达则回退至轻量 T5 模型）。四路召回结果经倒数秩融合（Reciprocal Rank Fusion）合并后，再由交叉编码器（cross-encoder）精细重排，并按 token 预算截断输出。

Reflect 将查询、召回记忆与可配置的行为档案输入生成流程，其中行为档案由怀疑程度、字面倾向与共情程度三个 1–5 分的参数控制。系统在生成回答的同时动态维护 Opinion 网络：每个观点带有 $[0, 1]$ 区间内的置信度，遇到支持性新证据时调高置信度，出现反证时则予以调低。后台整合进程还会记录支持引文、证据数量以及从 new 到 stale 的新鲜度状态，确保主观判断始终可回溯至底层事实证据。

在系统架构上，retain 与 recall 共同构成 TEMPR（Temporal Entity Memory Priming Retrieval）模块，reflect 则对应 CARA（Coherent Adaptive Reasoning Agents）模块。底层存储基于 PostgreSQL、pgvector 与全文检索索引实现；在 10,000 条记忆规模下，recall 阶段的纯检索延迟低于 200 ms。

3.3 实验设置与结果

论文在 LongMemEval 与 LoCoMo 两个长程对话基准上评测系统表现。LongMemEval 的 S 设置包含 500 道问题，单段对话最长约 150 万 tokens；LoCoMo 包含最多 35 个会话的多会话长对话。表4展示了 Hindsight 搭配不同规模与系列模型时的问答准确率。

表 4 Hindsight 在两项基准上的回答准确率（%）

基准	Hindsight 20B	Hindsight 120B	Hindsight Gemini-3
LongMemEval	83.6	89.0	91.4
LoCoMo	83.2	85.7	89.6

在 LongMemEval 上，Hindsight 配合开源 20B、120B 模型及 Gemini-3 分别取得 83.6%、89.0% 和 91.4% 的准确率；在 LoCoMo 上则分别达到 83.2%、85.7% 和 89.6%。细分题型来看，20B 配置在 LongMemEval 的时间推理与多会话题上均达到 79.7%，而在主观性较强的偏好题上为 66.7%，反映出隐式偏好归纳相较于显式事实检索仍具挑战。作为对比参照，LongMemEval 上全文 GPT-4o 为 60.2%、Supermemory-Gemini-3 为 85.2%，LoCoMo 上 Zep、Memobase 与 Backboard 分别为 75.1%、75.8% 与 90.0%。

3.4 方法局限与课设启发

Hindsight 的局限主要在于其构建与维护高度依赖大模型调用：事实抽取、实体消歧或关系建图阶段的偏差可能沿记忆图传播；评测目前仅覆盖英文数据集，且时间解析器对含混或特定文化背景下的时间表达仍有遗漏；Opinion 网络的观点质量与置信度校准尚待系统的用户研究验证。此外，长期持久化存储用户偏好与观点也对个人隐私保护（如 PII 自动检测与脱敏）提出了更高要求。

对本组课程设计而言，Hindsight 在记忆角色划分与多路检索上的设计极具参考价值：通过区分客观事实、实体摘要与主观判断，并结合向量、关键词、时间和实体图多路召回，可以有效弥补单一语义检索在时间过滤和跨会话实体追踪上的短板；显式的 token 预算控制也为公平对比不同检索策略提供了规范接口。

4 Semantic XPath：树形结构化记忆的查询访问

Semantic XPath[3]聚焦结构化对话记忆的精准访问，结合树路径导航、位置筛选与连续语义评分，从层级记忆树中定位目标节点及子树，为下游回答与状态更新提供上下文。

4.1 研究问题与方法定位

在长期任务导向对话中，用户常围绕同一任务对象（如旅行计划、待办清单）反复查看、修改或回溯。其中一项具体活动不仅包含文本描述，还从属于特定日期、行程和历史版本。直接输入全量历史开销高昂；扁平检索虽能缩减输入，却易召回语义相似但所属日期或版本错误的条目。例如“在会议最密集的一天增加咖啡休息”，需要先按日期聚合评估各天活动，而非仅找一条含“会议”字样的文本。Semantic XPath 据此将结构路径约束与软语义匹配结合，专门负责在树形记忆中锁定访问范围，再交由下游完成回答或节点增删改。

4.2 树形数据模型与查询语法

系统将记忆表示为有根树 $T = (V, E, r)$，非根节点具有唯一父节点，各节点包含类型标签与文本属性，树模式 Σ 由数据自身的节点类型、属性与父子关系自然形成。旅行规划场景采用

$$\text{Itinerary} \rightarrow \text{Version} \rightarrow \text{Day} \rightarrow \text{POI},$$

依次表示行程、版本、日期和活动；上下层体现组成与归属关系，完整保留底层细节而非仅做有损摘要。

查询由步骤序列组成，单步写为 $S = A\,N\,[R]\,[P]$，其中路径轴 A 与节点类型 N 必选，位置选择器 R 与语义谓词 P 可选（表5）。

表 5 Semantic XPath 查询步骤的组成

组成	示例写法	作用
路径 A	/、//	访问直接子节点或全部后代
类型 N	Day、POI、*	按节点类型筛选或匹配任意类型
位置 R	[i]、[-i]、[i:j]	按顺序、倒序或区间选取候选
语义 P	[node~="workshop"]	计算候选与语义条件的相关程度

例如，//Day[3]/POI[node~="workshop"] 先定位第 3 天，再对该日期下的活动计算语义得分；存在多个行程或版本时，可通过前缀路径先限定目标范围。语义条件还支持通过 $1 - P$ 取反，以筛选与指定概念无关的候选节点。

4.3 语义评分与带权执行

节点 u 对语义谓词 P 的满足程度定义为连续相关度 $\text{Rel}(u, P) \in [0, 1]$。除基于当前节点属性的局部评分外，查询还支持嵌套子查询，先对下层节点评分，再用平均（avg）、最小、最大或几何平均聚合下层证据；多个条件可通过乘积、均值及取反组合。

```
//Day[avg(/POI[node~="conference"])]
```

该查询通过聚合每日下属活动的语义得分来评价日期。示例中第 2 天的三个活动得分为 0.603、0.482 和 0.608，均值约 0.565，在候选日期中排名最高，从而被识别为会议最密集的一天。

执行器从根节点及初始权重 1 出发，维护带权集合 $W \subseteq V \times [0, 1]$，按步骤执行路径扩展、类型筛选、位置选择与语义评分更新：

$$w_{\text{new}} = w_{\text{old}}\,\text{Rel}(u, P). \tag{3}$$

遇到聚合条件时递归求值下层子查询，最终按预设阈值或返回数量输出高权重节点及子树。

4.4 范围约束示例

以行程调整为例，假设当前版本第 2 天安排海滨公园，第 5 天安排山地徒步，第 7 天安排植物园和海港游船。面对“找出第 7 天下雨时需调整的户外活动”，纯向量检索易混入其他日期的户外活动；结构化访问则先限定第 7 天子树，再评估户外属性，准确锁定植物园与游船。单层日期约束虽可由带元数据过滤的扁平 RAG 实现，但 Semantic XPath 还能统一处理多级版本嵌套及依赖子节点聚合评分的复杂访问需求。

4.5 实验设置与结果分析

论文在旅行行程、待办清单和家庭配餐三个自建场景（每场景 20 个单轮、5 个多轮对话）以及 LoCoMo 原生会话层级（Memory–Conversation–Session–Turn）上评测。回答模型采用 GPT-5 mini 与 Gemini 3 Flash；相似度评分（XPath Sem）与 Flat RAG 使用 Qwen3-Embedding-8B，蕴含评分（XPath Entail）使用 facebook/bart-large-mnli。自建场景统计任务通过率（需检索正确数据且输出符合约束），LoCoMo 统计模型裁判得分，并将 XPath 查询生成输入计入平均输入 tokens。

表 6 三个自建场景的平均单轮结果

回答模型	方法	通过率（%）	平均 tokens
GPT-5 mini	In-context	70.0	26 216
	Flat RAG	30.0	3 250
	XPath Sem	66.3	6 166
	XPath Entail	83.0	5 691
Gemini 3 Flash	In-context	79.0	25 387
	Flat RAG	37.7	3 361
	XPath Sem	64.3	6 043
	XPath Entail	70.7	5 830

单轮实验（表6）中，GPT-5 mini 配合 XPath Entail 的通过率达 83.0%，较 Flat RAG 提升 53.0 个百分点，且 token 消耗仅为全量上下文的 21.7%；在 Gemini 3 Flash 上，XPath Entail（70.7%）同样大幅优于 Flat RAG（37.7%），但略低于全量上下文（79.0%）。

表 7 三个自建场景的平均多轮结果

回答模型	方法	通过率（%）	平均 tokens
GPT-5 mini	In-context	80.0	69 097
	Flat RAG	26.7	3 327
	XPath Sem	70.0	6 294
	XPath Entail	83.3	5 850
Gemini 3 Flash	In-context	56.7	76 603
	Flat RAG	26.7	3 240
	XPath Sem	76.7	6 092
	XPath Entail	80.0	5 993

在包含多次版本修改的多轮实验（表7）中，XPath Entail 在两种模型下均取得最高通过率（83.3% 与 80.0%），

token 用量仅为全量上下文的 8.5% 与 7.8%；同时 Entail 稳定优于 Sem，说明蕴含模型更适合判定条件满足关系。

表 8 LoCoMo 结果（XPath 输入含查询生成）

回答模型	方法	回答得分	平均输入 tokens
GPT-5 mini	In-context	74.55	24 857
	Flat RAG	35.71	1 341
	Semantic XPath	65.19	3 032
Gemini 3 Flash	In-context	87.01	27 499
	Flat RAG	41.49	1 996
	Semantic XPath	73.25	3 870

在 LoCoMo（表8）上，Semantic XPath 仅用全量上下文 12.2%–14.1% 的输入 tokens，便大幅超越 Flat RAG，但仍低于全量上下文（如 GPT-5 mini 多跳题得分为 43.26，低于全量上下文的 58.87）。原文错误分析指出，自由对话缺乏显式业务树，跨分支多跳查询易在节点检索阶段出现漏召回或选错发言节点。

4.6 方法局限与课设启发

Semantic XPath 兼具结构范围约束与评分可解释性，但依赖清晰的层级质量与准确的查询生成，处理跨树关联和复杂多跳仍有局限。与侧重写入期事件绑定的 StructMem 相比，Semantic XPath 侧重读取期范围收缩；课程设计可将二者结合，在检索时先按会话、日期或版本收敛候选范围，再匹配具体事件条目。

5 HyMEM：电脑操作智能体的混合自演化记忆

HyMEM[4]面向需要观察屏幕截图并连续操作网页的电脑操作智能体，通过融合离散策略与连续轨迹表示构建混合记忆网络，并配合跨任务的长期记忆演化与任务内的工作记忆刷新，动态适应交互阶段的变化。

5.1 问题背景与混合表示

网页操作智能体以任务描述、当前截图和历史成功轨迹为输入，逐步生成下一步可执行动作。在此类多模态任务中，历史经验兼含高层策略与底层界面交互细节：纯文本总结容易丢失按钮位置、页面布局等视觉线索，单纯连续编码又缺乏清晰的策略组织与可解释索引；同时，随着任务从商品搜索推进至结账，子目标已发生转移，初始检索的经验不再适用，但全局预算等约束仍需保留。

论文在记忆图 $G = (V, E)$ 中以三元组表示单条历史轨迹：

$$v_i = (c_i, A_i, m_i), \tag{4}$$

其中 c_i 为高层策略，A_i 为动作、界面元素或领域标签构成的属性集合，m_i 为连续轨迹编码。共享相同属性的节点通过无向边相连，利用离散策略与属性构建语义索引网络；同时借鉴 CoMEM 的连续编码器将每条多模态轨迹压缩为 8 个嵌入向量 m_i，保留难以用文字概括的视觉与动作细节。检索时，系统将归一化后的任务文本 CLIP 向量与起始截图 CLIP 向量拼接，通过 FAISS 寻找相似经验。

5.2 全局记忆演化与结构化检索

更新长期记忆图时，系统先为新轨迹检索相似候选经验，再由视觉语言模型评估其信息增量，并执行三类操作：

（1）ADD：出现新策略或新属性时，新增对应节点与连接。

（2）MERGE：已有策略获得界面变体或替代路径等互补证据时，将新证据并入对应策略及属性关联。

（3）REPLACE：在同等条件下，新轨迹以更少步骤、更高成功率或更低风险实现同一策略时，用其替换过时证据并刷新关联。

上述操作在长期图中持续积累可迁移经验并抑制冗余。

推理检索时，系统先依据任务与截图召回语义相似的种子轨迹，再沿共享属性边扩展邻居并按相似度排序。主实验每次取回 10 条轨迹，由 5 条语义相似种子及其 1 跳邻居中选出的 5 条关联轨迹组成。

5.3 混合工作记忆及局部刷新

召回的经验形成两个互补视图：策略与属性汇总为指导指令（Guidance Instructions）写入系统提示词，辅助宏观规划；连续轨迹嵌入 m_i 则直接接入模型输入，提供细粒度视觉与动作参照，二者共同构成当前任务的工作记忆。

每步动作后，视觉语言模型对比前后页面观测与当前指导，判断是否发生阶段转换。若任务由搜索转入结账，系统在保留全局目标与约束的前提下剔除过时的阶段指导，再按新页面状态重新检索，合并新指导并刷新连续嵌入，从而在任务内部实现工作上下文的动态更新。

5.4 实验设置与结果

论文在 WebVoyager、Multimodal-Mind2Web 和 MMInA 三个多模态网页智能体基准上评测。前两者根据任务描述与截图轨迹由模型判分，MMInA 比对最终回答与标准答案，主指标均为各领域平均任务成功率（Overall）。记忆库由 GUIAct、Mind2Web 训练集及智能体自身生成的 2,883 条成功轨迹构成，主实验图含 1,858 个节点和逾 100 万条边。执行采用 ReAct 接口，配合 SOM 界面标记及 UI-INS-7B 定位回退；训练仅更新记忆编码器的 Q-Former 与 LoRA 层（约占总参数的 1.2%，训练 1 个 epoch）。

表 9 不同记忆表示下的 Overall 任务成功率（%）

基础模型	无记忆	离散记忆	连续记忆	HyMEM
Qwen2.5-VL-7B	12.5	17.0	21.7	35.0
Qwen3-VL-8B	21.9	21.3	23.3	33.8
UI-TARS-1.5-7B	17.1	15.4	28.7	31.2

表9显示，HyMEM 在三种模型上均取得最高总体成功率，其中 Qwen2.5-VL-7B 从无记忆时的 12.5% 升至 35.0%（提升 22.5 个百分点），显著优于单独的离散或连续记忆，验证了高层策略与轨迹细节的互补性。后两种模型在仅使用离散记忆时略低于无记忆基线，结合连续轨迹后则均获明显提升。在 Amazon 与 Google Maps 的消融分析中，相较于静态记忆，全局演化使成功率分别由 48.8% 升至 61.0%、43.9% 升至 51.2%，局部刷新亦分别达到 56.1% 和 48.8%，证实了两层动态更新机制的作用。

5.5 方法局限与课设启发

HyMEM 通过混合表示与两层演化提升了网页操作表现，但在记忆构建、编码器训练、图扩展及每步阶段判定上增加了计算开销；属性标签或阶段判断失误也可能引起错误传播。对纯文本对话记忆而言，可重点借鉴其“语义种子＋结构邻居”的扩展检索方式，以及区分“跨会话长期记忆演化”与“当前会话工作上下文刷新”的双层维护思路。

6 MetaMem：由事实存储转向事实利用

MetaMem[5]聚焦记忆检索之后的事实利用环节：即便检索模块已召回相关历史片段，模型仍可能因误判时间先后、数量包含或事件归属而答错。该方法将可复用的知识使用策略提炼为“元记忆”（Meta-Memory），并通过离线答案反馈与自我反思迭代优化。

6.1 研究问题与两种记忆

长程对话常包含复杂的时间跨度、数量统计与整体—部分关系。例如，某次旅行总里程为 1200 英里（含首日 300 英里），另三次旅行合计 1800 英里；计算四次旅行总里程时应为 3000 英里，但模型易将首日 300 英里重复累加而误答 3300 英里。此类错误并非源于事实漏检，而是由于整合多条记忆时缺乏对包含关系的核验。

论文据此区分事实记忆 M 与元记忆 E：前者存储具体的对话经历与客观知识，后者存储跨任务可迁移的推理与核验规则（如计数前先检查子项是否已计入总额）。设问题为 q，问答过程可表示为

$$\hat{y} = \mathrm{LLM}\big(\mathrm{Prompt}(q, M, E)\big). \tag{5}$$

传统记忆问答仅输入 (q, M)，MetaMem 则将 E 一并写入提示词；优化过程仅调整自然语言规则集合 E，基础语言模型的参数权重保持不变。

6.2 从反馈到规则的自反思优化

方法分为离线规则学习与在线冻结推理两个阶段。离线训练时，给定带标准答案的样本 (q, a, M)，模型在当前元记忆下多次采样生成回答，并由评判模型对照标准答案给出反馈。反思模块据此归纳正误原因，提出规则的新增、删除或修改建议，再合并批内重复与冲突提案。系统依据验证集选择最优规则版本；测试阶段则冻结元记忆 E，直接用于新问题的事实推理。

训练数据与候选回答 $\longrightarrow$ 正误反馈与反思 $\longrightarrow$ 规则编辑与合并 $\longrightarrow$ 冻结后的元记忆 E $\longrightarrow$ 新问题的事实利用

多次采样、反思与编辑的开销集中在离线阶段，在线问答仅增加少量规则提示词输入。

6.3 实验设置与结果

主要数据集 LongMemEval 包含 500 道问题，采用五折交叉验证（每折 350 题训练、50 题验证、100 题测试）。实验以 LightMem 为事实记忆基座，测试 Qwen3-30B-A3B-Instruct 与 Llama3.1-70B-Instruct 两种生成模型，默认使用 Qwen3-235B-A22B 作为评判模型；离线规则学习运行 5 个 epoch，每批 50 题，每题采样 5 次。

表 10 LongMemEval 平均准确率（%）

生成模型	LightMem	MetaMem	增量（百分点）
Qwen3-30B-A3B-Instruct	67.50	71.90	+4.40
Llama3.1-70B-Instruct	66.17	69.08	+2.91

在底层事实记忆相同的条件下，MetaMem 使两种生成模型的平均准确率分别提高 4.40 和 2.91 个百分点。Qwen 配置下，完整方法为 71.90%，移除反思模块后降至 70.02%，进一步移除规则演化后降至 68.33%，验证了反思归纳与多轮规则演化的共同贡献。

6.4 方法局限与课设启发

MetaMem 将事实召回与事实利用解耦，以可读的自然语言规则纠正重复计数、时间错位等常见推理偏差。但该方法以关键事实已被成功召回为前提；离线优化依赖标注样本与评判模型，规则过多或泛化过度时也可能干扰边界样本推理。在课程设计中，StructMem 负责组织与召回事件证据，MetaMem 则启发我们将失败样本划分为“检索证据缺失”与“上下文证据误用”，并在固定召回证据下针对性优化推理提示。

7 Text2Mem：记忆操作的统一表达与状态验证

Text2Mem[6]面向自然语言驱动的记忆管理，提出统一的记忆操作规范（Schema）与配套评测基准。系统将更新、合并、降级或定期清理等自然语言指令解析为结构化操作对象，映射至底层存储执行，并通过后置状态断言核验执行效果。

7.1 研究问题与适用范围

长期交互不仅需要检索历史信息，还需对记忆的优先级、有效期、合并与删除进行精细控制。日常指令往往存在操作语义歧义，例如“暂时不要再提午餐”通常意指下调显著性权重，而非永久删除记录。若缺乏明确的操作类型、作用范围与时间参数约束，系统即便成功调用接口，也可能误改无关记忆。Text2Mem 因此在自然语言指令与底层存储引擎之间引入结构化操作中间层，将记忆生命周期语义与具体后端实现解耦（论文主实验基于 SQL/SQLite 环境评测）。

7.2 操作集合、Schema 与执行流程

论文围绕编码（ENC）、存储（STO）和检索（RET）三个阶段定义了十二种操作：编码阶段含 Encode；存储阶段含 Update、Label、Promote、Demote、Merge、Split、Delete、Lock 和 Expire 九种操作；检索阶段含 Retrieve 与 Summarize。其中，Encode 组织内容、语义标签、来源与治理属性（支持延迟生成向量）；Promote 与 Demote 调整记忆显著性（Demote 支持归档降权而不删除）；Delete 处理软 / 硬删除，Expire 设置到期规则，三者在生命周期语义上严格区分。

操作规范包含 stage、op、target、args 和 meta 五个字段，依次对应阶段、动作、目标、专属参数与执行元数据。不同操作对应特定的必填与跨字段约束：例如 Encode 新建记录时无需先选定已有目标；针对存量记忆的操作则需在 target 中从 ids、filter、search、all 四类选择器中择一明确范围，并受锁定保护与批量写入权限限制。

执行流水线中，Validator 首先校验结构完整性与跨字段约束；Parser 将合法实例解析为类型化操作并归一化时间与优先级参数；Adapter 最终将其映射为后端数据库动作，返回记录受影响条目和状态变化的 ExecutionResult。多步请求可表示为保留依赖顺序的 schema_list 依次执行。

例如，针对“提高本周课设进度笔记的重要性，其他记录不变”，系统对条目 17 执行 STO 阶段的 Promote 操作，将 ids=[17] 的 weight 设为 0.9，并在执行后同时核验目标权重、原有内容与非目标条目，确保仅改动指定范围。

7.3 基准、指标与主要结果

评测基准由自然语言指令、前置操作建立的初态、参考 Schema 和后置 SQL 状态断言组成，覆盖中英双语、直接与间接表达、单步操作与多步工作流，并在统一提示模板下评测了 GPT-4o、Qwen2.5-72B-Instruct、Claude-4-Sonnet、Gemini-2.5-Pro 与 GPT-5 五种模型。

评测包含三项指标：结构匹配度（SMA）用编辑距离或余弦相似度衡量生成 Schema 与参考 Schema 的一致性；执行成功率（ESR）统计通过校验且无运行错误的实例比例；执行匹配率（EMR）统计执行后满足的 SQL 状态断言占全部期望断言的比例：

$$\mathrm{EMR} = \frac{\sum_i \sum_{a \in A_i} \mathbb{I}(a)}{\sum_i |A_i|}. \tag{6}$$

其中 A_i 为第 i 个实例的断言集合，断言 a 满足时 $\mathbb{I}(a) = 1$，否则为 0。由于 EMR 按断言汇总，包含更多检查项的复杂实例对总体得分权重更高。

表 11 Text2Mem 总体评测指标

模型	$\mathrm{SMA}_{\mathrm{lev}}$	$\mathrm{SMA}_{\mathrm{cos}}$	ESR	EMR
GPT-4o	0.6776	0.8690	0.9484	0.2532
Qwen2.5-72B-Instruct	0.6195	0.8349	0.9510	0.2535
Claude-4-Sonnet	0.6230	0.8475	0.9594	0.3132
Gemini-2.5-Pro	0.6491	0.8560	0.9479	0.2897
GPT-5	0.6115	0.8396	0.9662	0.2826

表11显示，各模型的 ESR 均达 94.79%–96.62%（GPT-5 最高），但 EMR 仅为 25.32%–31.32%（Claude-4-Sonnet 最高）。这一落差说明当前模型虽能稳定生成语法合规、可执行的操作指令，但在准确锁定目标范围并达成预期存储状态上仍有明显瓶颈。

在复杂操作与多步工作流上差距尤为突出：五个模型的 Split EMR 均为 0，Merge 仅 GPT-4o 取得 0.0465，其余为 0；GPT-5 的单步操作 EMR 为 0.2930，而在多步工作流中尽管 ESR 为 1.0000，EMR 却降至 0.1190，表明跨步状态依赖传递是主要难点。

7.4 方法局限与课设启发

Text2Mem 将结构校验（ESR）与后置状态核验（EMR）分离，清晰揭示了“指令可执行”与“状态改得对”之间的差距。不过，现有实验主要在离线 SQL 环境中评测，尚未接入长程对话循环检验状态更新对后续问答的长

期影响；若状态断言未充分覆盖非目标记录，也可能漏检误改旁支数据的副作用。在课程设计中，为 StructMem 补充计划变更与失效维护时，可借鉴 Text2Mem 将模糊变更要求显式化为 Update、Demote 或 Expire 操作，并在执行后同时核验目标事件与无关历史条目。

8 跨论文比较与讨论

上述六篇论文围绕“如何将持续增长的交互历史转化为可定位、可维护、可推理的结构化记忆”展开，分别切入记忆流水线的组织构建、范围访问、动态演化、推理利用与操作验证环节。本节从机制定位、上下游衔接、设计权衡、实验评价与共同案例五个方面展开比较，并讨论其对课程设计的启发。

8.1 研究对象与核心机制

表12汇总了六项工作的研究对象、核心机制及其应用边界。

表 12 六篇论文的研究定位与适用条件

工作	研究对象与表示	主要着力点	关键前提与边界
StructMem	长对话中的事件条目与跨事件整合摘要	事件内事实—关系绑定与跨事件叙事整合	依赖事件与关系抽取，需保留话轮来源时间戳
Hindsight	客观事实、自身经历、实体摘要与观点网络	记忆分类存储、四通道召回与观点置信度更新	依赖实体消歧与时间解析质量，检索含多路重排
Semantic XPath	树形层级记忆及其子树与节点	结合树路径导航、位置筛选与连续语义评分	依赖清晰的树形层级与模型生成查询的准确性
HyMEM	网页操作中的离散策略与连续多模态轨迹	离散—连续混合表示、长期图演化与局部刷新	面向多模态 GUI 轨迹，需配合编码器微调与阶段判定
MetaMem	事实记忆之外的可复用推理与核验规则	基于答案反馈与自我反思提炼元记忆规则	离线训练需标注样本与反馈采样，在线依赖事实召回
Text2Mem	面向记忆管理的结构化操作 Schema	规范十二种操作语法，分离执行校验与状态核验	需底层存储支持操作映射并具备完备的状态断言集

8.2 机制之间的联系

从记忆系统的全生命周期来看，六篇论文在读写链路的不同阶段形成紧密的上下游互补关系。

在写入组织与读取访问方面，StructMem 通过同时间戳事件绑定与跨事件摘要保存语境关联，克服了扁平切片丢失人际互动和叙事脉络的缺陷；Semantic XPath 则在读取阶段利用树路径与位置条件先锁定目标分支，再做语义评分，避免全局检索混入其他时期或版本的干扰项。若将二者结合，可将事件摘要与原始条目组织为“会话—事件—条目”层级树，兼具跨期叙事整合与局部范围收敛能力。

在多路召回与事实推理方面，Hindsight 通过 retain、recall 与 reflect 串联记忆分类存储与四通道混合召回，重在提升复杂查询的证据覆盖率；MetaMem 则进一步解决取回证据后的推理误用问题（如重复累加、时间错位或主次混淆）。二者结合能够分别加固“找全相关证据”与“正确使用证据”两个环节，并为区分检索漏召回与推理偏差提供清晰边界。

在角色划分与动态维护方面，Hindsight 分离事实、经历、实体摘要与观点，MetaMem 分离事实与推理规则，均体现了按信息性质分层管理的思想。在更新机制上，HyMEM 从决策层面判定何时新增、合并、替换长期经验以及何时刷新任务内工作记忆；Text2Mem 则从执行层面规范更新、升降级、合并与过期操作的 Schema 及后置状态断言，前者解决“何时更新、更新什么”，后者保障“更新指令被准确解析并落实到底层存储”。

8.3 结构化记忆的收益与代价

引入结构化记忆在提升长上下文表现的同时，也需要在三方面权衡收益与工程代价。

一是语境保持与抽取误差传播。事件绑定、实体图与层级树能够显式保留指代、时间与从属关系，改善多跳与时间推理；但若构建期发生实体消歧错误、时间戳误绑或摘要幻觉，错误结构也会固化至记忆库中。因此，保

留向原始话轮（source_id）的回溯链路并在提示词中施加时间与来源约束尤为关键。

二是召回覆盖率与上下文信噪比。多通道融合、同时间戳补齐与图邻居扩展能够弥补单一向量检索的遗漏，但扩展过宽也会引入冗余噪声并推高 token 开销。例如 StructMem 在种子数由 $K = 15$ 增至 $K = 20$、或平面检索由 60 条增至 100 条时，准确率均不再提升，说明结构化扩展需配合合理的上下文预算与重排截断。

三是自适应演化与维护验证成本。通过离线反思提炼规则（MetaMem）、在线演化经验图（HyMEM）或编译结构化操作（Text2Mem）增强了系统的适应性与可控性，但也带来了多次采样、编码器微调或在线判定的开销；同时，Text2Mem 中逾 94% 的 ESR 与仅 25%–31% 的 EMR 表明，语法合法的操作仍可能偏离业务意图，必须结合细粒度状态核验。

8.4 实验条件与评价指标

六篇论文分别面向长程对话问答、树结构访问、多模态网页操作与数据库状态控制，评测基准与核心指标各有侧重（表13）。即便同用 LoCoMo，各工作在基础模型、检索预算与裁判提示上也不尽相同，因此分析机制收益时应重点依据同一实验框架下的组件消融与开销对比。

表 13 任务、评价对象与比较条件

任务与代表工作	指标测量的对象	比较时需对齐的条件
长对话问答：StructMem、Hindsight、MetaMem	长程对话问答的准确率或裁判评分（单跳、多跳、时间等题型）	数据划分、基础模型、检索上下文预算与评判提示词
结构访问：Semantic XPath	自建结构化任务的约束通过率；LoCoMo 的回答得分	树层级定义、评分器模型、token 统计范围与查询开销
网页操作：HyMEM	基于屏幕截图与动作轨迹的多模态任务成功率	网页交互环境、经验轨迹来源、界面定位器与训练设置
记忆操作：Text2Mem	结构相似性 SMA、执行成功率 ESR、状态断言满足率 EMR	初始数据库状态、操作复杂度、断言覆盖范围与统计粒度

在组件消融上，StructMem 加入跨事件整合后，多跳与时间推理分别提升 2.46 和 2.18 个百分点，开放域保持不变，印证了跨事件摘要主要服务于跨期证据串联；MetaMem 在 Qwen 配置下移除反思或规则演化后，准确率由 71.90% 依次降至 70.02% 与 68.33%，展示了反馈反思与规则合并的各自贡献。

在性能与开销的综合评估上，系统总成本可拆分为构建整合、在线检索回答与离线优化三部分：例如 Semantic XPath 在 LoCoMo 上虽比全量上下文低 9.36–13.76 分，但节省了 85% 以上的输入 tokens；StructMem 通过按小时批量整合，将构建 tokens 控制在 Mem0g 的 5.4% 左右。分别统计三类开销有助于明确各机制在不同查询频率下的适用场景。

8.5 共同案例：行程变更中的范围、状态与证据

以跨会话行程变更为例，设用户依次留下三条记录：s_1（10 月 20 日）：“10 月 23 日去 A 地”；s_2（10 月 21 日）：“取消 A 地，改为 10 月 24 日去 B 地”；s_3（10 月 22 日）：“10 月 24 日先到 B 地，再去 C 地，仍按新计划”。面对问题“当前计划哪天出行，经过哪些地点”，正确回答应综合 s_2, s_3 给出“10 月 24 日，先 B 地后 C 地”。该例同时涉及发言时间与出行时间的区分、旧计划失效以及同版本路线合并（表14）。

表 14 行程变更示例中的机制分析

研究视角	在本例中的核心作用	落地所需的关键条件
StructMem	绑定每条陈述的时间与地点，通过跨事件整合串联 s_2, s_3	整合摘要需准确捕捉取消关系，并标记 s_1 旧计划失效
Hindsight	区分发言获知时间与出行发生时间，结合实体、时间与语义召回	时间解析器需准确换算日期，并在事实网络中更新计划状态
Semantic XPath	按“行程—版本—日期—地点”建树，先锁定最新版本再读取地点	计划修改时需生成新版本子树并维护当前有效版本指针
MetaMem	利用元记忆规则指导模型优先采纳最新变更，合并同版本路线	底层检索需同时召回 s_2, s_3，且规则明确新旧冲突消解顺序
Text2Mem	将修改意图解析为 Update / Expire 等规范操作，核验更新后状态	准确定位目标行程，并通过断言确认旧地点已移除、新地点已写入
HyMEM	将计划变更视为阶段转移，保留出行总目标并刷新当前有效路线	准确检测变更触发点，及时剔除工作记忆中已作废的旧路线

若用户继续要求“暂时不要再提这次行程”，系统还需区分下调检索权重（Demote）、设置阶段性过期（Expire）与删除记录（Delete）三种操作语义，并在执行后核查目标行程权重、内容完整性及无关记录状态，从而将潜在错误准确定位至抽取遗漏、范围误检、新旧混淆或执行误改四个环节。

8.6 课程设计与实验思路

综合上述分析，本组课程设计以 LoCoMo 数据集上的 StructMem 复现与消融为主线，在统一回答模型与检索预算下对比原始对话 Flat RAG、仅保留事件内绑定的变体以及完整 StructMem，系统记录四类题型准确率及构建与推理开销。

同时，我们吸收其余五篇工作的机制开展模块化错误归因：参考 Hindsight 与 Semantic XPath 检查时间锚点与会话范围约束；参考 MetaMem 固定召回证据，单独排查重复计数或时间换算等推理错误；参考 HyMEM 与 Text2Mem 检验计划变更场景下旧事实与旧摘要的失效维护效果，从而将结构设计与任务收益紧密结合。

9 总结

六篇论文从记忆的组织、访问、更新、利用与操作验证五个维度推进了长上下文结构化记忆建模。StructMem 通过事件绑定与跨事件整合保留语境关联，Hindsight 区分四类记忆角色并组织多路召回，Semantic XPath 依托树形层级收敛访问范围，HyMEM 结合多模态经验与两层更新适应交互变化，MetaMem 通过反思提炼事实利用规则，Text2Mem 则规范了记忆操作语法与后置状态核验。

综合各篇实验结果来看，引入结构化表示有助于加强跨轮证据整合与范围约束，但也会相应增加信息抽取、索引维护或离线优化开销。实际系统设计应结合任务的跨轮关联需求、反馈条件与计算预算进行取舍，并通过组件消融和开销统计评估各环节的实际贡献。

本组课程设计以 StructMem 在 LoCoMo 上的复现与分析为主线，同时吸收其余五篇工作的思路，从检索范围约束、时间与状态更新、证据推理利用等角度开展错误归因。通过结合来源记录、检索上下文与状态变化逐步定位瓶颈，可以在受控条件下清晰检验各类结构化机制的改进效果与资源代价。

References

[1] Xu B, Chen Y, Fang J, et al. StructMem: Structured memory for long-horizon behavior in LLMs. In: Liakata M, Moreira V P, Zhang J, et al., editors, Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers), San Diego, California, United States: Association for Computational Linguistics, 2026. 122–146

[2] Latimer C, Boschi N, Neeser A, et al. Hindsight: Structured agent memory that retains, recalls, and reflects. In: Durrett G, Jian P, editors, Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 3: System Demonstrations), San Diego, California, United States: Association for Computational Linguistics, 2026. 275–285

[3] Liu Y S, Wu R, Gallagher L, et al. Semantic XPath: Structured agentic memory access for conversational AI. In: Durrett G, Jian P, editors, Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 3: System Demonstrations), San Diego, California, United States: Association for Computational Linguistics, 2026. 286–296

[4] Zhu S, WU W, Zhou K, et al. Hybrid self-evolving structured memory for computer-use agents. In: Liakata M, Moreira V P, Zhang J, et al., editors, Findings of the Association for Computational Linguistics: ACL 2026, San Diego, California, United States: Association for Computational Linguistics, 2026. 11287–11304

[5] Xin H, Li X, Liu Z, et al. MetaMem: Evolving meta-memory for knowledge utilization through self-reflective symbolic optimization. In: Liakata M, Moreira V P, Zhang J, et al., editors, Findings of the Association for Computational Linguistics: ACL 2026, San Diego, California, United States: Association for Computational Linguistics, 2026. 5473–5492

[6] Wang L, Yang L, Chen B, et al. Text2Mem: A unified memory operation language for memory operating system. In: Liakata M, Moreira V P, Zhang J, et al., editors, Findings of the Association for Computational Linguistics: ACL 2026, San Diego, California, United States: Association for Computational Linguistics, 2026. 2105–2119

成员分工与贡献

六位成员均负责各自论文部分的报告与讲解，并参与系统性讨论。具体负责论文及贡献比例如下。

成员	主要分工	贡献比例
hycx233	StructMem 报告与讲解；共同部分整理与讲解、视频整合及讨论协调	25%
onlysonder	Hindsight 报告与讲解	15%
oioioi-521	Semantic XPath 报告与讲解	15%
lanshuheng9-oss	HyMEM 报告与讲解	15%
YaoYang-123456	MetaMem 报告与讲解	15%
ngocnamd93-spec	Text2Mem 报告与讲解	15%
合计		100%