长上下文场景结构化记忆建模：六篇论文阅读与比较

第 8 队（成员待填写）

(天津大学)

摘　要: 长期交互中的记忆需要保留人物、事件与时间关系，定位相关证据，并随新信息更新状态。本文围绕 StructMem、Hindsight、Semantic XPath、HyMEM、MetaMem 和 Text2Mem 六篇论文，梳理事件组织、多通道检索、结构化访问、混合经验更新、事实利用与操作验证六类机制。比较表明，各方法分别作用于记忆形成、访问、维护和使用过程，其适用性取决于任务类型、数据表示与反馈条件。结构化记忆有助于保留关联和限定访问范围，同时引入抽取、维护与计算开销。本文结合论文内部对照实验和行程变更示例，分析这些机制的联系与取舍，并提出围绕错误类型开展受控比较的思路，为以 StructMem 为主线的课程设计提供参考。

关键词: 大语言模型；长上下文；结构化记忆；论文综述
中图法分类号: TP18

Structured Memory for Long-Context Scenarios: A Review of Six Papers

Team 8

(Tianjin University)

1　背景与阅读范围

长期对话、持续任务和跨会话助手需要利用过去的信息。历史增长带来的困难包括计划变更、证据分散，以及用户陈述与系统推断的混淆。将完整历史交给模型会增加输入开销；将历史拆成独立片段后检索，则容易丢失人物、时间、事件归属及状态变更关系。记忆系统因此需要同时解决信息的组织、访问和使用问题。

结构化记忆通过明确组织单位、关系、访问范围或操作语义，为后续任务提供可定位、可维护的信息。其表示形式包括事件条目与整合摘要、带类型的记忆网络、层级树、离散策略与连续轨迹，以及事实利用规则和操作 Schema。不同表示对应不同的处理环节，选择时需要结合任务所需的关联、粒度和更新方式。

本文选取课程专题中的六篇论文：StructMem 与 Hindsight 研究长期对话记忆的组织和使用；Semantic XPath 研究层级记忆的访问；HyMEM 面向依赖截图与动作轨迹的电脑操作智能体；MetaMem 优化检索后对事实的利用；Text2Mem 定义记忆操作并评测执行后的状态效果。

下文依次介绍各方法的研究问题、核心机制、实验结果与局限，再从研究对象、机制联系、评价条件和共同案例四个方面展开比较，最后讨论这些工作对课程设计的启发。

2　StructMem：面向长程对话的结构化记忆

StructMem[1]研究长期对话中的记忆组织。它在事件内部保存事实与互动关系，并用来源时间将条目绑定；在事件之间检索历史、恢复事件语境，再生成整合记忆。细粒度条目与整合摘要共同参与问答。

2.1　研究问题与方法定位

2.1.1　长期对话中的关联信息

长程对话会持续产生事实、计划、态度和互动。例如，某人提到“去年参加过一个活动”，另一人在相邻话轮中回忆了与朋友共同参加的经历。回答“两人何时一起参加活动”需要把时间表达、共同参与关系和分散的事实放在一起。仅找到与活动名称相似的句子，未必能恢复这个联系。

这类问题同时涉及两个过程。第一，系统在写入记忆时决定保留什么信息。第二，系统在读取记忆时决定给回答模型什么上下文。写入阶段丢失的关系信息，很难单靠增加检索数量补回来。StructMem 因而把记忆单元的

设计作为主要切入点。

表 1 三种记忆组织方式

组织方式	保存的信息	主要优点	主要代价
平面记忆	独立自然语言条目及其向量	构建直接，语义检索方便	事件上下文容易分散
图记忆	实体、关系及图结构	关系显式，便于结构化访问	实体消歧、去重与关系维护增加成本
StructMem	带时间锚的事实与关系条目，加上跨事件摘要	保留细节，同时提供关联上下文	依赖抽取与整合提示的质量

2.1.2 结构从两个层次形成

事件级绑定解决 “同一段交流中的事实和关系怎样放在一起”。跨事件整合解决 “当前交流如何与更早的经历相联系”。最终的记忆包括两类可检索内容：一类保留细节，另一类提供跨事件的解释。



图 1 StructMem 的记忆构建与问答流程

从实现上看，StructMem 属于外部记忆框架。论文的核心流程由模型调用、向量检索和数据组织组成，没有引入基础语言模型的参数训练。它仍使用向量检索，结构主要体现在事件绑定与整合内容中。

2.2 事件级绑定：事实、关系与时间

2.2.1 双视角抽取

设第 i 条原话为 m_i，语言模型为 $\mathcal{L}$。事实提示 P_{fact} 和关系提示 P_{rel} 分别生成条目集合：

$$\Phi_i = \mathcal{L}(P_{\text{fact}} \| m_i), \qquad \Psi_i = \mathcal{L}(P_{\text{rel}} \| m_i). \tag{1}$$

其中，Φ_i 保存发生了什么、有什么计划或偏好；Ψ_i 保存人物如何回应、支持、评价或影响对方。“双视角” 对应事实内容与互动关系两个抽取目标。关系抽取关注赞扬、鼓励、感谢、兴趣、认同和回应等行为。

以研究生录取对话为例，Alice 分享自己被计算机科学项目录取的消息，Bob 祝贺她并询问研究方向。事实条目可记录录取项目与研究方向，关系条目可记录 Bob 对 Alice 的支持和兴趣。这些互动信息能帮助后续模型理解两人为何继续讨论相关计划。

表 2 事实、关系与来源信息

条目类型	条目内容
事实条目	Alice 被计算机科学研究生项目录取，研究方向为机器学习。
关系条目	Bob 祝贺 Alice，表达对她的信心，并询问她的研究方向。
来源信息	两类输出都携带 `source_id`，用于对应原话及其时间。

2.2.2 时间锚定与事件重建

条目 x 的表示包含自然语言文本、向量 $\mathbf{e}_x$ 和来源时间 τ_i：

$$\mathcal{M} = \bigcup_i \{\langle x, \mathbf{e}_x, \tau_i \rangle \mid x \in \Phi_i \cup \Psi_i\}. \tag{2}$$

来源时间将事实和关系绑定为一个事件单元。检索命中其中一个条目后，可以用同一时间戳找回其他条目，补全事件语境。

这里需要区分**提及时间**与**事件发生时间**。例如，2023 年 8 月 17 日的一条消息说“去年参加了活动”，时间锚记录这句话的来源日期，事件年份则由相对表达推到 2022 年。事实抽取提示要求保留相对时间与参考日期，问答提示再要求换算为具体时间。

2.2.3 批处理与来源追踪

抽取过程以原话 m_i 为基本单位，调用时可按话题批量处理，并按 `source_id` 顺序输出。事实与关系分别对应两个抽取目标。来源编号、人物和时间将生成条目连接到原始对话，便于事件重建与后续核查。

2.3 跨事件整合与双路问答

2.3.1 从当前缓存找到相关历史

系统先积累尚未整合的条目，并按来源时间排序。论文的整合触发阈值为**对话时间上的 1 小时**。设缓存上下文为 C_{buf}，其文本拼接后的向量为 q，系统按余弦相似度检索历史中的前 K 个种子条目，默认 $K = 15$。

对于每个种子 x^*，系统找回与其共享时间戳的全部条目：

$$E_\tau(x^*) = \{x' \in \mathcal{M} \mid \tau(x') = \tau(x^*)\}, \tag{3}$$

$$C_{\text{cross}} = C_{\text{buf}} \cup \bigcup_{x^* \in S_K} E_\tau(x^*). \tag{4}$$

这一步使语义检索结果扩展为完整事件上下文。一个与问题高度相似的事实条目，可能缺少周围的赞同、回应或计划信息。时间锚能把这些条目重新聚合起来。

2.3.2 生成有依据的整合记忆

整合模型接收当前事件和相关历史，生成跨事件摘要。提示要求保留具体人物、日期、地点和行动计划，按时间组织内容，并在有依据时表达事件之间的联系。跨时期的引用应带有具体时间，重点放在与当前话题直接相关的历史内容上。摘要长度为 200–350 个英文词。

生成的摘要形成额外的抽象层，与原有事件条目共同保存。细粒度条目负责具体事实，摘要提供跨事件联系。两类记忆共同组成存储：

$$\mathcal{M}_{\text{all}} = \mathcal{M}_{\text{entries}} \cup \mathcal{M}_{\text{syntheses}}.$$

2.3.3 回答阶段使用两路上下文

论文在问答阶段检索 **60 个条目与 5 条整合摘要**，把它们连同问题交给回答模型。提示要求核对人物、利用时间戳换算相对日期，并给出简短答案。

表 3 记忆整合与问答的默认配置

参数	默认设置	所处阶段
时间窗口	1 小时	触发记忆整合
历史种子数量 K	15	整合时检索历史，再扩展事件上下文
问答检索数量	60 + 5	回答时读取条目与整合摘要

2.4 案例分析：共同经历与相对时间

2.4.1 问题与证据

案例问题是：Caroline 和 Melanie 什么时候一起参加过 Pride festival？关键证据分散在不同条目中，同时出现了 2023 年的活动记录和对“去年”活动的回忆。

表 4 共同经历案例中的证据

证据	内容概述
事实 1	Caroline 在 2023 年 8 月 11 日参加了 Pride parade。
事实 2	Caroline 回忆自己在去年的 Pride fest 玩得很开心，该消息记录于 2023 年 8 月 17 日。
事实 3	Melanie 说自己和一群朋友在 Pride fest 度过了愉快时光，该消息同样记录于 2023 年 8 月 17 日。
互动关系	Melanie 对 Caroline 的相关经历表示兴趣，并积极回应她参与社区活动的事情。
整合记忆	在同一叙述中连接两人的回忆，形成她们对去年共同经历的讨论。

表 5 共同经历案例中的回答

方法	模型回答
Flat Memory	两人没有一起去过。
Graph Memory	上个月，2023 年 6 月。
StructMem	去年，2022 年 8 月。
参考答案	2022 年。

2.4.2 事件关联与时间推理

问题需要同时判断“共同参加”与“参加时间”。独立事实分别描述两人的经历，互动条目补充了彼此回应的语境。整合步骤把时间相近、语义相关的信息组织成连续叙述，回答模型据此识别共同经历，并将 2023 年消息中的“去年”换算为 2022 年。

事件绑定与整合使共同经历和相对时间出现在同一回答上下文中。参考答案为 2022 年，StructMem 给出的年份与之相符；更具体的月份仍需回溯原始对话确认。

整合记忆中的事件联系应与来源条目相连，便于回答时核对参与关系和具体日期。

2.5 实验设置与评价指标

2.5.1 数据与任务

论文使用 LoCoMo 的长对话问答任务。数据包括 10 段长期对话，平均每段 588 轮、16,618 tokens。实验采用四类问题，共 1,540 题。

表 6 LoCoMo 题型分布

问题类型	数量	主要考察内容
单跳 Single-hop	841	从相关记忆定位事实
多跳 Multi-hop	282	联合多条证据得到答案
时间 Temporal	321	时间顺序与相对日期推理
开放域 Open-domain	96	对话记忆与开放域知识相关的回答
合计	1,540	单跳题约占 54.6%

2.5.2 模型与基线

主实验统一使用 `gpt-4o-mini` 作为基础模型，以 `text-embedding-3-small` 生成向量。比较对象覆盖原始上下文输入、RAG、平面记忆与结构化记忆。

各方法的检索配置为：MiniRAG 和 LightRAG 各检索 20 条，A-Mem 和 LangMem 各检索 40 条；Mem0、Mem0g、Zep 和 Memobase 每位说话人检索 10 条。FullContext 使用完整历史的逆时间顺序表示，表中名为 OpenAI 的配置直接拼接对话文本。这里的 OpenAI 是一个基线配置名。

不同系统使用各自的检索设置，因此主表适合比较整套系统的效果与成本。分析事件绑定和整合组件时，同框架的范式对照和消融更直接。

2.5.3 准确率与构建效率

准确率使用 LLM-as-a-judge：评判模型接收问题、参考答案和生成答案，输出正确或错误。评判提示允许同义表达和等价日期表述。主结果使用 `gpt-4o-mini` 判断，并用另外两种模型复核。

效率指标统计**记忆构建阶段**的输入 / 输出 tokens、API 调用次数和运行时间。它们描述把历史对话变为记忆的成本。回答阶段的 tokens 预算和完整服务的响应延迟，还需要单独衡量。对没有构建过程的上下文基线，以及未公开构建细节的服务，主表以横线标注相关项。

2.6 准确率结果：总分与分项表现

表7列出各方法的问答准确率，加粗表示该列最高值。

表 7 LoCoMo 问答准确率（%）

方法	总分	单跳	多跳	时间	开放域
OpenAI	71.82	84.66	69.86	45.48	53.12
FullContext	73.83	**86.56**	68.79	50.16	56.25
MiniRAG	63.51	75.74	56.74	38.94	58.33
LightRAG	68.83	77.53	66.31	53.89	50.00
LangMem	58.10	71.12	62.23	23.43	47.92
A-Mem	64.16	72.06	56.03	60.44	31.25
Mem0	66.88	72.93	67.13	59.19	51.15
MemoryOS	58.25	67.06	56.74	40.19	45.83
Mem0g	68.44	75.71	65.71	58.13	47.19
Zep	75.14	79.79	**74.11**	67.71	**66.04**
Memobase	75.78	77.17	70.92	**85.05**	46.88
StructMem	**76.82**	81.09	68.77	81.62	46.88

2.6.1 主要结果

StructMem 的总分为 76.82%，比 Memobase 高 1.04 个百分点，比 Zep 高 1.68 个百分点，比 FullContext 高 2.99 个百分点。

分项表现更有解释力。相对 FullContext，StructMem 的时间推理提高 31.46 个百分点，而单跳下降 5.47 个百分点，多跳基本持平。相对 Zep，StructMem 时间推理更好，但多跳与开放域更低。Memobase 则仍保持最高的时间推理成绩。由此可见，StructMem 的收益与问题类型有关。

2.6.2 题型差异

全文上下文保留了大量原始细节，有利于单跳事实定位。事件结构和整合摘要帮助模型建立时间线，所以 StructMem 相对全文上下文的时间推理优势很突出。它在多跳任务上的机制收益，还要结合下一节的消融结果判断。

单跳题约占 54.6%，对总分影响较大。分项结果显示，StructMem 的优势集中在时间推理，单跳、多跳和开放域仍有提升空间。

部分基线的汇总口径存在差异：按题型数量加权，Mem0 与 Zep 的分类分数约为 67.646% 和 75.375%，而论文报告的总分为 66.88% 和 75.14%。对应行需结合有效样本和逐题结果核对。

2.7 效率结果：构建成本与运行时间

2.7.1 主表中的资源消耗

表8统计记忆构建的资源消耗，tokens 单位为百万（M），时间单位为秒。MemoryOS 的总量沿用论文报告值 2.868M；其输入与输出之和为 2.828M，存在汇总差异。相对 Mem0g，StructMem 的构建 tokens 减少约 94.6%，API

表 8 记忆构建的资源消耗

方法	输入 tokens	输出 tokens	总 tokens	调用次数	时间
MiniRAG	9.022	1.081	10.103	2,508	2,566
LightRAG	10.014	1.916	11.931	13,576	60,469
LangMem	9.873	1.192	11.066	5,990	26,281
A-Mem	9.126	2.368	11.494	11,754	60,607
Mem0	10.958	1.239	12.196	9,181	30,057
MemoryOS	1.889	0.939	2.868	5,534	24,220
Mem0g	33.512	2.313	35.825	53,514	115,670
StructMem	**1.501**	**0.436**	**1.937**	**1,056**	22,854

调用减少约 98.0%，运行时间减少约 80.2%。相对 Mem0，构建 tokens 减少约 84.1%。

运行时间具有不同的排序：MiniRAG 只用 2,566 秒，明显短于 StructMem 的 22,854 秒。tokens 数量、调用次数和耗时之间还受到模型调用方式、批处理、服务延迟与并发等因素影响。论文没有提供足够的信息，把全部耗时差异归因于其中某一因素。

2.7.2 同一框架下的组织代价

同框架的范式比较在 LoCoMo 第一段对话上拆分构建 tokens：平面记忆约 77.6k，StructMem 约 226.1k，图记忆约 402.3k。StructMem 的 226.1k 中，条目抽取约 151.0k，整合约 75.1k。

双视角抽取与整合增加了相对平面记忆的构建成本；相对图记忆，批量整合减少了实体、关系抽取及去重的多阶段开销。StructMem 把一部分原本留到问答时完成的关系推理，提前放进周期性的记忆构建。它用额外的组织成本换取更好的上下文，再通过批处理控制这部分成本。

2.8 消融与参数分析

2.8.1 事件绑定与跨事件整合的贡献

表 9 记忆组织消融：准确率（%）及百分点变化

配置	单跳	多跳	时间	开放域
Flat Memory	78.83	66.31	78.50	46.88
Graph Memory	80.50	66.67	76.64	48.96
去掉跨事件整合	80.86	66.31	79.44	46.88
StructMem	81.09	68.77	81.62	46.88
加入跨事件整合的变化	+0.23	+2.46	+2.18	0.00

保留事件绑定、去掉跨事件整合后，单跳与时间任务仍高于 Flat Memory。进一步加入整合，多跳提高 2.46 个百分点，时间提高 2.18 个百分点，单跳只增加 0.23 个百分点。这与方法设计相符：跨事件摘要主要帮助联合分散信息。去掉与加入整合的两种配置中，开放域分数均为 46.88%。

2.8.2 历史种子数量与效果

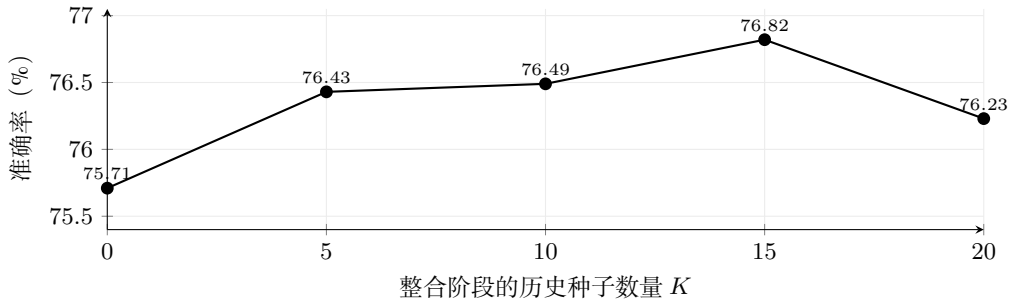


图 2 历史种子数量对问答准确率的影响（纵轴范围 75.4–77.05）

$K = 0$ 时仍整合当前缓存，只是不引入历史事件。$K = 15$ 达到图中最高的 76.82%，$K = 20$ 则回落到 76.23%。这表明更多历史上下文不一定继续改善效果，选择范围需要控制。

在检索规模分析中，平面检索从 10 条增加到 60 条，准确率由 70.91% 提高到 75.78%；继续增加到 100 条时为 75.71%，相关 tokens 量则从 3.65M 增到 5.62M。该结果支持适度增加检索覆盖率，也说明覆盖率之外仍存在信息组织问题。

2.9 生成记忆的忠实性与评判稳定性

2.9.1 抽取和整合分别接受检验

新的记忆由语言模型生成，因此需要检查生成内容是否有原始证据。忠实性评测分成两步：先检查单个条目是否忠于原话，再检查跨事件摘要是否引入了错误联系。

在事件抽取阶段，三个评判模型报告的幻觉率分别为 2.63%（GPT）、1.61%（Qwen）和 2.84%（DeepSeek），原文汇总的平均值为 2.36%。这描述的是抽取条目的忠实性，与问答错误率是不同指标。

在整合阶段，评判模型比较“只整合当前缓存”与“加入 15 个历史种子”的摘要，识别新增历史联系。作者进一步删除提示中的具体时间引用与具体联系要求，得到无约束版本。这组实验支持具体时间与来源关联约束的作用。不同评判模型识别出的联系数量不同，因此表中保留各自的分子和分母，分别比较约束前后变化。

表 10 来源约束对错误关联的影响

评判模型	有约束的错误联系	无约束的错误联系	错误率变化
GPT	6/982（0.61%）	72/966（7.45%）	+6.84 个百分点
Qwen	33/968（3.41%）	213/1065（20.00%）	+16.59 个百分点
DeepSeek	13/358（3.63%）	104/687（15.14%）	+11.51 个百分点

2.9.2 更换问答评判模型后的排名

三个评判模型下，StructMem 的总分都略高于 Memobase。作者报告 Fleiss' $\kappa = 0.8341$，表明这些模型的判断具有较高一致性。与此同时，DeepSeek 评判下的分差只有 0.06 个百分点。排名相近的系统还需要逐题分析和重复实验来理解差异来源。

表 11 不同评判模型下的准确率（%）

评判模型	StructMem	Memobase	分差（百分点）
gpt-4o-mini	76.82	75.78	+1.04
Qwen2.5-32B-Instruct	77.01	76.36	+0.65
DeepSeek-V3.2	79.35	79.29	+0.06

2.10 方法局限与课设启发

2.10.1 关系保存与多粒度记忆

StructMem 将关系信息的保存提前到记忆形成阶段。人物的支持、回应和共同回忆经常出现在话语互动中；保留这些关系有助于重建事件语境，再通过整合连接相关历史。

原子条目和整合摘要提供了互补粒度：条目保存具体细节，摘要组织分散信息。两种粒度共同检索，兼顾事实定位与跨事件理解，也提供了清晰的消融维度。

2.10.2 更新、追溯与泛化

旧记忆如何修订。作者在局限部分指出，当前框架缺少显式的冲突消解与记忆更新机制。用户更改计划或偏好后，旧摘要可能继续被检索。问答提示中的“优先最近记忆”提供了回答规则，存储层仍需要版本、失效标记或重新整合机制。

摘要联系如何追溯。时间锚和提示约束降低了无依据联系，但摘要中的每项关联若能对应到具体来源条目，检查和更新会更加直接。尤其当某条历史事实失效时，系统应能找到受它影响的摘要。

收益能否迁移。论文主要在 LoCoMo 上测试，基础模型固定为 gpt-4o-mini。更多任务类型、不同模型和更长历史能够帮助判断方法适用范围。现有消融尚未逐项拆开“关系抽取”“时间锚定”“摘要检索”的贡献，后续可以在固定预算下继续比较。

2.10.3 适合课设的小规模验证

以同一基础模型和同一份数据，比较事实记忆、事件记忆、事件记忆加跨事件整合三种配置。先固定检索预算，再分别去掉关系条目、时间信息和整合摘要。记录四类准确率、构建与问答 tokens、调用次数，并保留失败题的检索上下文。

还可加入计划变更对话，观察旧事实和旧摘要的影响，并比较来源追踪与摘要失效策略。

2.11 小结

StructMem 通过事件内绑定保留人物互动与事实语境，通过跨事件整合建立时间联系。主结果、组件消融和忠实性检查分别展示了整体表现、整合模块的作用与生成关联的可靠性。

该方法适合分析时间关系和跨事件证据组织。进一步研究可聚焦关系抽取、时间锚和摘要检索的独立贡献，以及计划变更后旧条目与摘要的一致性维护。

3 Hindsight：保留、召回与反思的结构化智能体记忆

Hindsight[2]面向跨多轮对话和多个会话保持记忆的智能体。它把记忆组织为四类网络，并用 retain、recall、reflect 三种操作分别处理信息写入、证据检索和基于记忆的回答。

3.1 研究问题与四类记忆

作者将现有对话记忆的困难概括为三个相连的问题：长历史中怎样保留有用信息，查询时怎样跨会话找回相关信息，以及怎样在回答时避免只凭局部线索而产生全局不一致。单纯把片段放进向量库并取回 top-k，还可能混淆用户说过的事实与智能体形成的判断，也难以表达时间和实体之间的联系。

Hindsight 在每个 memory bank 中维护四类逻辑网络：World 与 Experience 记录事实或经历，Observation 汇总

表 12 Hindsight 的四类记忆

网络	保存内容	例子或作用
World	关于外部环境的客观事实	Alice 在 Google 的 Mountain View 团队工作。
Experience	智能体自身采取过的行动	智能体曾向 Alice 推荐徒步旅行。
Observation	根据多条事实整合出的实体摘要	Alice 是专长于机器学习的软件工程师。
Opinion	带置信度、可随证据变化的主观判断	“Python 适合数据科学”，并记录置信度。

实体证据，Opinion 保存主观判断。这些类型区分了事实、概括与观点，便于检查和更新。记忆单元带有事件发生时间区间和系统获知时间，并通过时间、语义、实体和因果关系连接成图。

3.2 三种操作：写入、检索与生成

Retain 接收对话或文档，由模型抽取较粗粒度的叙事事实，再进行分类、实体识别与消歧、时间标注和关系建图。作者称每段对话通常抽取 2–5 条事实，以减少记忆切分方式对后续检索的影响。这里记录的时间至少要区分事件发生时间与智能体提及或获知该信息的时间。

Recall 接收查询和 token 预算，返回预算内排序后的记忆。它并行使用四类检索：HNSW 向量相似度、BM25 关键词匹配、沿实体 / 时间 / 因果连接进行图遍历，以及按事件时间范围过滤。不同通道的排序由 Reciprocal Rank Fusion 合并，再由 cross-encoder 重排。图遍历通常限制在 2–3 跳；时间解析先处理常见表达，规则无法处理时再调用轻量 T5 模型。token 预算让调用者限定送入回答模型的上下文规模。

Reflect 将查询、取回的记忆和可配置的行为档案交给生成流程。行为档案由怀疑程度、字面倾向和共情程度三个 1–5 的参数组成。Opinion 与事实分开存储，置信度在 $[0, 1]$ 范围内；新证据支持某个判断时提高置信度，形成反证时降低置信度。后台整合还会保存支持性引文、证据数量和从 new 到 stale 的新鲜度趋势，使判断可以回溯到证据。

论文把 retain 和 recall 放在 TEMPR（Temporal Entity Memory Priming Retrieval）组件中，把 reflect 放在 CARA（Coherent Adaptive Reasoning Agents）组件中。端到端流程可概括为 “对话进入四类记忆网络—多通道召回—依据证据生成并更新意见”。作者使用 PostgreSQL、pgvector 与全文检索索引作为存储基础，并报告：包含 10,000 条记忆的 bank，其 recall 检索延迟低于 200 ms，但该数字不包含回答模型的推理时间。

3.3 实验设置与结果

论文在 LongMemEval 与 LoCoMo 上评估长期对话记忆。LongMemEval 的 S 设置包含 500 道问题，对话最长约 150 万 tokens；LoCoMo 使用多会话对话，每段最多 35 个会话。表13列出不同模型配置下的回答准确率。

表 13 Hindsight 在两项基准上的回答准确率（%）

基准	Hindsight 20B	Hindsight 120B	Hindsight Gemini-3
LongMemEval	83.6	89.0	91.4
LoCoMo	83.2	85.7	89.6

在 LongMemEval 上，20B 模型配合 Hindsight 达到 83.6%，120B 模型为 89.0%，Gemini-3 为 91.4%；在 LoCoMo 上，相应结果为 83.2%、85.7% 和 89.6%。20B 配置在 LongMemEval 时间推理和多会话题上均为 79.7%，偏好题为 66.7%，反映出不同题型仍有差异。

作为参照，全文 GPT-4o 在 LongMemEval 上的分数为 60.2%，Supermemory-Gemini-3 为 85.2%；LoCoMo 中 Zep、Memobase 和 Backboard 分别为 75.1%、75.8% 和 90.0%。这些结果涉及不同基础模型和系统配置，适合描述各配置的表现；记忆机制的独立贡献则需在固定模型与预算下比较。

3.4 方法局限与课设启发

论文明确列出的局限包括：事实抽取、实体消歧和意见更新依赖语言模型，错误可能沿记忆图传播；评测只覆盖英文基准；Opinion 的主观质量和置信度校准还没有通过正式用户研究验证；时间解析可能漏掉含混或文化相关的表达。持续保存个人偏好与意见也带来隐私和偏见风险，论文指出系统没有内置 PII 检测或自动脱敏机制。

评测材料也有待完善：系统演示论文引用的完整评估条目仍带有 arXiv 编号占位符，且正文与附录中的部分 LongMemEval 分类基线数值不一致。复核组件效果时，需要补充完整实验配置和逐题结果。

Hindsight 对课程设计的启发集中在记忆类型和检索组织：分别保存事实、经历、实体摘要与观点，利用时间和实体关系补充向量检索，并通过 token 预算控制回答上下文。可在固定模型、数据和预算下逐项比较检索通道，记录准确率、无关条目比例、延迟与 token 开销。

4 Semantic XPath

Semantic XPath[3]研究结构化对话记忆的访问。它结合路径、位置条件和连续语义评分，从已有树形记忆中选择相关节点及子树，支持下游回答和状态更新。

4.1 研究问题与方法定位

长期任务导向对话需要反复查看、修改和回溯同一个任务对象。旅行计划中的一项活动不仅包含文本，还属于特定日期、行程与历史版本。全量上下文保留信息较多，但输入量随历史增长；扁平检索降低输入量，却可能取回语义相似而所属范围错误的条目。比如 “在会议安排最密集的一天增加咖啡休息”，需要比较各天的活动，而不仅是找一条包含会议内容的文本。

查询负责定位访问范围，插入、删除及版本维护由下游步骤完成。

4.2 树形数据模型与查询语法

记忆表示为有根树 $T = (V, E, r)$。非根节点只有一个父节点，节点具有类型和文本属性；模式 Σ 由记忆数据已有的节点类型、属性和父子关系决定，而非要求人工预先设计一个通用模式。旅行示例采用

$$\text{Itinerary} \rightarrow \text{Version} \rightarrow \text{Day} \rightarrow \text{POI},$$

分别表示计划、版本、日期和活动；层级主要是组成关系，不只是对下层文本做有损摘要。

查询是步骤序列，每一步写为 $S = A\,N\,[R]\,[P]$：路径与类型必需，位置选择器和语义条件可选。

表 14 Semantic XPath 查询步骤的组成

组成	示例写法	作用
路径 A	`/`、`//`	访问直接子节点或全部后代
类型 N	`Day`、`POI`、`*`	按节点类型筛选或匹配任意类型
位置 R	`[i]`、`[-i]`、`[i:j]`	按顺序、倒序或区间选取候选
语义 P	`[node~="workshop"]`	计算候选与语义条件的相关程度

例如，`//Day[3]/POI[node~="workshop"]` 先选第三个匹配日期，再对该日期下的活动评分。存在多个行程或版本时，查询需先限定目标范围。语义条件 $1 - P$ 对原条件评分取反，提高低分候选的优先级。

4.3 语义评分与带权执行

语义相关度定义为 $\text{Rel}(u, P) \in [0, 1]$。局部评分依据一个属性或完整节点表示；聚合评分先在当前节点下执行内部结构查询，再用平均、最小、最大或几何平均聚合证据；多个条件还可用乘积、平均及取反组合。

```
//Day[avg(/POI[node~="conference"])]
```

这个查询根据活动证据评价日期。示例中第二天的三个活动分数为 0.603、0.482、0.608，平均约 0.565，在候选日期中得分最高。该值衡量活动与会议主题的平均相关度。

执行器从根节点及权重 1 出发，维护带权集合 $W \subseteq V \times [0,1]$，按步骤进行路径扩展、类型筛选、位置选择与语义评价。语义步骤更新为

$$w_{\text{new}} = w_{\text{old}} \operatorname{Rel}(u, P). \tag{5}$$

聚合条件递归访问下层证据。阈值、返回数量和空集处理由具体任务设置，查询质量则可从目标范围、节点选择和证据完整性三个方面检查。

4.4 范围约束示例

以行程调整为例，假设当前版本的第 2 天安排海滨公园，第 5 天安排山地徒步，第 7 天安排植物园和海港游船。用户要求找出“第 7 天下雨时需要调整的户外活动”。纯语义排序可能混入其他日期的活动；结构化访问先限定第 7 天，再评价活动语义，目标为植物园与游船。

简单日期约束也可由带元数据过滤的扁平 RAG 完成。比较查询机制时，可将其作为基线，进一步考察嵌套范围、下层证据聚合等结构访问需求。

4.5 实验设置与指标口径

作者评估旅行行程、待办清单和家庭配餐三个自建场景，每场景 20 个单轮对话、5 个多轮对话；另在 LoCoMo 中使用原生的 Memory–Conversation–Session–Turn 层级。回答模型为 GPT-5 mini 与 Gemini 3 Flash。相似度评分器（Sem）和 Flat RAG 使用 Qwen3-Embedding-8B；蕴含评分器（Entail）使用 `facebook/bart-large-mnli`。

自建场景使用任务通过率，要求检索到正确结构化数据且输出满足任务约束；LoCoMo 使用模型裁判评定的回答得分。LoCoMo 的平均输入 tokens 包含 XPath 查询生成输入，自建场景则报告平均 token 用量。成本比较还需计入嵌入、蕴含评分和查询执行，并在同一模型内对齐分词与统计口径。

表 15 三个自建场景的平均单轮结果

回答模型	方法	通过率（%）	平均 tokens
GPT-5 mini	In-context	70.0	26 216
	Flat RAG	30.0	3 250
	XPath Sem	66.3	6 166
	XPath Entail	83.0	5 691
Gemini 3 Flash	In-context	79.0	25 387
	Flat RAG	37.7	3 361
	XPath Sem	64.3	6 043
	XPath Entail	70.7	5 830

单轮 GPT-5 mini 配置中，Entail 相对 Flat RAG 提高 53.0 个百分点，相对增幅约 176.7%；token 用量约为全量上下文的 21.7%。Gemini 配置中，全量上下文的 79.0% 高于 Entail 的 70.7%，评分机制的收益随模型变化。

表 16 三个自建场景的平均多轮结果

回答模型	方法	通过率（%）	平均 tokens
GPT-5 mini	In-context	80.0	69 097
	Flat RAG	26.7	3 327
	XPath Sem	70.0	6 294
	XPath Entail	83.3	5 850
Gemini 3 Flash	In-context	56.7	76 603
	Flat RAG	26.7	3 240
	XPath Sem	76.7	6 092
	XPath Entail	80.0	5 993

多轮 Entail 在两种模型下取得最高平均通过率，token 用量约为全量上下文的 8.5% 与 7.8%。Sem 与 Entail 的差异说明评分器选择会影响任务效果。单轮与多轮实验使用不同请求，分别反映两类任务设置。

表 17 LoCoMo 结果（XPath 输入含查询生成）

回答模型	方法	回答得分	平均输入 tokens
GPT-5 mini	In-context	74.55	24 857
	Flat RAG	35.71	1 341
	Semantic XPath	65.19	3 032
Gemini 3 Flash	In-context	87.01	27 499
	Flat RAG	41.49	1 996
	Semantic XPath	73.25	3 870

LoCoMo 上 XPath 的总体得分处于两种基线之间，输入分别约为全量上下文的 12.2% 与 14.1%。这说明已有会话层级可用于访问，但准确性仍有损失。例如 GPT-5 mini 多跳题得分为 43.26，低于全量上下文 58.87，证据整合仍有差距。作者的失败分析将错误分为查询生成、检索和回答生成，认为检索是主要剩余来源，包括无命中、证据不全及选错节点或发言。

4.6 方法局限与课设启发

结构范围与连续语义评分支持不同粒度的访问，路径与评分轨迹便于解释结果。方法依赖可靠层级，跨树关系、模糊版本和复杂多跳仍有困难。现有评测规模较小，重复实验、置信区间及本地评分开销也有待补充。

StructMem 侧重写入时保存事件关联，Semantic XPath 侧重读取时限定范围。课程设计可明确日期与版本约束，保留节点及来源标识，分别检查范围、证据完整性和回答错误，并以元数据过滤基线评估层级访问的贡献。

5 HyMEM：电脑操作智能体的混合自演化记忆

HyMEM[4]面向需要观察截图并连续操作网页的电脑操作智能体。历史经验既包含可复用策略，也包含界面与动作细节；任务推进后，最初检索的经验可能失效。系统因此结合离散策略与连续轨迹表示，分别更新长期记忆和当前任务的工作记忆。

5.1 问题背景与混合表示

输入包括任务描述、当前截图及历史成功操作轨迹，输出为下一步可执行操作。例如，搜索商品和结账所需经验不同，但可能需要保留同一预算约束。纯文本总结容易丢失视觉细节，单纯连续表示则缺少清晰的策略组织和可解释索引；一次性检索也难以覆盖交互阶段变化。这些问题构成混合表示与两种更新机制的动机。

论文在图 $G = (V, E)$ 中组织经验，将一条轨迹的逻辑表示写为

$$v_i = (c_i, A_i, m_i), \tag{6}$$

其中 c_i 为高层策略，A_i 为动作、界面元素或领域标签等属性集合，m_i 为连续轨迹表示。共享相同属性的轨迹间建立无向边，并通过策略、属性与轨迹的关联支持跨经验检索。策略与属性提供语义锚点；借鉴 CoMEM 的连续编码保留难以用文本概括的视觉及动作细节，每条轨迹压缩为 8 个嵌入向量并接入智能体输入。

检索使用独立的索引向量：归一化的任务文本 CLIP 表示与起始截图 CLIP 表示拼接后，通过 FAISS 寻找相似经验。连续记忆 m_i 则负责向智能体提供检索到的轨迹细节。

5.2 全局记忆演化与结构化检索

更新长期图时，新轨迹先检索相关经验，再由视觉语言模型判断信息增量。检索提供候选集合，模型进一步判断经验是否重复。三种更新为：

- **ADD**：出现新策略或属性，增加对应节点与连接。
- **MERGE**：已有策略获得互补证据，如界面变体或另一条操作路径，将证据并入相应策略及属性关联。
- **REPLACE**：在同等条件下，新轨迹以更少步骤、更高成功率或更低风险实现相同策略，用其替换过时证据并刷新关联。

这些操作在长期图中积累可迁移经验并减少冗余。更新效果取决于模型对信息增量和轨迹质量的判断。

推理时，系统依据任务和截图寻找相似种子，再沿图扩展邻居并按相似度排序。主实验每次使用 10 条轨迹，包括 5 条语义相似种子和从其 1 跳邻居中选出的 5 条轨迹。一般算法允许进一步扩展邻居。

5.3 混合工作记忆及局部刷新

检索后形成两个互补视图：策略与属性归纳为指导指令（Guidance Instructions），作为文本写入系统提示；轨迹连续嵌入则与模型输入连接。前者帮助规划，后者提供细粒度视觉和动作信息，二者构成当前任务的工作记忆。

每个动作后，视觉语言模型比较前后观测与当前指导，判断是否发生阶段转换。若任务由搜索转入结账，先保留长期目标和约束，丢弃不相关内容，再按新状态检索，合并指导并刷新连续嵌入。这是**任务内部的上下文更新**，与长期图的 ADD/MERGE/REPLACE 属于不同层次。

5.4 实验设置与结果

实验覆盖 WebVoyager、Multimodal-Mind2Web 和 MMInA 三个多模态网页智能体基准。前两者根据任务描述与截图轨迹进行模型判分；MMInA 比较最终回答和标准答案。主指标是任务成功率，Overall 按可用领域取平均。各方法在统一环境、抽样和评价方式下实现。

记忆来源为 GUIAct、Mind2Web 训练集及作者智能体生成的成功轨迹，共 2883 条；主实验图含 1858 个节点和超过 100 万条边。执行采用 ReAct 式接口，包含 SOM 界面标记及 UI-INS-7B 定位回退。训练更新记忆编码器的 Q-Former 和 LoRA 层，可训练参数约占总参数的 1.2%，通常训练 1 个 epoch。系统效果因此同时依赖记忆数据、编码器训练和界面定位能力。

Qwen2.5-VL-7B 由 12.5% 升至 35.0%，提高 22.5 个百分点，混合记忆高于单独的离散或连续记忆。不同模型和领域的收益有差异：Qwen3-VL-8B 离散记忆的 21.3% 略低于无记忆的 21.9%，部分领域采用 HyMEM 后也未改善。

在 Amazon 与 Google Maps 的更新分析中，全局演化使成功率分别由 48.8% 升至 61.0%、43.9% 升至 51.2%；局部刷新分别达到 56.1% 和 48.8%。两项分析各自使用静态记忆作为参照，展示跨任务更新和任务内刷新的作用。

表 18 不同记忆表示下的 Overall 任务成功率（%）

基础模型	无记忆	离散记忆	连续记忆	HyMEM
Qwen2.5-VL-7B	12.5	17.0	21.7	35.0
Qwen3-VL-8B	21.9	21.3	23.3	33.8
UI-TARS-1.5-7B	17.1	15.4	28.7	31.2

5.5 方法局限与课设启发

HyMEM 结合可解释策略与连续视觉细节，并通过长期图更新和任务内刷新适应状态变化。其开销包括记忆构建、编码器训练、图扩展和执行期间的模型判断。图关联与更新依赖标签质量及模型判断，错误记忆传播、阶段误判和跨网站迁移是进一步评测的重点。

对文本事件记忆而言，可借鉴 HyMEM 对语义种子与结构邻居、长期更新与工作记忆刷新的区分。课程设计可在固定检索预算下比较邻居扩展带来的证据覆盖、无关信息和调用成本；连续轨迹编码则适用于具有截图和动作序列的多模态任务。

6 MetaMem：由事实存储转向事实利用

MetaMem[5]研究检索后的事实利用：模型即使找到相关记忆，仍可能误解时间、数量或从属关系。该方法将可复用的知识使用经验保存为元记忆，并通过答案反馈迭代优化。

6.1 研究问题与两种记忆

长期对话包含时间、人物、地点、数量及其从属关系。例如，一次旅行总里程为 1200 英里，其中第一天的 300 英里已包含在总数中；若另三次旅行合计 1800 英里，四次旅行应为 3000 英里，而非 3300 英里。错误不仅可能来自遗漏证据，也可能来自取回后对“整体与部分”关系的误判。

论文区分事实记忆 M 与元记忆 E：前者保存具体经历与知识，后者保存**可迁移的知识使用经验**，例如在计数前检查是否重复包含。设问题为 q，主方法可抽象为

$$\hat{y} = \mathrm{LLM}\big(\mathrm{Prompt}(q, M, E)\big). \tag{7}$$

普通记忆问答主要提供 (q, M)，MetaMem 进一步将 E 写入提示词。优化对象是自然语言规则，基础语言模型的权重保持不变。

6.2 从反馈到规则的自反思优化

方法包含规则学习与冻结后的问答两个阶段。训练时，给定带标准答案的样本 (q, a, M)，模型在当前元记忆下多次生成回答，再利用标准答案评价。反思模块归纳成功与失败原因，提出规则的添加、删除或修改，并合并批内重复与冲突的提案。验证集用于选择规则版本，测试时使用固定规则和独立问题。

训练数据与候选回答 $\longrightarrow$ 正误反馈与反思 $\longrightarrow$ 规则编辑与合并 $\longrightarrow$ 冻结后的元记忆 E $\longrightarrow$ 新问题的事实利用

规则学习的主要成本来自多次回答采样、反馈、反思与编辑；冻结后的问答阶段读取事实记忆和规则。

6.3 实验设置与结果

主要数据集 LongMemEval 包含 500 道问题，采用五折划分，每折 350 题训练、50 题验证、100 题测试。生成模型为 Qwen3-30B-A3B-Instruct 与 Llama3.1-70B-Instruct，事实记忆基座主要为 LightMem，默认评价模型为 Qwen3-235B-A22B。规则学习默认运行 5 个 epoch，每批 50 题，每题采样 5 次。

两种生成模型的平均准确率分别提高 4.40 和 2.91 个百分点。Qwen 配置下，完整方法为 71.90%，去除反思后为 70.02%，去除规则演化后为 68.33%，说明两个环节均有贡献。

表 19 LongMemEval 平均准确率（%）

生成模型	LightMem	MetaMem	增量（百分点）
Qwen3-30B-A3B-Instruct	67.50	71.90	+4.40
Llama3.1-70B-Instruct	66.17	69.08	+2.91

6.4 方法局限与课设启发

元记忆将事实召回与事实利用分开处理。自然语言规则便于检查、合并与迁移，可用于分析时间推理、计数和跨事件引用中的重复错误。

规则学习依赖带答案样本与评价模型，错误评判可能污染更新；多次采样和编辑增加优化成本。规则过度泛化、彼此冲突或积累过长也会影响回答。方法发挥作用的前提是关键事实已进入上下文，其在小模型、小样本和其他任务上的适用性仍需检验。

StructMem 侧重事实与关系的组织，MetaMem 侧重检索结果的使用。课程设计可据此将失败题分为证据缺失与证据利用错误，并在固定证据的条件下检查重复计数、时间误读等问题。这样的诊断有助于判断下一步应调整检索还是回答策略。

7 Text2Mem：记忆操作的统一表达与状态验证

Text2Mem[6]面向自然语言驱动的记忆控制，提出统一操作语言及其基准。用户要求更新、合并或调整记忆时，系统通过结构化规范表达目标范围与参数，并检查执行后的状态是否符合预期。

7.1 研究问题与适用范围

长期交互不仅需要检索历史信息，还需要控制记忆的优先级、有效期、合并和删除。例如，“暂时不要再提午餐”可能意味着降低显著性，也可能被误解为删除记录。如果动作、范围与时间未被明确表达，系统即使调用成功，也可能改变错误的记忆。论文因此在自然语言与具体后端之间引入结构化操作规范。

中间规范用记忆生命周期操作表达意图，再由后端实现其语义，为不同后端提供共同的操作接口。论文主实验采用 SQL/SQLite 参考环境。

7.2 操作集合、Schema 与执行流程

十二个操作。论文将操作分为编码、存储和检索三阶段。编码阶段仅有 Encode；存储阶段包括 Update、Label、Promote、Demote、Merge、Split、Delete、Lock、Expire 九个操作；检索阶段包含 Retrieve、Summarize。Encode 组织内容、语义、来源与治理属性，向量生成可以延迟。Promote 与 Demote 调整显著性，Demote 可以归档而不删除；Delete 处理软/硬删除，Expire 设置到期规则，三者具有不同语义。

五字段契约。操作由 `stage`、`op`、`target`、`args`、`meta` 描述，分别对应阶段、动作、目标、专属参数和执行上下文。不同操作的必填条件不同，例如 Encode 创建新记忆时不必先选择已有目标。对于需要定位已有条目的操作，`target` 在 `ids`、`filter`、`search`、`all` 四种选择方式中择一；跨字段约束限制锁定、到期和大范围写入等行为。

Validator–Parser–Adapter。Validator 检查结构完整性与跨字段约束；Parser 把合法实例转换为类型化操作，归一化时间和优先级等参数；Adapter 再映射为具体后端动作。执行返回 `ExecutionResult`，记录受影响条目和状态变化。多步骤请求可表示为保留依赖顺序的 `schema_list`。该流程检查结构和治理约束；目标选择与意图理解则由执行后的状态检查评估。

教学案例：提高课设进度记忆的优先级。以请求“提高本周课设进度笔记的重要性，其他记录不变”为例，设目标条目为 17，可用 STO 阶段的 Promote，将 `ids=[17]` 的 `weight` 设为 0.9。状态检查同时覆盖目标权重、原有内容和非目标条目，确认操作只改变了指定范围。

7.3 基准、指标与主要结果

基准以自然语言指令、前置操作建立的初态、参考 Schema 和 SQL 状态断言组成评测实例，覆盖中英文、直接与间接指令、单操作与工作流。模型包括 GPT-4o、Qwen2.5-72B-Instruct、Claude-4-Sonnet、Gemini-2.5-Pro 与 GPT-5，使用相同自然语言指令与提示模板。

评测包含三个指标：SMA 用编辑距离或余弦相似度衡量生成 Schema 与参考的相似程度；ESR 统计通过验证且无运行错误地执行的实例比例；EMR 统计满足的 SQL 状态断言占全部期望断言的比例：

$$\mathrm{EMR} = \frac{\sum_i \sum_{a \in A_i} \mathbf{1}[a\text{满足}]}{\sum_i |A_i|}. \tag{8}$$

其中 A_i 为第 i 个实例的断言集合。EMR 以断言为统计单位，断言较多的实例对总体指标影响更大。

表 20 Text2Mem 总体评测指标

模型	$\mathrm{SMA}_{\mathrm{lev}}$	$\mathrm{SMA}_{\mathrm{cos}}$	ESR	EMR
GPT-4o	0.6776	0.8690	0.9484	0.2532
Qwen2.5-72B-Instruct	0.6195	0.8349	0.9510	0.2535
Claude-4-Sonnet	0.6230	0.8475	0.9594	0.3132
Gemini-2.5-Pro	0.6491	0.8560	0.9479	0.2897
GPT-5	0.6115	0.8396	0.9662	0.2826

表20列出各模型的总体指标。ESR 约为 94.79%–96.62%，EMR 约为 25.32%–31.32%，显示操作普遍可以执行，但状态效果与预期仍有较大差距。最高 ESR 与最高 EMR 分别对应 GPT-5 和 Claude-4-Sonnet。

复杂存储和工作流的表现较弱。五个模型的 Split EMR 均为 0；Merge 仅 GPT-4o 为 0.0465，其余为 0。GPT-5 的单操作 EMR 为 0.2930，工作流 EMR 为 0.1190，而工作流 ESR 为 1.0000。这表明多步骤操作中的状态正确性是该基准的主要难点。

现有实验主要比较模型、操作类型和任务分组。Validator、Parser 与 Adapter 的独立作用，以及指令复杂度对结果的影响，还需要组件消融和受控实验分析。

7.4 方法局限与课设启发

统一规范将动作、范围和生命周期参数显式化，便于执行前检查与执行后追踪。将结构相似、执行状态和实际效果分别计量，有助于定位目标选择、操作规划和后端执行中的问题。

方法的局限包括复杂记忆语义缺少形式保证、真实后端覆盖有限，以及尚未评测端到端长期智能体表现。状态断言的覆盖也会影响 EMR：只检查目标权重，可能遗漏非目标条目被误改的情况。实际应用需要同时考虑后端适配、长期效果和错误传播。

StructMem 关注事件绑定、整合与问答检索，Text2Mem 关注操作表达和状态核验。与 Semantic XPath 的目标定位、MetaMem 的事实利用结合比较，可以将记忆系统的错误依次定位到访问、推理和执行环节。

课程设计可借鉴显式输入约束与效果检查相结合的做法。若开展记忆更新实验，可固定初态、请求和模型，分别记录格式合法性、执行成功率、断言满足率与整任务通过率，并检查非目标记录是否保持完整。

8 跨论文比较与讨论

六篇论文共同研究如何将持续增长的历史转化为可维护、可访问和可使用的记忆。它们分别改变信息组织、访问范围、更新方式、事实利用或操作执行。本节从这些作用位置出发，比较机制之间的联系、实验条件及其对课程设计的启发。

8.1 研究对象与核心机制

表21概括六项工作的研究对象、核心机制与适用条件。

表 21 六篇论文的研究定位与适用条件

工作	研究对象与表示	主要着力点	适用条件
StructMem	长对话中的事件条目与跨事件整合记忆	保留事件内绑定，连接跨事件信息	需保留来源时间，并区分整合与问答两阶段的检索配置
Hindsight	外部事实、自身经历、实体摘要与意见网络	写入、多通道召回和基于证据的反思	实体与时间处理依赖抽取质量；端到端分数包含多环节因素
Semantic XPath	树状记忆及其子树与节点	将结构范围约束与语义匹配结合	依赖可用的层级结构及正确的查询生成
HyMEM	电脑操作中的离散经验和连续多模态表示	混合表示、经验更新和工作记忆刷新	网页交互、视觉输入与训练条件不同于纯文本问答
MetaMem	事实之外的知识利用经验	通过反馈反思优化可复用的符号经验	规则学习需要答案反馈，测试阶段使用冻结规则
Text2Mem	记忆操作的结构化语言与执行状态	明确操作语义，验证规划和执行	以 SQL/SQLite 为参考后端，通过操作及状态变化评测

8.2 机制之间的联系

组织结构与访问范围。StructMem 通过事件绑定与整合保存关联，Semantic XPath 通过层级约束定位证据。二者分别对应写入时丢失关系和读取时选错范围。若将这两类机制结合，需要先定义事件与树节点的映射、保留来源标识，并统计查询生成和执行的开销。

取回证据与使用证据。Hindsight 的 recall 与 reflect 分别处理检索和基于记忆的回答，MetaMem 进一步学习可复用的事实利用规则。回答失败可分为证据缺失和证据利用错误：前者要求改进检索，后者涉及重复计数、时间误读或不当整合。固定证据后检查回答，有助于区分两类问题。

更新策略与操作语义。HyMEM 决定何时合并、替换和刷新经验，Text2Mem 明确操作的目标、参数和预期状态。二者分别关注更新决策与执行效果。应用到同一系统时，需要为具体记忆表示定义操作接口和状态检查，尤其要处理连续轨迹表示与结构化记录之间的差异。

事实、观点与利用经验。Hindsight 区分事实、经历、实体摘要与观点，MetaMem 将知识利用经验单独保存。明确条目角色有助于决定其使用和更新方式：事实记录事件，观点随支持证据变化，利用规则则指导推理。不同条目应保留各自的来源与有效条件。

8.3 结构化记忆的收益与代价

关联完整性与抽取误差。事件、实体关系和层级有助于保留上下文，抽取中的实体合并错误、时间绑定错误和摘要遗漏也会进入后续处理。评测应同时检查来源对应关系与关键事实的完整性。

检索覆盖与上下文开销。多路召回、事件补齐和结构扩展能够增加证据覆盖，也会引入冗余和无关信息。在相同回答上下文预算下比较证据覆盖、回答质量和成本，可以区分结构组织与输入规模的影响。

动态适应与错误固化。整合记忆、观点更新和反思规则能够适应新任务，也可能保留错误概括或过拟合开发样本。更新过程应记录所依赖的证据与反馈；离线规则学习使用训练答案，独立测试则使用冻结规则。

表达能力与验证范围。操作 Schema 使格式、目标和参数可检查，语义正确性仍需通过状态结果验证。复杂表示还会增加构建和维护成本，因此需要结合具体任务评估其收益，并分别检查访问、推理与执行过程。

8.4 实验条件与评价指标

六篇论文覆盖长期对话问答、结构化任务、网页操作和记忆指令执行，其指标分别衡量答案、任务完成或状态变化。即使同用 LoCoMo，模型、数据处理、题型范围、检索预算和评分提示也可能不同。比较机制效果时，应优先采用同一实验内的对照。

组件消融直接体现机制作用。StructMem 加入跨事件整合后，多跳准确率由 66.31% 升至 68.77%，开放域保持 46.88%，收益主要体现在部分题型。MetaMem 的 Qwen 配置中，完整方法、去掉反思、去掉规则演化分别为

表 22 任务、评价对象与比较条件

任务与代表工作	指标测量的对象	比较时需对齐的条件
长对话问答：StructMem、Hindsight、MetaMem	在各自数据、模型与评分条件下，答案是否正确	数据划分、回答模型、记忆预算与评判方式
结构访问：Semantic XPath	自建任务的约束通过率；LoCoMo 的回答得分	任务类型、token 统计范围与检索计算开销
网页操作：HyMEM	基于截图和动作轨迹的任务成功率	网页环境、轨迹来源、定位能力与训练设置
记忆操作：Text2Mem	结构相似性 SMA、执行成功率 ESR、断言满足比例 EMR	初始状态、操作范围、断言集合与统计单位

71.90%、70.02% 和 68.33%，显示两个优化环节均有贡献。

准确率与资源开销需要一起观察。Semantic XPath 的 GPT-5 mini 配置在 LoCoMo 上由全量上下文的 74.55 分降至 65.19 分，平均输入由 24,857 降至 3,032 tokens。Text2Mem 的 GPT-5 工作流 ESR 为 100%，EMR 为 11.90%，说明执行成功与状态满足仍有差距。ESR 以实例为单位，EMR 以断言为单位，应分别解释。

受控比较应记录六类条件：任务与数据划分、各模型的角色、训练或优化反馈、检索范围与预算、评价指标、主要成本。复现时，各组对照共用数据划分与评价方式，并记录与论文配置的差异。

成本可分为写入与整合、检索与回答、优化与评判三部分。构建成本按数据规模统计，查询成本按请求统计，规则学习还应计入多次采样与反馈。分开记录这些开销，才能判断收益适合一次性任务还是持续使用场景。

8.5 共同案例：行程变更中的范围、状态与证据

以行程变更为例，设用户连续留下三条记录：s_1（10 月 20 日）：“10 月 23 日去 A 地”；s_2（10 月 21 日）：“取消 A 地，改为 10 月 24 日去 B 地”；s_3（10 月 22 日）：“10 月 24 日先到 B 地，再去 C 地，仍按新计划”。问题是“当前计划哪天出行，经过哪些地点”。根据 s_2, s_3，当前路线为 “10 月 24 日，先 B 地后 C 地”。这一示例涉及来源时间与出行时间的区分、旧计划失效，以及同一行程内的路线合并。

表 23 行程变更示例中的机制分析

研究视角	对本例有帮助的检查	实现所需条件
StructMem	绑定同一条陈述的人物、时间、地点，联系 s_2, s_3	整合保留取消关系与来源，并标记旧计划失效
Hindsight	区分发生时间与获知时间，结合实体、时间和语义召回	正确解析事件与来源时间，将新计划作为事实变更处理
Semantic XPath	若已有行程 / 版本树，先限定同一行程及目标版本，再访问地点	建立行程树及版本归属，维护当前有效状态
MetaMem	用事实利用规则检查新旧陈述、取消关系及事件归属	检索上下文包含 s_2, s_3，规则明确事件与版本关系
Text2Mem	若用户要求调整该行程记忆，明确目标、动作与执行后断言	明确目标行程，并检查更新后的目标与非目标记录
HyMEM	提供长期经验与任务内工作记忆分开维护的分析思路	本例仅借鉴两层维护思路；连续记忆需要截图和动作轨迹

若用户接着说 “暂时不要再提这次行程”，系统需要确定具体意图：降低检索优先级、关闭主动提醒，还是删除记录。Text2Mem 中的 Demote、Delete 和 Expire 分别表达显著性调整、删除和到期处理。执行后应检查目标行程、变更字段、作用期限及无关记录；主动提醒还需由上层应用行为验证。

这一示例可将失败定位到四个位置：抽取时丢失取消信息，访问时找到旧版本，回答时混合新旧路线，执行时误改其他行程。来源记录、检索上下文与状态变化共同帮助判断应调整哪个环节。

8.6 课程设计与实验思路

课程设计以 LoCoMo 小子集上的 StructMem 方法复现为主，采用同一回答模型，比较原始对话 Flat RAG、去掉跨事件整合的事件记忆和完整 StructMem 三组配置。该任务与人物、时间和跨事件证据组织直接相关，事件记忆与整合记忆也具有可分离的接口，便于分析组件作用。

其余工作为错误分析提供参照：Hindsight 与 Semantic XPath 帮助检查实体、时间和范围约束；MetaMem 区分证据缺失与利用错误；HyMEM 区分长期经验更新与当前工作上下文刷新；Text2Mem 强调操作范围及状态效果。

局部实验应固定数据划分、回答模型和评分方式。检验跨事件整合时只改变整合模块，检验范围约束时保持其余检索条件一致，诊断事实利用时则提供固定证据。开发集用于分析和选择配置，独立测试用于最终评价。

机制选择应从具体错误出发：先检查信息是否完整保留、相关证据是否取回、事实是否正确使用，再观察更新后的状态。对每项改动设置对应的对照和成本记录，有助于将结构设计与实际任务收益联系起来。

9 总结

六篇论文分别从组织、访问、更新、利用和操作验证改善长期记忆。StructMem 通过事件绑定与跨事件整合保留关联，Hindsight 区分记忆角色并组织多路召回，Semantic XPath 将访问范围落实到层级结构，HyMEM 结合多模态经验与两层更新，MetaMem 学习事实利用规则，Text2Mem 明确操作语义并核验状态变化。各方法的作用位置为分析记忆系统的错误提供了依据。

论文中的对照实验显示，结构化表示能够改善部分任务的证据组织和使用，同时增加抽取、维护或优化成本。方法选择需要结合具体题型、可用反馈与资源预算。评价时应对齐任务、模型和数据划分，分别记录构建、检索、回答及优化开销，并用组件消融和失败案例解释变化。

课程设计以 StructMem 的小规模复现为主线，将其余五篇用于分析检索范围、时间更新、证据利用和操作效果。后续实验可先根据来源记录、检索上下文与状态变化定位错误，再在固定条件下引入相应机制。这样的比较能够明确改动解决了什么问题，以及为此增加了多少成本。

References:

[1] Xu B, Chen Y, Fang J, et al. StructMem: Structured memory for long-horizon behavior in LLMs. In: Proceedings of Liakata M, Moreira V P, Zhang J, et al., editors, Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers), San Diego, California, United States: Association for Computational Linguistics, 2026. 122–146

[2] Latimer C, Boschi N, Neeser A, et al. Hindsight: Structured agent memory that retains, recalls, and reflects. In: Proceedings of Durrett G, Jian P, editors, Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 3: System Demonstrations), San Diego, California, United States: Association for Computational Linguistics, 2026. 275–285

[3] Liu Y S, Wu R, Gallagher L, et al. Semantic XPath: Structured agentic memory access for conversational AI. In: Proceedings of Durrett G, Jian P, editors, Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 3: System Demonstrations), San Diego, California, United States: Association for Computational Linguistics, 2026. 286–296

[4] Zhu S, WU W, Zhou K, et al. Hybrid self-evolving structured memory for computer-use agents. In: Proceedings of Liakata M, Moreira V P, Zhang J, et al., editors, Findings of the Association for Computational Linguistics: ACL 2026, San Diego, California, United States: Association for Computational Linguistics, 2026. 11287–11304

[5] Xin H, Li X, Liu Z, et al. MetaMem: Evolving meta-memory for knowledge utilization through self-reflective symbolic optimization. In: Proceedings of Liakata M, Moreira V P, Zhang J, et al., editors, Findings of the Association for Computational Linguistics: ACL 2026, San Diego, California, United States: Association for Computational Linguistics, 2026. 5473–5492

[6] Wang L, Yang L, Chen B, et al. Text2Mem: A unified memory operation language for memory operating system. In: Proceedings of Liakata M, Moreira V P, Zhang J, et al., editors, Findings of the Association for Computational Linguistics: ACL 2026, San Diego, California, United States: Association for Computational Linguistics, 2026. 2105–2119

成员分工与贡献

待填写：六位成员姓名、负责论文、报告章节、PPT 与讲解工作及实际贡献百分比，总和为 100%。