长上下文场景结构化记忆建模：六篇论文阅读与比较

第 8 队（成员待填写）

(天津大学)

摘　要: 待填写：研究背景、六篇论文的共同问题、主要比较结论和局限。当前为写作框架，尚未形成最终阅读报告。

关键词: 大语言模型；长上下文；结构化记忆；论文综述
中图法分类号: TP18

Structured Memory for Long-Context Scenarios: A Review of Six Papers

Team 8

(Tianjin University)

1　背景与阅读范围

待填写：长上下文记忆的需求、六篇论文的选取范围和本文比较维度。

2　StructMem：面向长程对话的结构化记忆

StructMem[1]研究长期对话中的记忆组织，发表于 ACL 2026 Short Papers，印刷页 122–146。它在事件内部保存事实与互动关系，并用来源时间将条目绑定；在事件之间检索历史、恢复事件语境，再生成整合记忆。细粒度条目与整合摘要共同参与问答。本节实验数值均来自原论文，阅读判断与后续设想分别说明，不表示已完成本组复现。

2.1　研究问题与方法定位

2.1.1　长期对话为什么需要组织记忆

长程对话会持续产生事实、计划、态度和互动。例如，某人提到“去年参加过一个活动”，另一人在相邻话轮中回忆了与朋友共同参加的经历。回答“两人何时一起参加活动”需要把时间表达、共同参与关系和分散的事实放在一起。仅找到与活动名称相似的句子，未必能恢复这个联系。

这类问题同时涉及两个过程。第一，系统在写入记忆时决定保留什么信息。第二，系统在读取记忆时决定给回答模型什么上下文。写入阶段丢失的关系信息，很难单靠增加检索数量补回来。StructMem 因而把记忆单元的设计作为主要切入点。

2.1.2　三种记忆组织方式

组织方式	保存的信息	主要优点	主要代价
平面记忆	独立自然语言条目及其向量	构建直接，语义检索方便	事件上下文容易分散
图记忆	实体、关系及图结构	关系显式，便于结构化访问	实体消歧、去重与关系维护增加成本
StructMem	带时间锚的事实与关系条目，加上跨事件摘要	保留细节，同时提供关联上下文	依赖抽取与整合提示的质量

原文位置：§1–3，图 1，印刷页 122–124。

2.1.3　结构从两个层次形成

事件级绑定解决“同一段交流中的事实和关系怎样放在一起”。跨事件整合解决“当前交流如何与更早的经历相联系”。最终的记忆包括两类可检索内容：一类保留细节，另一类提供跨事件的解释。



图 1 据原文图 2 及附录 A.3、A.7 重绘的处理流程。

从实现上看，StructMem 属于外部记忆框架。论文的核心流程由模型调用、向量检索和数据组织组成，没有引入基础语言模型的参数训练。它仍使用向量检索，结构主要体现在事件绑定与整合内容中。

2.2 事件级绑定：事实、关系与时间

2.2.1 双视角抽取

设第 i 条原话为 m_i，语言模型为 $\mathcal{L}$。事实提示 P_{fact} 和关系提示 P_{rel} 分别生成条目集合：

$$\Phi_i = \mathcal{L}(P_{\text{fact}} \| m_i), \qquad \Psi_i = \mathcal{L}(P_{\text{rel}} \| m_i). \tag{1}$$

其中，Φ_i 保存发生了什么、有什么计划或偏好；Ψ_i 保存人物如何回应、支持、评价或影响对方。“双视角”对应事实内容与互动关系两个抽取目标。附录的关系提示特别关注赞扬、鼓励、感谢、兴趣、认同和回应等行为。

以附录中的研究生录取对话为例，Alice 分享自己被计算机科学项目录取的消息，Bob 祝贺她并询问研究方向。事实条目可记录录取项目与研究方向，关系条目可记录 Bob 对 Alice 的支持和兴趣。这些互动信息能帮助后续模型理解两人为何继续讨论相关计划。

条目类型	据附录示例简化后的内容
事实条目	Alice 被计算机科学研究生项目录取，研究方向为机器学习。
关系条目	Bob 祝贺 Alice，表达对她的信心，并询问她的研究方向。
来源信息	两类输出都携带 `source_id`，用于对应原话及其时间。

2.2.2 时间锚定与事件重建

条目 x 的表示包含自然语言文本、向量 $\mathbf{e}_x$ 和来源时间 τ_i：

$$\mathcal{M} = \bigcup_i \{\langle x, \mathbf{e}_x, \tau_i \rangle \mid x \in \Phi_i \cup \Psi_i\}. \tag{2}$$

来源时间将事实和关系绑定为一个事件单元。检索命中其中一个条目后，可以用同一时间戳找回其他条目，补全事件语境。

这里需要区分**提及时间**与**事件发生时间**。例如，2023 年 8 月 17 日的一条消息说“去年参加了活动”，时间锚记录这句话的来源日期，事件年份则由相对表达推到 2022 年。附录的事实抽取提示要求保留相对时间与参考日期，问答提示再要求换算为具体时间。

2.2.3 形式化表示与实际调用

正文按单条原话 m_i 描述抽取过程。附录提示实际接收按话题组织的文本，并要求按 `source_id` 顺序输出。因此，双视角表示两种抽取任务，具体 API 次数还取决于批处理方式。保留来源编号、人物和时间，是将生成文本接回原始证据的关键。

原文位置：§3.1、式 (1)–(2)，图 4–7、图 13；印刷页 123–124、133–136、139。

2.3 跨事件整合与双路问答

2.3.1 从当前缓存找到相关历史

系统先积累尚未整合的条目，并按来源时间排序。论文的整合触发阈值为**对话时间上的 1 小时**。设缓存上下文为 C_{buf}，其文本拼接后的向量为 q，系统按余弦相似度检索历史中的前 K 个种子条目，默认 $K = 15$。

对于每个种子 x^*，系统找回与其共享时间戳的全部条目：

$$E_\tau(x^*) = \{x' \in \mathcal{M} \mid \tau(x') = \tau(x^*)\}, \tag{3}$$

$$C_{\text{cross}} = C_{\text{buf}} \cup \bigcup_{x^* \in S_K} E_\tau(x^*). \tag{4}$$

这一步使语义检索结果扩展为完整事件上下文。一个与问题高度相似的事实条目，可能缺少周围的赞同、回应或计划信息。时间锚能把这些条目重新聚合起来。

2.3.2 生成有依据的整合记忆

整合模型接收当前事件和相关历史，生成跨事件摘要。提示要求保留具体人物、日期、地点和行动计划，按时间组织内容，并在有依据时表达事件之间的联系。跨时期的引用应带有具体时间，重点放在与当前话题直接相关的历史内容上。附录给出的摘要长度是 200–350 个英文词。

生成的摘要形成额外的抽象层，与原有事件条目共同保存。细粒度条目负责具体事实，摘要提供跨事件联系。为了清楚表达这种并存关系，可以把存储理解为：

$$\mathcal{M}_{\text{all}} = \mathcal{M}_{\text{entries}} \cup \mathcal{M}_{\text{syntheses}}.$$

原文式 (6) 简写了摘要生成与记忆写入过程，同段及问答模板说明了原始条目和整合摘要会一起参与后续回答。

2.3.3 回答阶段使用两路上下文

论文在问答阶段检索 **60 个条目与 5 条整合摘要**，把它们连同问题交给回答模型。提示要求核对人物、利用时间戳换算相对日期，并给出简短答案。

参数	默认设置	所处阶段
时间窗口	1 小时	触发记忆整合
历史种子数量 K	15	整合时检索历史，再扩展事件上下文
问答检索数量	60 + 5	回答时读取条目与整合摘要

原文位置：§3.2、式 (3)–(6)，附录 A.3，图 8、图 13；印刷页 124、129、137、139。

2.4 案例分析：共同经历与相对时间

2.4.1 原论文中的问题

附录 A.8 的问题是：Caroline 和 Melanie 什么时候一起参加过 Pride festival？关键证据分散在不同条目中，同时出现了 2023 年的活动记录和对“去年”活动的回忆。

证据	内容概述
事实 1	Caroline 在 2023 年 8 月 11 日参加了 Pride parade。
事实 2	Caroline 回忆自己在去年的 Pride fest 玩得很开心，该消息记录于 2023 年 8 月 17 日。
事实 3	Melanie 说自己和一群朋友在 Pride fest 度过了愉快时光，该消息同样记录于 2023 年 8 月 17 日。
互动关系	Melanie 对 Caroline 的相关经历表示兴趣，并积极回应她参与社区活动的事情。
整合记忆	在同一叙述中连接两人的回忆，形成她们对去年共同经历的讨论。

2.4.2 三种方法的回答

方法	原文报告的预测
Flat Memory	两人没有一起去过。
Graph Memory	上个月，2023 年 6 月。
StructMem	去年，2022 年 8 月。
参考答案	2022 年。

2.4.3 这个案例说明了什么

问题需要同时判断“共同参加”与“参加时间”。独立事实分别描述两人的经历，互动条目补充了彼此回应的语境。整合步骤把时间相近、语义相关的信息组织成连续叙述，回答模型据此识别共同经历，并将 2023 年消息中的“去年”换算为 2022 年。

这一案例展示了记忆组织如何改变回答上下文。它也提示我们，关系整合需要保留证据来源，避免把主题相似误当成共同经历。原文的参考答案只给出年份，因此案例能够支持的时间结论是 2022 年；预测中额外出现的“8 月”没有得到表内参考答案的单独验证。

对实际系统而言，适合保存的整合记忆应同时包含事件联系和可回溯的来源。这样既能使用摘要中的关联信息，也能在回答涉及具体日期或参与关系时重新检查原始条目。

原文位置：附录 A.8，表 8；印刷页 132。

2.5 实验设计与评价口径

2.5.1 数据与任务

论文使用 LoCoMo 的长对话问答任务。数据包括 10 段长期对话，平均每段 588 轮、16,618 Token。实验采用四类问题，共 1,540 题。

问题类型	数量	主要考察内容
单跳 Single-hop	841	从相关记忆定位事实
多跳 Multi-hop	282	联合多条证据得到答案
时间 Temporal	321	时间顺序与相对日期推理
开放域 Open-domain	96	对话记忆与开放域知识相关的回答
合计	1,540	单跳题约占 54.6%

2.5.2 模型与基线

主实验统一使用 `gpt-4o-mini` 作为基础模型，以 `text-embedding-3-small` 生成向量。比较对象覆盖原始上下文输入、RAG、平面记忆与结构化记忆。

附录还给出了不同方法的检索配置：MiniRAG 和 LightRAG 各检索 20 条，A-Mem 和 LangMem 各检索 40 条；Mem0、Mem0g、Zep 和 Memobase 每位说话人检索 10 条。FullContext 使用完整历史的逆时间顺序表示，表中名为 OpenAI 的配置直接拼接对话文本。这里的 OpenAI 是一个基线配置名。

不同系统使用各自的检索设置，因此主表适合比较整套系统的效果与成本。分析事件绑定和整合组件时，表 2 中的范式对照和消融更直接。

2.5.3 准确率与效率分别衡量什么

准确率使用 LLM-as-a-judge：评判模型接收问题、参考答案和生成答案，输出正确或错误。附录提示允许同义表达和等价日期表述。主结果使用 `gpt-4o-mini` 判断，并用另外两种模型复核。

效率指标统计**记忆构建阶段**的输入 / 输出 Token、API 调用次数和运行时间。它们描述把历史对话变为记忆的成本。回答阶段的 Token 预算和完整服务的响应延迟，还需要单独衡量。对没有构建过程的上下文基线，以及未公开构建细节的服务，主表以横线标注相关项。

原文位置：§4.1，附录 A.2–A.5，表 3，图 16；印刷页 125、128–130、142。

2.6 准确率结果：总分与分项表现

下表按原文表 1 转录，并将单跳列放在多跳列之前，便于对应任务含义。全部数值为百分比。

方法	总分	单跳	多跳	时间	开放域
OpenAI	71.82	84.66	69.86	45.48	53.12
FullContext	73.83	**86.56**	68.79	50.16	56.25
MiniRAG	63.51	75.74	56.74	38.94	58.33
LightRAG	68.83	77.53	66.31	53.89	50.00
LangMem	58.10	71.12	62.23	23.43	47.92
A-Mem	64.16	72.06	56.03	60.44	31.25
Mem0	66.88	72.93	67.13	59.19	51.15
MemoryOS	58.25	67.06	56.74	40.19	45.83
Mem0g	68.44	75.71	65.71	58.13	47.19
Zep	75.14	79.79	**74.11**	67.71	**66.04**
Memobase	75.78	77.17	70.92	**85.05**	46.88
StructMem	**76.82**	81.09	68.77	81.62	46.88

原文位置：表 1；印刷页 125。加粗表示该列最高值。

2.6.1 主要结果

StructMem 的总分为 76.82%，比 Memobase 高 1.04 个百分点，比 Zep 高 1.68 个百分点，比 FullContext 高 2.99 个百分点。这表明它在论文所采用的数据与配置下，达到了较好的整体平衡。

分项表现更有解释力。相对 FullContext，StructMem 的时间推理提高 31.46 个百分点，而单跳下降 5.47 个百分点，多跳基本持平。相对 Zep，StructMem 时间推理更好，但多跳与开放域更低。Memobase 则仍保持最高的时间推理成绩。由此可见，StructMem 的收益与问题类型有关。

2.6.2 结果应如何理解

全文上下文保留了大量原始细节，有利于单跳事实定位。事件结构和整合摘要帮助模型建立时间线，所以 StructMem 相对全文上下文的时间推理优势很突出。它在多跳任务上的机制收益，还要结合下一节的消融结果判断。

单跳题占数据的一半以上，总分会受到题型分布影响。阅读这一结果时，应同时报告总分与四类成绩，避免把综合排名解释为所有任务上的全面领先。

2.7 效率结果：构建成本与运行时间

2.7.1 主表中的资源消耗

Token 单位为百万（M），时间单位为秒。下表保留了原文的构建总量；其中 MemoryOS 的输入输出加总差异在文末注明。

方法	输入 Token	输出 Token	总 Token	调用次数	时间
MiniRAG	9.022	1.081	10.103	2,508	2,566
LightRAG	10.014	1.916	11.931	13,576	60,469
LangMem	9.873	1.192	11.066	5,990	26,281
A-Mem	9.126	2.368	11.494	11,754	60,607
Mem0	10.958	1.239	12.196	9,181	30,057
MemoryOS	1.889	0.939	2.868	5,534	24,220
Mem0g	33.512	2.313	35.825	53,514	115,670
StructMem	**1.501**	**0.436**	**1.937**	**1,056**	22,854

原文位置：表 1；印刷页 125。

相对 Mem0g，StructMem 的构建 Token 减少约 94.6%，API 调用减少约 98.0%，运行时间减少约 80.2%。相对 Mem0，构建 Token 减少约 84.1%。这些百分比由原表数值计算，表达的是不同系统配置之间的差异。

运行时间具有不同的排序：MiniRAG 只用 2,566 秒，明显短于 StructMem 的 22,854 秒。Token 数量、调用次数和耗时之间还受到模型调用方式、批处理、服务延迟与并发等因素影响。论文没有提供足够的信息，把全部耗时差异归因于其中某一因素。

2.7.2 同一框架下的组织代价

图 3(b) 在 LoCoMo 第一段对话上拆分三种范式的构建 Token。平面记忆约 77.6k，StructMem 约 226.1k，图记忆约 402.3k。StructMem 的 226.1k 中，条目抽取约 151.0k，整合约 75.1k。

这组结果说明，增加双视角抽取与整合会比简单平面记忆付出更多构建成本。相对图记忆，批量整合又减少了实体 / 关系抽取及去重的多阶段开销。主表的跨系统比较与图 3 的范式比较回答了不同层面的问题，两者需要分别解读。

我的理解

StructMem 把一部分原本留到问答时完成的关系推理，提前放进周期性的记忆构建。它用额外的组织成本换取更好的上下文，再通过批处理控制这部分成本。

原文位置：图 3(a)–(b) 及 §4.3；印刷页 126。

2.8 消融与参数分析

2.8.1 事件绑定和跨事件整合各带来什么

配置	单跳	多跳	时间	开放域
Flat Memory	78.83	66.31	78.50	46.88
Graph Memory	80.50	66.67	76.64	48.96
去掉跨事件整合	80.86	66.31	79.44	46.88
StructMem	81.09	68.77	81.62	46.88
加入跨事件整合的变化	+0.23	+2.46	+2.18	0.00

数值来自表 2，最后一行是本总结计算的百分点差值。

保留事件绑定、去掉跨事件整合后，单跳与时间任务仍高于 Flat Memory。进一步加入整合，多跳提高 2.46 个百分点，时间提高 2.18 个百分点，单跳只增加 0.23 个百分点。这与方法设计相符：跨事件摘要主要帮助联合分散信息。去掉与加入整合的两种配置中，开放域分数均为 46.88%。

2.8.2 历史种子数量与效果

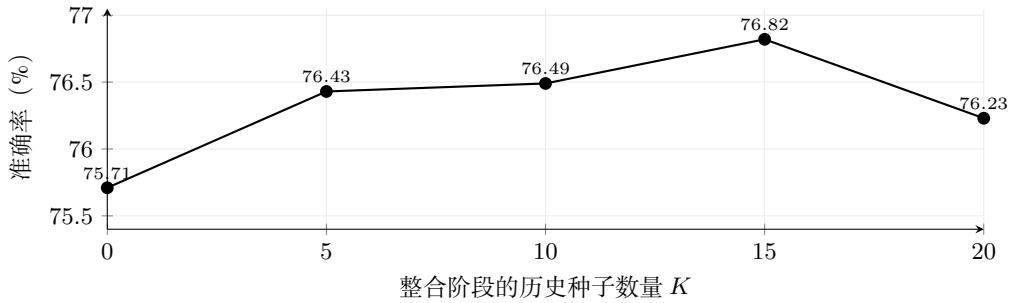


图 2　据原文图 3(d) 重绘。纵轴截取 75.4–77.05，用于显示参数间的细小差异。

$K = 0$ 时仍整合当前缓存，只是不引入历史事件。$K = 15$ 达到图中最高的 76.82%，$K = 20$ 则回落到 76.23%。这表明更多历史上下文不一定继续改善效果，选择范围需要控制。

图 3(c) 中，平面检索从 10 条增加到 60 条，准确率由 70.91% 提高到 75.78%；继续增加到 100 条时为 75.71%，相关 Token 量则从 3.65M 增到 5.62M。该结果支持适度增加检索覆盖率，也说明覆盖率之外仍存在信息组织问题。

原文位置：表 2，图 3(c)–(d)；印刷页 125–126。

2.9 生成记忆的忠实性与评判稳定性

2.9.1 抽取和整合分别接受检验

新的记忆由语言模型生成，因此需要检查生成内容是否有原始证据。附录 A.6 将这个问题分成两步：先检查单个条目是否忠于原话，再检查跨事件摘要是否引入了错误联系。

在事件抽取阶段，三个评判模型报告的幻觉率分别为 2.63%（GPT）、1.61%（Qwen）和 2.84%（DeepSeek），原文汇总的平均值为 2.36%。这描述的是抽取条目的忠实性，与问答错误率是不同指标。

在整合阶段，评判模型比较“只整合当前缓存”与“加入 15 个历史种子”的摘要，识别新增历史联系。作者进一步删除提示中的具体时间引用与具体联系要求，得到无约束版本。

评判模型	有约束的错误联系	无约束的错误联系	错误率变化
GPT	6/982（0.61%）	72/966（7.45%）	+6.84 个百分点
Qwen	33/968（3.41%）	213/1065（20.00%）	+16.59 个百分点
DeepSeek	13/358（3.63%）	104/687（15.14%）	+11.51 个百分点

这组实验支持具体时间与来源关联约束的作用。不同评判模型识别出的联系数量不同，因此表中保留各自的分子和分母，分别比较约束前后变化。

2.9.2 更换问答评判模型后的排名

评判模型	StructMem	Memobase	分差（百分点）
gpt-4o-mini	76.82	75.78	+1.04
Qwen2.5-32B-Instruct	77.01	76.36	+0.65
DeepSeek-V3.2	79.35	79.29	+0.06

三个评判模型下，StructMem 的总分都略高于 Memobase。作者报告 Fleiss' $\kappa = 0.8341$，表明这些模型的判断具有较高一致性。与此同时，DeepSeek 评判下的分差只有 0.06 个百分点。排名相近的系统还需要逐题分析和重复实验来理解差异来源。

原文位置：附录 A.5–A.7，表 4–7，图 17–20；印刷页 129–131、143–146。

2.10 阅读思考与后续实验

2.10.1 方法最值得借鉴的部分

我认为这篇论文最有价值的设计，是把关系信息的保存提前到记忆形成阶段。人物的支持、回应和共同回忆经常出现在话语互动中，这些内容一旦被压缩成孤立事实，后续检索很难恢复。StructMem 在抽取时保留互动关系，在整合时再连接历史事件，使回答上下文更接近一段有时间线的经历。

第二个值得借鉴的设计是原子条目和整合摘要并存。条目保存具体细节，摘要把分散信息组织起来。两种粒度一起检索，可以兼顾事实定位与跨事件理解。这也为后续系统提供了清楚的消融维度。

2.10.2 还需要解决的实际问题

旧记忆如何修订。作者在局限部分指出，当前框架缺少显式的冲突消解与记忆更新机制。用户更改计划或偏好后，旧摘要可能继续被检索。问答提示中的“优先最近记忆”提供了回答规则，存储层仍需要版本、失效标记或重新整合机制。

摘要联系如何追溯。时间锚和提示约束降低了无依据联系，但摘要中的每项关联若能对应到具体来源条目，检查和更新会更加直接。尤其当某条历史事实失效时，系统应能找到受它影响的摘要。

收益能否迁移。论文主要在 LoCoMo 上测试，基础模型固定为 gpt-4o-mini。更多任务类型、不同模型和更长历史能够帮助判断方法适用范围。表 2 也没有逐项拆开“关系抽取”“时间锚定”“摘要检索”的贡献，后续可以在固定预算下继续比较。

2.10.3 适合课设的小规模验证

以同一基础模型和同一份数据，比较事实记忆、事件记忆、事件记忆加跨事件整合三种配置。先固定检索预算，再分别去掉关系条目、时间信息和整合摘要。记录四类准确率、构建与问答 Token、调用次数，并保留失败题的检索上下文。

在此基础上，可以增加一组计划变更对话，观察旧事实及旧摘要的影响，再尝试加入来源追踪和摘要失效策略。这些是基于论文提出的后续实验设想，能够把阅读中的问题转化为具体实现与评测。

原文位置：§3–4，Limitations，附录 A.3、A.7；印刷页 123–127、129、139。

2.11 原论文表格的复核问题

本文引用原论文印刷值，差值与比例在该基础上计算。复核时发现，表 1 中 MemoryOS 的输入 1.889M 与输出 0.939M 相加为 2.828M，Sum 列为 2.868M。另外，按表 3 题型数量对表 1 的 Mem0 与 Zep 分类分数加权，约得到 67.646% 和 75.375%，与报告的 66.88% 和 75.14% 不一致。论文未说明这些行是否采用了不同的有效样本或汇总规则。后续复现时可用逐题结果核对。

图 3(c) 的 Token 量对应其检索规模分析，正文没有完整展开该图的计量过程。本文按图中趋势讨论检索数量与效果，不把它并入表 1 的构建成本。

2.12 本篇阅读结论

这篇论文最重要的启发是：记忆组织改变的不只是存储形式，还改变后续模型能够联合哪些证据。事件内绑定保留人物互动与事实语境，跨事件整合则把相关历史组织成有时间依据的叙述。主结果、组件消融和忠实性检查分别从整体效果、机制作用与生成风险三个层面提供支持。

与此同时，论文条件下的整体排名不等于所有题型领先，较少的构建 tokens 也不等于每项效率指标都最优。后续仍应检查关系抽取、时间锚和摘要通道的独立贡献，以及新旧信息变化后如何维护一致性。与其他五篇论文的系统性比较，留待各成员完成个人部分后共同讨论。

3 Hindsight：保留、召回与反思的结构化智能体记忆

Latimer 等人提出 Hindsight，面向需要跨多轮对话和多个会话保持记忆的智能体[2]。它把记忆组织为四类网络，并用 retain、recall、reflect 三种显式操作分别处理信息写入、证据检索和基于记忆的回答。本文是 ACL 2026 System Demonstrations 论文，重点介绍系统架构与交互演示；实验部分概述了作者报告的 LongMemEval 和 LoCoMo 结果。下文的准确率均为论文报告值，不是本组复现结果。

3.1 研究问题与四类记忆

作者将现有对话记忆的困难概括为三个相连的问题：长历史中怎样保留有用信息，查询时怎样跨会话找回相关信息，以及怎样在回答时避免只凭局部线索而产生全局不一致。单纯把片段放进向量库并取回 top-k，还可能混淆用户说过的事实与智能体形成的判断，也难以表达时间和实体之间的联系（PDF 第 1–3 页，印刷页 275–277）。

Hindsight 在每个 memory bank 中维护四类逻辑网络：

网络	保存内容	例子或作用
World	关于外部环境的客观事实	Alice 在 Google 的 Mountain View 团队工作。
Experience	智能体自身采取过的行动	智能体曾向 Alice 推荐徒步旅行。
Observation	根据多条事实整合出的实体摘要	Alice 是专长于机器学习的软件工程师。
Opinion	带置信度、可随证据变化的主观判断	“Python 适合数据科学”，并记录置信度。

World 与 Experience 记录事实或经历；Observation 汇总关于实体的证据；Opinion 则明确标记为主观判断。论文强

调这种区分便于开发者检查智能体“知道什么”以及“相信什么”。记忆单元还带有发生时间区间和被系统获知的时间戳，并可通过时间、语义、实体和因果关系连接成图（PDF 第 3–4 页，§3.1、图 1）。

3.2 三种操作：写入、检索与生成

Retain 接收对话或文档，由模型抽取较粗粒度的叙事事实，再进行分类、实体识别与消歧、时间标注和关系建图。作者称每段对话通常抽取 2–5 条事实，以减少记忆切分方式对后续检索的影响。这里记录的时间至少要区分事件发生时间与智能体提及或获知该信息的时间（PDF 第 3–4 页，§3.2–3.3）。

Recall 接收查询和 token 预算，返回预算内排序后的记忆。它并行使用四类检索：HNSW 向量相似度、BM25 关键词匹配、沿实体 / 时间 / 因果连接进行图遍历，以及按事件时间范围过滤。不同通道的排序由 Reciprocal Rank Fusion 合并，再由 cross-encoder 重排。图遍历通常限制在 2–3 跳；时间解析先处理常见表达，规则无法处理时再调用轻量 T5 模型。token 预算让调用者限定送入回答模型的上下文规模（PDF 第 3、5 页，§3.2、§4.1）。

Reflect 将查询、取回的记忆和可配置的行为档案交给生成流程。行为档案由怀疑程度、字面倾向和共情程度三个 1–5 的参数组成。Opinion 与事实分开存储，置信度在 $[0, 1]$ 范围内；新证据支持某个判断时提高置信度，形成反证时降低置信度。后台整合还会保存支持性引文、证据数量和从 new 到 stale 的新鲜度趋势，使判断可以回溯到证据（PDF 第 3–4 页，§3.2–3.3）。

论文把 retain 和 recall 放在 TEMPR（Temporal Entity Memory Priming Retrieval）组件中，把 reflect 放在 CARA（Coherent Adaptive Reasoning Agents）组件中。端到端流程可概括为“对话进入四类记忆网络—多通道召回—依据证据生成并更新意见”。作者使用 PostgreSQL、pgvector 与全文检索索引作为存储基础，并报告：包含 10,000 条记忆的 bank，其 recall 检索延迟低于 200 ms，但该数字不包含回答模型的推理时间（PDF 第 4–5 页，图 1、§4.1–4.2）。

3.3 实验设置与论文报告的结果

论文在 LongMemEval 与 LoCoMo 上评估对话长期记忆。LongMemEval 的 S 设置包含 500 道问题，对话最长约 150 万 token；LoCoMo 使用多会话对话，每段最多 35 个会话。指标为回答准确率。以下转录原文表 2 中的总体分数（单位：%）；不同工作使用的模型、系统配置和评测设置并不完全相同，因此表中结果不构成严格控制变量的直接比较。

基准	论文列出的参照结果	Hindsight 20B	Hindsight 120B	Hindsight Gemini-3	阅读时需注意
LongMemEval	Full-context GPT-4o：60.2；Supermemory（Gemini-3）：85.2	83.6	89.0	91.4	20B 高于 GPT-4o 全文基线，但低于表中的 Supermemory。
LoCoMo	Zep：75.1；Memobase：75.8；Backboard：90.0	83.2	85.7	89.6	Gemini-3 结果接近但低于 Backboard 的报告值。

Hindsight 结果表　据原文表 2 转录；PDF 第 6 页，印刷页 280。

在 LongMemEval 上，作者报告 20B 开源模型配合 Hindsight 达到 83.6%，比全文 GPT-4o 的 60.2% 高 23.4 个百分点；模型扩大到 120B 后为 89.0%，使用 Gemini-3 后为 91.4%。在 LoCoMo 上，相应结果为 83.2%、85.7% 和 89.6%。附录表 4 显示，20B 配置在 LongMemEval 的时间推理和多会话题上均为 79.7%，偏好题为 66.7%；这些题型与时间过滤、实体关联和 Opinion / Observation 组织所针对的问题相对应（PDF 第 7 页及第 11 页，§6.1–6.3、表 4）。

表内模型条件影响结论范围：20B 配置的 LongMemEval 分数低于表列的 Supermemory-Gemini-3，LoCoMo 上 Hindsight-Gemini-3 的 89.6% 也低于 Backboard 的 90.0%。这不等于受控条件下 Hindsight 一定较差，而是说明不宜把摘要中的“胜过所有既有记忆系统”泛化为对表中每个系统、每个模型配置都领先。比较时需要同时报告基座模型、记忆方法、数据集和评测口径。

3.4 局限、证据边界与课设启发

论文明确列出的局限包括：事实抽取、实体消歧和意见更新依赖语言模型，错误可能沿记忆图传播；评测只覆盖英文基准；Opinion 的主观质量和置信度校准还没有通过正式用户研究验证；时间解析可能漏掉含混或文化相关的表达。持续保存个人偏好与意见也带来隐私和偏见风险，论文指出系统没有内置 PII 检测或自动脱敏机制（PDF 第 8 页，印刷页 282）。

还有两点证据边界值得在复述时说明。第一，本文是系统演示论文，并称完整评估见 Latimer 等人的 2025 年工作；但本文参考文献中该条目的 arXiv 编号仍为占位符 “2505.XXXXX”，因此不能仅凭本文核实其完整实验与消融。第二，§6.2 的 LongMemEval 细分类别基线数值与附录表 4 中 Full-context GPT-4o 的对应数值不同，正文没有在该处充分解释差异。阅读结果时应以明确标注的数据配置为单位，避免把不同设置的数字当作同一组对照（PDF 第 7–9、11 页，§6.2、表 4 及参考文献）。

对本组 “长上下文场景结构化记忆” 课设，Hindsight 提供了三类可验证的设计问题：事实、经历、实体摘要与主观意见是否需要分开存储；时间与实体图连接是否能补足向量检索；多通道检索在固定 token 预算下是否提高答案质量。若后续实验采用这些想法，应固定模型、数据与预算，逐项比较检索通道，并同时记录准确率、噪声、延迟和 token 成本。上述内容是从论文推导出的实验设想，不是本组已经验证的结果，也不代表全组已形成结论。

原文：Latimer et al. (2026), ACL Anthology，PDF 第 1–11 页；关键架构见图 1（PDF 第 4 页），总体结果见表 2（PDF 第 6 页），分类结果见表 4（PDF 第 11 页）。

4 Semantic XPath

本节由 `oioioi-521` 负责，依据既有个人阅读报告、13 页演示稿及讲稿整理。原文为 Liu 等人的 Semantic XPath[3]，见 https://aclanthology.org/2026.acl-demo.28/。下述页码均为原论文 PDF 页码（共 11 页，印刷页 286–296）。所有实验数字属于作者结果；本组没有进行 Semantic XPath 的端到端复现。

4.1 研究问题与方法定位

长期任务导向对话需要反复查看、修改和回溯同一个任务对象。旅行计划中的一项活动不仅包含文本，还属于特定日期、行程与历史版本。全量上下文保留信息较多，但输入量随历史增长；扁平检索降低输入量，却可能取回语义相似而所属范围错误的条目。比如 “在会议安排最密集的一天增加咖啡休息”，需要比较各天的活动，而不仅是找一条包含会议内容的文本（PDF 第 1–2 页，图 1–2）。

Semantic XPath 将已有的结构化记忆组织为树，用 XPath 风格的路径、位置条件和连续语义评分定位相关节点及子树，再交给下游模型回答或更新。研究重点是**记忆访问**：查询负责定位，实际插入、删除及版本维护由下游步骤处理。论文不能被解读为已经解决通用记忆构建、全部冲突消解或任意图关系推理。

4.2 树形数据模型与查询语法

记忆表示为有根树 $T = (V, E, r)$。非根节点只有一个父节点，节点具有类型和文本属性；模式 Σ 由记忆数据已有的节点类型、属性和父子关系决定，而非要求人工预先设计一个通用模式。旅行示例采用

$$\text{Itinerary} \rightarrow \text{Version} \rightarrow \text{Day} \rightarrow \text{POI},$$

分别表示计划、版本、日期和活动；层级主要是组成关系，不只是对下层文本做有损摘要（PDF 第 3 页，§3.1）。

查询是步骤序列，每一步写为 $S = A\,N\,[R]\,[P]$：路径与类型必需，位置选择器和语义条件可选（PDF 第 3–4 页，§3.2）。

表 1 Semantic XPath 查询步骤的组成；依据原文 §3.2

组成	示例写法	作用
路径 A	`/`、`//`	访问直接子节点或全部后代
类型 N	`Day`、`POI`、`*`	按节点类型筛选或匹配任意类型
位置 R	`[i]`、`[-i]`、`[i:j]`	按顺序、倒序或区间选取候选
语义 P	`[node~="workshop"]`	计算候选与语义条件的相关程度

例如 `//Day[3]/POI[node~="workshop"]` 先选第三个匹配日期，再对该日期下的活动进行语义评分。若同时存在多个行程或版本，必须先限定目标范围；第三个匹配日期不能自动当作当前版本的第三天。语义条件 $1-P$ 提高原条件低分候选的优先级，它是软评分操作，不等同于已经执行删除。

4.3 语义评分与带权执行

原文附录 A 定义 $\mathrm{Rel}(u,P)\in[0,1]$。局部评分依据一个属性或完整节点表示；聚合评分先在当前节点下执行内部结构查询，再用平均、最小、最大或几何平均聚合证据；多个条件还可用乘积、平均及取反组合（PDF 第 10 页）。

```
//Day[avg(/POI[node~="conference"])]
```

这个查询根据活动证据评价日期。原文第二天的三个活动分数为 0.603、0.482、0.608，平均约 0.565；与其他日期比较后选中第二天。该平均值刻画会议相关性的密集程度，不能直接解释为会议数量最多（PDF 第 4 页，§3.3、图 2）。

执行器从根节点及权重 1 出发，维护带权集合 $W\subseteq V\times[0,1]$，按步骤进行路径扩展、类型筛选、位置选择与语义评价。语义步骤更新为

$$w_{\text{new}} = w_{\text{old}}\,\mathrm{Rel}(u,P). \tag{5}$$

聚合条件递归访问下层证据。可执行的查询、正确的目标节点、足够完整的证据与正确的最终回答是不同层次；形式定义本身不统一规定所有场景的阈值、返回数量或空集处理。

4.4 教学案例与公平比较

沿用个人演示中的教学示例：假设只有一个当前版本，第 2 天有海滨公园，第 5 天有山地徒步，第 7 天有植物园和海港游船。用户要求找出“第 7 天下雨时需要调整的户外活动”。纯语义排序可能混入其他日期的活动；结构化访问先限定第 7 天，再评价活动语义，目标为植物园与游船。

这个例子用于解释范围约束，**没有运行真实检索，也不是论文实验数据**。带日期元数据过滤的扁平 RAG 同样可以解决简单日期约束，因此应作为公平比较基线；不能把简单过滤收益全部归因于复杂查询语言。

4.5 实验设置与指标口径

作者评估旅行行程、待办清单和家庭配餐三个自建场景，每场景 20 个单轮对话、5 个多轮对话；另在 LoCoMo 中使用原生的 Memory–Conversation–Session–Turn 层级。回答模型为 GPT-5 mini 与 Gemini 3 Flash。相似度评分器（Sem）和 Flat RAG 使用 Qwen3-Embedding-8B；蕴含评分器（Entail）使用 `facebook/bart-large-mnli`（PDF 第 5 页，§4.1）。

自建场景的通过率要求检索到正确结构化数据，且输出满足任务约束；LoCoMo 则是模型裁判与参考答案对照的回答得分。后者不是人工金标准，两类指标不能直接混比。表 1 明确报告平均**输入** tokens，XPath 包含查询生成输入；附录表 2、表 3 仅称平均 token 用量，没有同样完整交代各组成。跨提供方的分词器也不同，宜在同一模型内比较。token 不能代表嵌入、蕴含评分及查询执行的全部计算成本。

表 2 作者单轮结果节选；原文 PDF 第 11 页、表 2，三个自建场景平均

回答模型	方法	通过率（%）	平均 tokens
GPT-5 mini	In-context	70.0	26 216
	Flat RAG	30.0	3 250
	XPath Sem	66.3	6 166
	XPath Entail	83.0	5 691
Gemini 3 Flash	In-context	79.0	25 387
	Flat RAG	37.7	3 361
	XPath Sem	64.3	6 043
	XPath Entail	70.7	5 830

单轮 GPT-5 mini 的 Entail 相对 Flat RAG 提高 $83.0 - 30.0 = 53.0$ 个百分点，相对增幅约 176.7%；其 token 用量为全量上下文的 $5691/26216 \approx 21.7\%$。但 Gemini 的 In-context 为 79.0%，高于 Entail 的 70.7%，因此不能声称所有模型下准确性均最高。

表 3 作者多轮结果节选；原文 PDF 第 11 页、表 3，三个自建场景平均

回答模型	方法	通过率（%）	平均 tokens
GPT-5 mini	In-context	80.0	69 097
	Flat RAG	26.7	3 327
	XPath Sem	70.0	6 294
	XPath Entail	83.3	5 850
Gemini 3 Flash	In-context	56.7	76 603
	Flat RAG	26.7	3 240
	XPath Sem	76.7	6 092
	XPath Entail	80.0	5 993

多轮 Entail 在两种模型下取得最高平均通过率，token 约为全量上下文的 8.5% 与 7.8%。Sem 与 Entail 的平均差异提供评分器比较，但不保证每个子场景都改善。单轮和多轮请求不同，不能将两张表当作同批样本的退化曲线。摘要中的 9.1% 是作者概括；不能把它与单轮 176.7% 相对提升拼接为同一设置下的结论。

表 4 作者 LoCoMo 结果；原文 PDF 第 7 页、表 1，XPath 输入含查询生成

回答模型	方法	回答得分	平均输入 tokens
GPT-5 mini	In-context	74.55	24 857
	Flat RAG	35.71	1 341
	Semantic XPath	65.19	3 032
Gemini 3 Flash	In-context	87.01	27 499
	Flat RAG	41.49	1 996
	Semantic XPath	73.25	3 870

LoCoMo 上 XPath 的总体得分处于两种基线之间，输入分别约为全量上下文的 12.2% 与 14.1%。这说明已有会话层级可用于访问，但准确性仍有损失。例如 GPT-5 mini 多跳题得分为 43.26，低于全量上下文 58.87，证据整合仍有差距。作者的失败分析将错误分为查询生成、检索和回答生成，认为检索是主要剩余来源，包括无命中、证据不全及选错节点或发言（PDF 第 6–7 页，§4.3、图 8）。

4.6 优缺点与本组课设的联系

方法的优势是将结构范围与连续语义判断组合，并用路径与评分轨迹解释结果；下层证据可以评价上层对象，访问粒度不必固定为独立片段。其前提是有可用且可靠的层级。跨树关系、版本范围模糊、复杂多跳和不完整证据仍需检验；小规模自建任务、缺少充分重复实验和置信区间、未覆盖本地评分开销等，也限制了对泛化和成本的判断。这些属于本节阅读评价，不作为已验证的改进成果。

与 StructMem 相比，Semantic XPath 强调**如何在已有层级中访问证据**，StructMem 强调事件绑定及跨事件综合；二者表示、模型、任务与预算不同，不按原论文分数直接排名。HyMEM 的图邻居与动态更新、Text2Mem 的操作规范可以作为比较维度，但本节不推定已完成模块组合或形成全组共识。

本人课设技术分工 C 已经完成 91 个 session 的事件抽取与交接，具体实现和验收另见 C 结项记录[1]；它不是 Semantic XPath 复现。对后续设计可提出三项待验证建议：明确日期/版本等硬范围；输出可追溯的节点与证据标识；分别检查范围、节点、证据完整性及回答错误，并与元数据过滤基线比较。

5 HyMEM：电脑操作智能体的混合自演化记忆

HyMEM[4]面向需要观察截图并连续操作网页的电脑操作智能体。历史经验既包含可复用策略，也包含难以写成文字的界面与动作细节；任务推进后，最初检索的经验又可能失效。因此，系统结合离散策略与连续轨迹表示，分别更新长期记忆和当前任务的工作记忆。以下数据均为作者实验，不能作为本组复现结果。原文为 ACL 2026 Findings，印刷页 11287–11304；下述 PDF 页码从论文首页起计。

5.1 问题背景与混合表示

输入包括任务描述、当前截图及历史成功操作轨迹，输出为下一步可执行操作。例如，搜索商品和结账所需经验不同，但可能需要保留同一预算约束。纯文本总结容易丢失视觉细节，单纯连续表示则缺少清晰的策略组织和可解释索引；一次性检索也难以覆盖交互阶段变化。这些问题构成混合表示与两种更新机制的动机（PDF 第 1–3 页，表 1）。

论文在图 $G = (V, E)$ 中组织经验，将一条轨迹的逻辑表示写为

$$v_i = (c_i, A_i, m_i), \tag{6}$$

其中 c_i 为高层策略，A_i 为动作、界面元素或领域标签等属性集合，m_i 为连续轨迹表示。共享相同属性的轨迹间建立无向边，并通过策略、属性与轨迹的关联支持跨经验检索。三元组描述经验的内容层次，不意味着实际图只有一种同质节点。策略与属性提供语义锚点；借鉴 CoMEM 的连续编码保留难以用文本概括的视觉及动作细节，每条轨迹压缩为 8 个嵌入向量并接入智能体输入（PDF 第 3–5 页，§3.1–3.3、图 1）。

另一个容易混淆的表示是**检索索引向量**：归一化的任务文本 CLIP 表示与起始截图 CLIP 表示拼接后，通过 FAISS 进行相似度检索。它用于寻找经验，不等同于送入智能体的连续记忆 m_i（PDF 第 3 页，式 (1)）。

5.2 全局记忆演化与结构化检索

更新长期图时，新轨迹先检索相关经验，再由视觉语言模型判断信息增量。相似度仅决定候选集合，不能直接决定经验是否重复。三种更新为（PDF 第 4 页，图 1 与 Memory Update）：

- **ADD**：出现新策略或属性，增加对应节点与连接。
- **MERGE**：已有策略获得互补证据，如界面变体或另一条操作路径，将证据并入相应策略及属性关联。

1 https://github.com/YaoYang-123456/NLP-2026-Team08-Structured-Memory/issues/32

- **REPLACE**：在同等条件下，新轨迹以更少步骤、更高成功率或更低风险实现相同策略，用其替换过时证据并刷新关联。

这些操作改变跨任务复用的长期图，目的是减少冗余、积累可迁移经验。更新质量依赖模型的冗余与优劣判断，不能理解为图规模必然受控或每次替换必然正确。

推理时，系统依据任务和截图寻找相似种子，再沿图扩展邻居并按相似度排序。主实验每次使用 10 条轨迹：5 条语义相似种子，加上从种子的 1 跳邻居中选出的 5 条轨迹。“5+5” 是实验配置，不能表述为任意任务的最优预算。一般算法允许重复扩展，主实验采用上述具体配置（PDF 第 4–5 页，Structured Retrieval 及 Memory Settings）。

5.3 混合工作记忆及局部刷新

检索后形成两个互补视图：策略与属性归纳为指导指令（Guidance Instructions），作为文本写入系统提示；轨迹连续嵌入则与模型输入连接。前者帮助规划，后者提供细粒度视觉和动作信息，二者构成当前任务的工作记忆。

每个动作后，视觉语言模型比较前后观测与当前指导，判断是否发生阶段转换。若任务由搜索转入结账，先保留长期目标和约束，丢弃不相关内容，再按新状态检索，合并指导并刷新连续嵌入。这是**任务内部的上下文更新**，与长期图的 ADD/MERGE/REPLACE 属于不同层次（PDF 第 5 页，On-the-fly Working Memory Refresh）。此例仅用于机制说明，不是本组运行案例。

5.4 实验条件及作者结果

实验覆盖 WebVoyager、Multimodal-Mind2Web 和 MMInA 三个多模态网页智能体基准。前两者根据任务描述与截图轨迹进行模型判分；MMInA 比较最终回答和标准答案。主指标是任务成功率，表 2 的 Overall 为可用领域的平均值，并非将所有测试样本合并后的统一样本准确率。作者声明表 2 各方法均为其在统一环境、抽样和评价口径下的实现（PDF 第 5–7 页，§4.1–4.2 与表 2）。

记忆来源为 GUIAct、Mind2Web 训练集及作者智能体生成的成功轨迹，共 2883 条；主表所用图为 1858 个节点、超过 100 万条边。执行采用 ReAct 式接口，包含 SOM 界面标记及 UI-INS-7B 定位回退。训练更新记忆编码器的 Q-Former 和 LoRA 层，作者称可训练参数约占总参数的 1.2%，通常训练 1 个 epoch。因此，HyMEM 不只是拼接提示词；定位系统、记忆数据和编码器训练也是结果成立的条件（PDF 第 5 页，§4.1）。

表 5 作者表 2 的 Overall 成功率节选（%）；来自 PDF 第 7 页

基础模型	无记忆	离散记忆	连续记忆	HyMEM
Qwen2.5-VL-7B	12.5	17.0	21.7	35.0
Qwen3-VL-8B	21.9	21.3	23.3	33.8
UI-TARS-1.5-7B	17.1	15.4	28.7	31.2

Qwen2.5-VL-7B 由 12.5% 升至 35.0%，提高 22.5 个**百分点**，不能写为相对提高 22.5%。混合记忆在该模型上高于单独离散或连续记忆，但不能证明所有任务均有相同收益。例如，Qwen3-VL-8B 离散记忆的 21.3% 低于无记忆 21.9%；部分领域也未随 HyMEM 改善。

作者另在 Amazon 与 Google Maps 比较静态记忆和自演化记忆。图 2 中，全局演化使成功率分别由 48.8% 升至 61.0%、43.9% 升至 51.2%；局部刷新分别达到 56.1% 和 48.8%（静态参照分别为 48.8% 和 43.9%）。这是特定分析设置的结果，不能与表 2 不同模型、领域配置直接拼接，也不能将两种提升相加（PDF 第 7 页，§4.3.1、图 2）。

5.5 优缺点、可比性及与课设的联系

HyMEM 把可解释策略、连续视觉细节、跨任务图更新和任务内工作记忆刷新组合为闭环，主表与自演化分析给出相应证据。其代价包括构建、编码器训练、图扩展和执行期间的模型判断；本节未据成功率推导端到端成本优势。图关联与更新依赖标签质量及模型判断，仍需考察错误记忆传播、阶段误判和跨网站迁移。

本组 StructMem D 负责文本事件记忆的综合与检索；HyMEM 实证任务则为基于截图的网页操作，数据、输

出、接口和评价均不同。因此，不能将 35.0% 与本组 LoCoMo 结果并排排名，也不能声称本组已实现连续多模态记忆或局部刷新。可作为**后续假设**借鉴的设计是：区分语义种子与结构邻居；区分跨任务更新和任务内刷新；在固定检索预算下分别评估覆盖、噪声和调用成本。以上为本节阅读分析，尚非全组共识或已完成实验结论。

6 MetaMem：由事实存储转向事实利用

MetaMem[5]（ACL 2026 Findings，印刷页 5473–5492）讨论一个区别于检索召回的问题：**模型即使找到了与问题相关的记忆，仍可能不能正确利用这些事实**。本节首先概括论文的机制与实验，再分析适用条件和局限。以下表格数据是论文报告的结果，不能等同于本组复现实验。

6.1 研究问题与两种记忆

长期对话包含时间、人物、地点、数量及其从属关系。例如，一次旅行总里程为 1200 英里，其中第一天的 300 英里已包含在总数中；若另三次旅行合计 1800 英里，四次旅行应为 3000 英里，而非 3300 英里。错误不仅可能来自遗漏证据，也可能来自取回后对“整体与部分”关系的误判（原文 PDF 第 1 页，图 1）。

论文区分事实记忆 M 与元记忆 E：前者保存具体经历与知识，后者保存**可迁移的知识使用经验**，例如在计数前检查是否重复包含。设问题为 q，主方法可抽象为

$$\hat{y} = \mathrm{LLM}\big(\mathrm{Prompt}(q, M, E)\big). \tag{7}$$

普通记忆问答主要提供 (q, M)；MetaMem 把 E 也送入提示词。这不意味着重新训练基础大语言模型的权重，更新对象主要是自然语言规则（原文 PDF 第 3 页，式 (1)–(3)）。

6.2 从反馈到规则的自反思优化

方法包含训练阶段与冻结后的问答阶段。训练时，给定带标准答案的样本 (q, a, M)，模型在当前元记忆下多次生成答案，再利用标准答案评价这些回答。反思模块归纳成功与失败的原因，提出对规则集合的添加、删除或修改，最后处理批内提案的重复与冲突并更新 E。验证集用于选择规则版本，测试集则使用固定规则，不能把测试答案用于生成规则。流程依据原文 PDF 第 3–5 页、图 2 及式 (4)–(10)；作者公开代码中的部分正确组筛选进一步限定了真正用于更新的样本。

训练数据与候选回答 $\longrightarrow$ 正误反馈与反思 $\longrightarrow$ 规则编辑与合并 $\longrightarrow$ 冻结后的元记忆 E $\longrightarrow$ 新问题的事实利用

可见，训练阶段需要标准答案及多轮模型调用，但推理阶段不能看到标准答案；“不修改基础权重”不等于“训练过程没有代价”。

6.3 实验设计及原论文证据

论文的主要数据集为 LongMemEval，共 500 道问题。附录采用五折，每折 350 题训练、50 题验证、100 题测试；生成模型包括 Qwen3-30B-A3B-Instruct 与 Llama3.1-70B-Instruct，主要以 LightMem 作为事实记忆基座，默认评价模型为 Qwen3-235B-A22B（原文 PDF 第 5、11 页，§4 与附录 A.3、A.5）。训练时每题多次采样，默认 5 个 epoch、每批 50 题、每题采样 5 次，不能把这些学习成本忽略。

表 6 原论文 LongMemEval 主表的平均值（%，原文 PDF 第 6 页，表 1）

生成模型	LightMem	MetaMem	增量（百分点）
Qwen3-30B-A3B-Instruct	67.50	71.90	+4.40
Llama3.1-70B-Instruct	66.17	69.08	+2.91

两组实验中整体指标均提高，但增幅并不相同，不能把相对百分比误写为百分点，也不能推出所有问题类型都改善。消融实验（原文 PDF 第 7 页，表 2）中，Qwen 设置下完整方法为 71.90，去除反思为 70.02，去除规则演化为 68.33，支持两个环节在该设置下都有贡献。不同模型与不同检索系统的分数不能不经控制直接比较。

6.4 优缺点与适用范围

优点。该方法将“有没有找回事实”和“找回后能否正确使用”明确区分；元记忆以自然语言形式保存，可检查、合并与迁移，不需要修改基础模型权重；主实验和消融提供了改善证据。对存在时间关系、计数、跨事件引用的记忆问答，因而有可检验的研究切入点。

局限。规则学习依赖带答案样本与评价模型，错误评判可能污染更新；反复采样、反思和编辑带来额外成本；规则过度泛化、冲突或积累过长可能适得其反。若关键事实本身未检索到，元记忆也无法凭空补回证据。论文原模型规模和完整五折设置不代表小模型或小样本下可复现相同收益（原文 PDF 第 9、11–12 页及本组既有代码核查）。

6.5 与本组其他论文及课程设计的联系

StructMem 侧重**事实和关系怎样组织并被检索**，MetaMem 侧重**检索结果怎样被用于回答**。二者关注的错误位置不同，不能把 MetaMem 的规则学习直接当成 StructMem 的事件综合模块。本组可用已有的 MetaMem 小规模个人试点辅助解释“检索缺失”与“证据利用错误”，但它与本次 StructMem/LoCoMo 基线采用不同数据、模型和评分口径，不能直接混合成绩。当前课程设计以 StructMem 为拟定主线，MetaMem 在此主要承担相关工作与错误分析参考；这一选择属于本组方案，不是论文结论。

7 Text2Mem：记忆操作的统一表达与状态验证

Text2Mem 面向自然语言驱动的记忆控制，提出统一操作语言及其基准[6]。本文关注的问题是：用户要求更新、合并或调整记忆时，系统能否明确表达目标范围与参数，并验证执行后是否得到预期状态。以下页码均为仓库原论文 PDF 页码，区别于出版物页码 2105–2119。本文整理作者的方法与实验，并给出阅读分析；本组未运行 Text2Mem 模型实验。

7.1 研究问题与适用范围

长期交互不仅需要检索历史信息，还需要控制记忆的优先级、有效期、合并和删除。例如，“暂时不要再提午餐”可能意味着降低显著性，也可能被误解为删除记录。如果动作、范围与时间未被明确表达，系统即使调用成功，也可能改变错误的记忆。论文因此在自然语言与具体后端之间引入结构化操作规范，而不是提出新的向量检索算法（原文第 1–3 页，图 1）。

与直接生成 SQL 相比，中间规范用记忆生命周期操作表达意图，再由后端实现其语义。它为不同后端提供共同描述的方向，但不能把架构中的适配能力写成跨后端性能已得到充分验证；作者主实验明确限定为 SQL/SQLite 参考环境（第 5、7 页，§3.3、§4.3）。

7.2 操作集合、Schema 与执行流程

十二个操作。论文将操作分为编码、存储和检索三阶段。编码阶段仅有 Encode；存储阶段包括 Update、Label、Promote、Demote、Merge、Split、Delete、Lock、Expire 九个操作；检索阶段包含 Retrieve、Summarize。Encode 组织内容、语义、来源与治理属性，向量生成可以延迟，不能简单等同于计算嵌入。Promote 与 Demote 调整显著性，Demote 可以归档而不删除；Delete 处理软/硬删除，Expire 设置到期规则，三者具有不同语义（第 4 页表 1，第 11 页附录 A）。

五字段契约。操作由 `stage`、`op`、`target`、`args`、`meta` 描述，分别对应阶段、动作、目标、专属参数和执行上下文。不同操作的必填条件不同，例如 Encode 创建新记忆时不必先选择已有目标。对于需要定位已有条目的操作，`target` 在 `ids`、`filter`、`search`、`all` 四种选择方式中择一；跨字段约束限制锁定、到期和大范围写入等行为（第 4–5 页，§3.2）。

Validator–Parser–Adapter。Validator 检查结构完整性与跨字段约束；Parser 把合法实例转换为类型化操作，归一化时间和优先级等参数；Adapter 再映射为具体后端动作。执行返回 `ExecutionResult`，记录受影响条目和状态变化。多步骤请求可表示为保留依赖顺序的 `schema_list`（第 3 页图 2、第 5–7 页 §3.3–4.1 及图 3）。这个流程能

检查格式和部分治理约束，但不能只靠合法 JSON 证明模型选对了目标或正确理解用户意图。

教学案例：提高课设进度记忆的优先级。参照附录 B.1.1 的 OKR 示例，构造请求“提高本周课设进度笔记的重要性，其他记录不变”。在目标 ID 已明确的简化情况下，可用 STO 阶段的 Promote，目标为 `ids=[17]`，参数为 `weight=0.9`。这只是未执行的教学实例，不是本组实验。检查应同时覆盖：条目 17 的权重是否达到要求、其内容是否未被误改、其他条目是否保持不变。仅返回执行成功，不能回答后两项；若目标选择阶段就选错条目，格式合法的操作仍可能产生错误结果（第 12 页附录 B.1.1；后两项为本文的检查建议）。

7.3 基准、指标与主要结果

基准以自然语言指令、前置操作建立的初态、参考 Schema 与 SQL 状态断言组成评测实例，区分中英文、直接/间接指令和单操作/工作流。作者比较 GPT-4o、Qwen2.5-72B-Instruct、Claude-4-Sonnet、Gemini-2.5-Pro 与 GPT-5，并给出相同自然语言指令与提示模板下的结果（第 6–8 页，§4）。本节不补写正文未明确给出的样本总数，也不把模型比较当作组件移除消融。

三个指标需要分开解释：SMA 用编辑距离或余弦相似度衡量生成 Schema 与参考的相似程度；ESR 统计能通过验证并无运行错误地执行的比例；EMR 衡量满足的 SQL 状态断言占全部期望断言的比例。因而 EMR 既不是问答准确率，也不是整条任务全部断言通过的比例（第 7–8 页，§4.1、§4.3）：

$$\mathrm{EMR} = \frac{\sum_i \sum_{a \in A_i} \mathbf{1}[a\text{满足}]}{\sum_i |A_i|}. \tag{8}$$

其中 A_i 为第 i 个实例的断言集合；任务所含断言数可能不同，不能把 ESR 与 EMR 的差值解释为失败任务比例。

表 7 Text2Mem 作者报告的总体指标，原文第 8 页表 2 的 Avg 列

模型	$\mathrm{SMA}_{\mathrm{lev}}$	$\mathrm{SMA}_{\mathrm{cos}}$	ESR	EMR
GPT-4o	0.6776	0.8690	0.9484	0.2532
Qwen2.5-72B-Instruct	0.6195	0.8349	0.9510	0.2535
Claude-4-Sonnet	0.6230	0.8475	0.9594	0.3132
Gemini-2.5-Pro	0.6491	0.8560	0.9479	0.2897
GPT-5	0.6115	0.8396	0.9662	0.2826

表7保留原表 Avg 值，不自行重算为十二种操作的简单均值。总体 ESR 约为 94.79%–96.62%，而 EMR 约为 25.32%–31.32%。可执行性较高与状态效果较弱可以同时发生，最高 ESR 和最高 EMR 也不对应同一模型。两类指标衡量不同对象，不能直接据此断言校验器降低了多少语义错误。

复杂存储与工作流值得进一步分析。原表 2 中五个模型的 Split EMR 均为 0；Merge 仅 GPT-4o 为 0.0465，其余为 0。原表 3 中 GPT-5 的单操作 EMR 为 0.2930，工作流 EMR 为 0.1190，而工作流 ESR 为 1.0000。这些数字支持“运行成功不保证效果正确”的观察，但只适用于该基准设置，不能扩展为模型在任何条件下都无法合并或拆分。

论文未报告独立移除 Validator、Parser 或 Adapter 的组件消融。表 2 是模型/操作比较，表 3 是任务分组分析；附录 F 对指令类型现象提出的复杂度混杂与幸存者偏差解释仍是假设，不能作为控制实验确立的因果结论（第 8、15 页）。

7.4 优缺点与阅读判断

可借鉴之处。统一规范使动作、作用范围与生命周期参数显式化，便于在执行前检查并在执行后追踪；规划与状态效果分开计量，避免用格式正确或无异常返回替代语义验收。对长上下文系统而言，这为定位“检索错目标”“计划错动作”和“后端执行错误”提供了不同检查位置。后者是阅读分析，不是作者证明的误差分解定理。

适用边界与不足。作者明确指出复杂记忆语义缺少正式保证、真实后端覆盖有限，以及未评测端到端长期智能体表现（第 9 页 Limitations）。此外，本文认为断言设计会影响 EMR 的解释力：若只检查权重提高，可能遗漏非目

标条目被误改的问题。基准中的单步与工作流结果也不能单独证明迁移到真实个人记忆后仍有同等效果。论文提供了可审计基础，但实际适配成本、长期任务收益及错误传播仍需额外验证。

7.5 与其他论文及本组课设的联系

StructMem 关注事件绑定、综合和问答检索；Text2Mem 关注动作规范与执行后的状态核验。Semantic XPath 可帮助理解目标范围的定位，MetaMem 提醒我们区分已取回证据与正确使用证据，Text2Mem 则提醒我们区分可运行操作与正确状态效果。这是机制联系的阅读比较，不代表相关系统可以不经适配直接拼接，也不能用不同基准的分数比较优劣。

本组主线仍是 StructMem，未实现 Text2Mem 的十二操作后端。A 任务已完成的输入字段白名单、版本哈希和答案隔离，是数据准备与校验工作，不能改称 Text2Mem 复现。可在团队讨论中借鉴“显式输入契约与效果分别检查”的原则；若未来开展操作实验，应固定相同初态、请求和模型，分别报告格式、执行、断言满足和整任务通过情况。此处仅提出讨论方向，不新增小组必做任务，也不预设优化收益。

8 跨论文的系统性比较与讨论

待各成员完成个人论文章节后，再由全组共同讨论和整理。现有综合分析草稿暂不编入主稿。

9 总结

待填写：共同认识、适用条件、局限和对课设的启发。

References:

[1] Xu B, Chen Y, Fang J, et al. StructMem: Structured memory for long-horizon behavior in LLMs. In: Proceedings of Liakata M, Moreira V P, Zhang J, et al., editors, Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers), San Diego, California, United States: Association for Computational Linguistics, 2026. 122–146

[2] Latimer C, Boschi N, Neeser A, et al. Hindsight: Structured agent memory that retains, recalls, and reflects. In: Proceedings of Durrett G, Jian P, editors, Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 3: System Demonstrations), San Diego, California, United States: Association for Computational Linguistics, 2026. 275–285

[3] Liu Y S, Wu R, Gallagher L, et al. Semantic XPath: Structured agentic memory access for conversational AI. In: Proceedings of Durrett G, Jian P, editors, Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 3: System Demonstrations), San Diego, California, United States: Association for Computational Linguistics, 2026. 286–296

[4] Zhu S, WU W, Zhou K, et al. Hybrid self-evolving structured memory for computer-use agents. In: Proceedings of Liakata M, Moreira V P, Zhang J, et al., editors, Findings of the Association for Computational Linguistics: ACL 2026, San Diego, California, United States: Association for Computational Linguistics, 2026. 11287–11304

[5] Xin H, Li X, Liu Z, et al. MetaMem: Evolving meta-memory for knowledge utilization through self-reflective symbolic optimization. In: Proceedings of Liakata M, Moreira V P, Zhang J, et al., editors, Findings of the Association for Computational Linguistics: ACL 2026, San Diego, California, United States: Association for Computational Linguistics, 2026. 5473–5492

[6] Wang L, Yang L, Chen B, et al. Text2Mem: A unified memory operation language for memory operating system. In: Proceedings of Liakata M, Moreira V P, Zhang J, et al., editors, Findings of the Association for Computational Linguistics: ACL 2026, San Diego, California, United States: Association for Computational Linguistics, 2026. 2105–2119

成员分工与贡献

待填写：六位成员姓名、负责论文、报告章节、PPT 与讲解工作及实际贡献百分比，总和为 100%。