Semantic XPath 结构化记忆访问方法阅读报告

oioioi-521

(天津大学 NLP 第 8 队)

摘　要:Semantic XPath 将对话任务记忆组织为树，结合路径、位置选择与连续语义评分访问相关节点和子树。本报告梳理数据模型、查询执行与证据聚合，核对作者单轮、多轮与 LoCoMo 结果，区分任务通过率、回答得分和 token 口径。该方法改善相对扁平检索的效果及相对全量上下文的输入规模，但准确性取决于模型和任务。本报告进一步讨论层级依赖、证据完整性、元数据过滤基线及与本组课设的联系。

关键词: 结构化记忆；对话智能体；Semantic XPath；语义检索；论文阅读
中图法分类号: TP18

A Reading Report on Semantic XPath for Structured Conversational Memory Access

oioioi-521

(NLP Team 8, Tianjin University)

1　Semantic XPath

本节由 `oioioi-521` 负责，依据既有个人阅读报告、13 页演示稿及讲稿整理。原文为 Liu 等人的 Semantic XPath[1]，见 https://aclanthology.org/2026.acl-demo.28/。下述页码均为原论文 PDF 页码（共 11 页，印刷页 286–296）。所有实验数字属于作者结果；本组没有进行 Semantic XPath 的端到端复现。

1.1　研究问题与方法定位

长期任务导向对话需要反复查看、修改和回溯同一个任务对象。旅行计划中的一项活动不仅包含文本，还属于特定日期、行程与历史版本。全量上下文保留信息较多，但输入量随历史增长；扁平检索降低输入量，却可能取回语义相似而所属范围错误的条目。比如 “在会议安排最密集的一天增加咖啡休息”，需要比较各天的活动，而不仅是找一条包含会议内容的文本（PDF 第 1–2 页，图 1–2）。

Semantic XPath 将已有的结构化记忆组织为树，用 XPath 风格的路径、位置条件和连续语义评分定位相关节点及子树，再交给下游模型回答或更新。研究重点是**记忆访问**：查询负责定位，实际插入、删除及版本维护由下游步骤处理。论文不能被解读为已经解决通用记忆构建、全部冲突消解或任意图关系推理。

1.2　树形数据模型与查询语法

记忆表示为有根树 $T = (V, E, r)$。非根节点只有一个父节点，节点具有类型和文本属性；模式 Σ 由记忆数据已有的节点类型、属性和父子关系决定，而非要求人工预先设计一个通用模式。旅行示例采用

$$\text{Itinerary} \rightarrow \text{Version} \rightarrow \text{Day} \rightarrow \text{POI},$$

分别表示计划、版本、日期和活动；层级主要是组成关系，不只是对下层文本做有损摘要（PDF 第 3 页，§3.1）。

查询是步骤序列，每一步写为 $S = A\,N\,[R]\,[P]$：路径与类型必需，位置选择器和语义条件可选（PDF 第 3–4 页，§3.2）。

表 1 Semantic XPath 查询步骤的组成；依据原文 §3.2

组成	示例写法	作用
路径 A	`/`、`//`	访问直接子节点或全部后代
类型 N	`Day`、`POI`、`*`	按节点类型筛选或匹配任意类型
位置 R	`[i]`、`[-i]`、`[i:j]`	按顺序、倒序或区间选取候选
语义 P	`[node~="workshop"]`	计算候选与语义条件的相关程度

例如 `//Day[3]/POI[node~="workshop"]` 先选第三个匹配日期，再对该日期下的活动进行语义评分。若同时存在多个行程或版本，必须先限定目标范围；第三个匹配日期不能自动当作当前版本的第三天。语义条件 $1-P$ 提高原条件低分候选的优先级，它是软评分操作，不等同于已经执行删除。

1.3 语义评分与带权执行

原文附录 A 定义 $\mathrm{Rel}(u,P)\in[0,1]$。局部评分依据一个属性或完整节点表示；聚合评分先在当前节点下执行内部结构查询，再用平均、最小、最大或几何平均聚合证据；多个条件还可用乘积、平均及取反组合（PDF 第 10 页）。

```
//Day[avg(/POI[node~="conference"])]
```

这个查询根据活动证据评价日期。原文第二天的三个活动分数为 0.603、0.482、0.608，平均约 0.565；与其他日期比较后选中第二天。该平均值刻画会议相关性的密集程度，不能直接解释为会议数量最多（PDF 第 4 页，§3.3、图 2）。

执行器从根节点及权重 1 出发，维护带权集合 $W\subseteq V\times[0,1]$，按步骤进行路径扩展、类型筛选、位置选择与语义评价。语义步骤更新为

$$w_{\text{new}} = w_{\text{old}}\,\mathrm{Rel}(u,P). \tag{1}$$

聚合条件递归访问下层证据。可执行的查询、正确的目标节点、足够完整的证据与正确的最终回答是不同层次；形式定义本身不统一规定所有场景的阈值、返回数量或空集处理。

1.4 教学案例与公平比较

沿用个人演示中的教学示例：假设只有一个当前版本，第 2 天有海滨公园，第 5 天有山地徒步，第 7 天有植物园和海港游船。用户要求找出“第 7 天下雨时需要调整的户外活动”。纯语义排序可能混入其他日期的活动；结构化访问先限定第 7 天，再评价活动语义，目标为植物园与游船。

这个例子用于解释范围约束，**没有运行真实检索，也不是论文实验数据**。带日期元数据过滤的扁平 RAG 同样可以解决简单日期约束，因此应作为公平比较基线；不能把简单过滤收益全部归因于复杂查询语言。

1.5 实验设置与指标口径

作者评估旅行行程、待办清单和家庭配餐三个自建场景，每场景 20 个单轮对话、5 个多轮对话；另在 LoCoMo 中使用原生的 Memory–Conversation–Session–Turn 层级。回答模型为 GPT-5 mini 与 Gemini 3 Flash。相似度评分器（Sem）和 Flat RAG 使用 Qwen3-Embedding-8B；蕴含评分器（Entail）使用 `facebook/bart-large-mnli`（PDF 第 5 页，§4.1）。

自建场景的通过率要求检索到正确结构化数据，且输出满足任务约束；LoCoMo 则是模型裁判与参考答案对照的回答得分。后者不是人工金标准，两类指标不能直接混比。表 1 明确报告平均**输入** tokens，XPath 包含查询生成输入；附录表 2、表 3 仅称平均 token 用量，没有同样完整交代各组成。跨提供方的分词器也不同，宜在同一模型内比较。token 不能代表嵌入、蕴含评分及查询执行的全部计算成本。

表 2 作者单轮结果节选；原文 PDF 第 11 页、表 2，三个自建场景平均

回答模型	方法	通过率（%）	平均 tokens
GPT-5 mini	In-context	70.0	26 216
	Flat RAG	30.0	3 250
	XPath Sem	66.3	6 166
	XPath Entail	83.0	5 691
Gemini 3 Flash	In-context	79.0	25 387
	Flat RAG	37.7	3 361
	XPath Sem	64.3	6 043
	XPath Entail	70.7	5 830

单轮 GPT-5 mini 的 Entail 相对 Flat RAG 提高 $83.0 - 30.0 = 53.0$ 个百分点，相对增幅约 176.7%；其 token 用量为全量上下文的 $5691/26216 \approx 21.7\%$。但 Gemini 的 In-context 为 79.0%，高于 Entail 的 70.7%，因此不能声称所有模型下准确性均最高。

表 3 作者多轮结果节选；原文 PDF 第 11 页、表 3，三个自建场景平均

回答模型	方法	通过率（%）	平均 tokens
GPT-5 mini	In-context	80.0	69 097
	Flat RAG	26.7	3 327
	XPath Sem	70.0	6 294
	XPath Entail	83.3	5 850
Gemini 3 Flash	In-context	56.7	76 603
	Flat RAG	26.7	3 240
	XPath Sem	76.7	6 092
	XPath Entail	80.0	5 993

多轮 Entail 在两种模型下取得最高平均通过率，token 约为全量上下文的 8.5% 与 7.8%。Sem 与 Entail 的平均差异提供评分器比较，但不保证每个子场景都改善。单轮和多轮请求不同，不能将两张表当作同批样本的退化曲线。摘要中的 9.1% 是作者概括；不能把它与单轮 176.7% 相对提升拼接为同一设置下的结论。

表 4 作者 LoCoMo 结果；原文 PDF 第 7 页、表 1，XPath 输入含查询生成

回答模型	方法	回答得分	平均输入 tokens
GPT-5 mini	In-context	74.55	24 857
	Flat RAG	35.71	1 341
	Semantic XPath	65.19	3 032
Gemini 3 Flash	In-context	87.01	27 499
	Flat RAG	41.49	1 996
	Semantic XPath	73.25	3 870

LoCoMo 上 XPath 的总体得分处于两种基线之间，输入分别约为全量上下文的 12.2% 与 14.1%。这说明已有会话层级可用于访问，但准确性仍有损失。例如 GPT-5 mini 多跳题得分为 43.26，低于全量上下文 58.87，证据整合仍有差距。作者的失败分析将错误分为查询生成、检索和回答生成，认为检索是主要剩余来源，包括无命中、证据不全及选错节点或发言（PDF 第 6–7 页，§4.3、图 8）。

1.6 优缺点与本组课设的联系

方法的优势是将结构范围与连续语义判断组合，并用路径与评分轨迹解释结果；下层证据可以评价上层对象，访问粒度不必固定为独立片段。其前提是有可用且可靠的层级。跨树关系、版本范围模糊、复杂多跳和不完整证据仍需检验；小规模自建任务、缺少充分重复实验和置信区间、未覆盖本地评分开销等，也限制了对泛化和成本的判断。这些属于本节阅读评价，不作为已验证的改进成果。

与 StructMem 相比，Semantic XPath 强调**如何在已有层级中访问证据**，StructMem 强调事件绑定及跨事件综合；二者表示、模型、任务与预算不同，不按原论文分数直接排名。HyMEM 的图邻居与动态更新、Text2Mem 的操作规范可以作为比较维度，但本节不推定已完成模块组合或形成全组共识。

本人课设技术分工 C 已经完成 91 个 session 的事件抽取与交接，具体实现和验收另见 C 结项记录[1]；它不是 Semantic XPath 复现。对后续设计可提出三项待验证建议：明确日期/版本等硬范围；输出可追溯的节点与证据标识；分别检查范围、节点、证据完整性及回答错误，并与元数据过滤基线比较。

References:

[1] Liu Y S, Wu R, Gallagher L, et al. Semantic XPath: Structured agentic memory access for conversational AI. In: Proceedings of Durrett G, Jian P, editors, Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 3: System Demonstrations), San Diego, California, United States: Association for Computational Linguistics, 2026. 286–296

1 https://github.com/YaoYang-123456/NLP-2026-Team08-Structured-Memory/issues/32