专题论文阅读

Hindsight

结构化智能体记忆：保留、召回与反思

李金昊

长对话中的信息保留与使用

智能体需要保留信息、跨会话找回它，并据此给出连贯回答。

- 历史不断增长，相关信息可能分散在不同会话。
- 用户陈述的事实与智能体形成的判断容易混在一起。
- 只取相似片段，回答可能局部合理、整体矛盾。

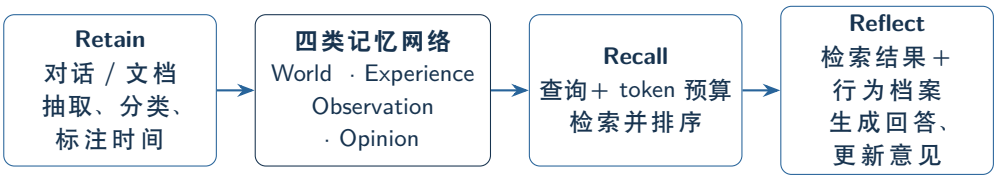
Hindsight 把写入、检索和推理分成可检查的操作。

四类网络把事实、摘要和意见分开

网络	记忆类型	例子或用途
World	外部世界事实	Alice 在 Google 的 Mountain View 团队工作。
Experience	智能体自己的经历	智能体曾向 Alice 推荐徒步旅行。
Observation	从事实归纳的实体摘要	Alice 是专长于机器学习的软件工程师。
Opinion	有置信度的主观判断	“Python 适合数据科学”；置信度随证据更新。

Observation 是证据摘要；Opinion 是带置信度的判断。

写入、检索与反思



TEMPR 负责写入和检索；CARA 负责反思，并依据新证据更新意见。

四路检索与融合排序

{向量，关键词，图遍历，时间过滤} ⟶ RRF ⟶ 重排与预算裁剪

通道	找什么
向量相似度	语义相近的记忆；使用 HNSW 索引。
BM25	关键词或实体名称；使用 PostgreSQL 全文检索。
图遍历	沿实体、时间、因果关系扩展，通常限制在 2–3 跳。
时间过滤	按问题中的日期或时间区间匹配事件。

RRF 合并各通道排序，cross-encoder 再重排；token 预算限制返回上下文。

Reflect 让意见随证据变化

行为档案

- 怀疑程度、字面倾向、共情程度
- 每项取值 1–5，用于调节回答倾向
- Opinion 保存置信度和支持证据

论文中的三会话示例

- 用户开始用 Rust 改造支付服务。
- 之后询问下一季度应重点做什么。
- 后来表示 Rust 难维护、更怀念 Go。

新证据削弱先前的偏好判断；相关世界事实仍保留。

长期对话问答结果

LongMemEval S，准确率（%）

Full-context GPT-4o	60.2
Hindsight OSS-20B	83.6
Hindsight OSS-120B	89.0
Hindsight Gemini-3	91.4
Supermemory Gemini-3	85.2

LoCoMo，准确率（%）

Zep	75.1
Memobase	75.8
Hindsight OSS-20B	83.2
Hindsight OSS-120B	85.7
Hindsight Gemini-3	89.6
Backboard	90.0

20B 在 LongMemEval 比全文 GPT-4o 高 23.4 个百分点。

LongMemEval S 共 500 题；表中各系统使用的模型配置不同。

系统局限与评测范围

系统局限

- 抽取与实体消歧依赖 LLM，错误可能传播。
- 只评测英文数据；Opinion 置信度未做正式用户验证。
- 持续保存个人信息，且无内置 PII 自动脱敏。

评测记录的缺口

- 完整评估指向另一篇工作，本文引用编号仍是占位符。
- 正文与附录的部分类别基线数值不一致。

对课设的启发

- 分开事实、经历、实体摘要和意见，检查来源与置信度。
- 在固定 token 预算下，比较语义检索与时间 / 实体关联。
- 用消融区分各通道收益，并同步记录准确率、噪声和成本。

按记忆类型和检索通道设计对照，观察准确率与成本变化。