天津大学 NLP　第 8 队

长上下文场景结构化记忆建模

六篇论文阅读与系统性比较

组织、访问、更新、利用与操作验证

长历史的困难不只有长度

一段历史能够被保存，不等于后续任务就能正确使用它。

环节	需要回答的问题
组织	人物、事件、时间和来源关系是否保留下来？
访问	找到的是相关证据，还是相似但范围错误的片段？
更新与利用	新旧状态如何区分，已取回的证据如何解释？
操作验证	改了哪条记忆，执行后的状态是否符合意图？

阅读范围：六篇原论文；下列问题为综述整理

先建立论文依据，再比较机制与边界

环节	内容	计划时间
开场	共同问题与阅读范围	2 分钟
六篇论文	StructMem、Hindsight、Semantic XPath HyMEM、MetaMem、Text2Mem	每人约 8 分钟
系统性总结	统一比较、共同案例、实验边界与课设选择	10 分钟

$2 + 6\times8 + 10 = 60$ 分钟

不同任务的原文分数不直接排名；论文结果、阅读分析和本组实验分别说明。

时间为讲解计划；实际时长以本人排练与录制为准

专题论文阅读

StructMem

面向长程对话的结构化记忆

hycx233

7–9 分钟

长程对话中的证据组织

问题：Caroline 和 Melanie 什么时候一起参加过 Pride festival？

2023 年 8 月的回忆	两人在交流中提到去年的活动经历，以及与朋友共同参与的记忆。
回答需要的证据	将人物互动与活动经历关联起来，并由来源时间把“去年”换算为 2022 年。

三种组织方式

方法	保存形式	需要处理的问题
平面记忆	独立条目＋向量	检索后补齐分散的事件语境
图记忆	实体、关系与图结构	实体消歧、关系去重与维护
StructMem	时间绑定的条目＋整合摘要	在写入时组织相关事件

关键词相似能找到相关片段，完整回答还需要人物、事件与时间之间的联系。

原文 §1–2；附录 A.8，表 8，p.132。案例证据简化为中文

StructMem 的两层记忆



记忆层次	保存内容	回答时的作用
事件级记忆	事实、互动关系、来源时间	提供可核对的具体细节
跨事件记忆	当前事件与相关历史的整合摘要	提供跨越多次交流的联系

两层共同保留。核心流程由提示调用与向量检索组成，无需训练新的语言模型。

原文图 2、§3，pp.123–124；流程据原文重绘

双视角抽取与时间锚定

对话示例：Alice 分享研究生录取和机器学习方向，Bob 祝贺她、询问计划并表达支持。

事实视角 Φ_i	Alice 被研究生项目录取，计划研究机器学习。
关系视角 Ψ_i	Bob 为 Alice 感到高兴，支持她的选择并关注研究计划。

$$\text{记忆条目} = \langle x, e_x, \tau_i \rangle, \qquad x \in \Phi_i \cup \Psi_i$$

x：自然语言内容　e_x：检索向量　τ_i：来源话语时间

时间示例：2023 年 8 月说“去年参加过活动”。
来源时间保留为 2023 年 8 月，回答时将事件年份换算为**2022 年**。

抽取结果附带 source_id；事件重建按相同来源时间聚合事实与关系条目。

原文 §3.1，式 (1)–(2)；图 4–7、13，pp.133–136、139

历史检索与跨事件整合

1. **积累当前事件**：条目按对话时间排序，以 1 小时窗口触发整合。
2. **检索历史种子**：拼接缓存文本并编码，按余弦相似度取 top-15。
3. **恢复事件语境**：取回每个种子同时间锚的其他事实与关系条目。
4. **生成整合摘要**：当前缓存与恢复后的历史事件共同进入整合模型。

$$E_\tau(x^*) = \{x' \in M \mid \tau(x') = \tau(x^*)\}$$

摘要要求：200–350 个英文词，保留人物、具体时间和行动，组织有依据的事件联系。

关键区别：15 是历史种子数，展开后的上下文可能包含更多条目。

1 小时指对话时间窗口。整合摘要与事件条目共同保留。

原文 §3.2，式 (3)–(5)；A.3；图 8，pp.124、129、137

回答阶段的证据组合

检索内容	提供的信息	回答中的用途
60 条事件记忆	具体事实、人物互动、来源时间	核对人物身份与细节
5 条整合摘要	已整理的相关历史与事件联系	联合多段证据

回答提示中的处理规则

- 同时检查两位说话人的记忆，区分说话人与记忆中提到的人物。
- 依据来源日期换算“去年”“两个月前”等时间表达。
- 信息冲突时优先较新的记忆，最终输出简短、具体的答案。

构建阶段的 15 条种子与回答阶段的 60 + 5 分别控制不同环节。

原文 A.3；图 13，pp.129、139；案例参考表 8，p.132

实验设置与比较范围

LoCoMo 长期对话问答

10 段对话，平均 588 轮、16,618 Token。

任务	数量	需要的能力
单跳	841	定位单一事实
多跳	282	连接多条证据
时间	321	推理时间关系
开放域	96	对话结合背景知识
合计	1,540	单跳占 54.6%

模型与指标

生成：gpt-4o-mini
向量：text-embedding-3-small

正确率：LLM 评判回答
构建成本：Token、调用数、耗时

主要对比：全文上下文、RAG、图记忆及长期记忆系统。

读表方式：总分结合分类结果看；检索预算各异，主表反映整套系统表现。

原文 §4.1；A.2–A.4、表 3，pp.125、128–129

总分提升与能力差异

方法	总分	单跳	多跳	时间	开放域
FullContext	73.83	**86.56**	68.79	50.16	56.25
Zep	75.14	79.79	**74.11**	67.71	**66.04**
Memobase	75.78	77.17	70.92	**85.05**	46.88
StructMem	**76.82**	81.09	68.77	81.62	46.88

主要收益

总分比 Memobase 高**1.04**。

相对 FullContext，时间推理提高**31.46**，总分提高 2.99。

能力取舍

相对 FullContext，单跳下降 5.47，多跳接近。

Zep 多跳、开放域更高；Memobase 时间任务更高。

时间相关任务受益明显；跨事件整合的具体作用，需要进一步看组件消融。

原文表 1，p.125。粗体为所列方法中最高值；差值单位为百分点

构建成本与运行时间

完整实验的构建统计

方法	Token(M)	调用数	时间 (s)
MiniRAG	10.103	2,508	2,566
StructMem	1.937	1,056	22,854
Mem0g	35.825	53,514	115,670

相对 Mem0g：Token 减少94.6%，调用减少98.0%，耗时减少 80.2%。

同框架，首段对话

平面记忆	77.6k
StructMem	226.1k
图记忆	402.3k

StructMem 约为平面记忆的 2.91 倍，比图记忆少 43.8%。

成本来自哪里：双视角抽取和摘要增加调用；批量整合减少图维护的多阶段开销。

MiniRAG 运行更快。调用量、Token 消耗与墙钟时间需要分别评价。

原文表 1、图 3(b)，pp.125–126。M 为百万 Token，k 为千 Token

跨事件整合的消融结果

配置	单跳	多跳	时间	开放域
Flat Memory	78.83	66.31	78.50	46.88
Graph Memory	80.50	66.67	76.64	48.96
去掉跨事件整合	80.86	66.31	79.44	46.88
StructMem	81.09	68.77	81.62	46.88
整合带来的变化	+0.23	**+2.46**	**+2.18**	0.00

进一步实验可分别去掉关系抽取和时间锚定，定位每个设计的贡献。

结果解释

多跳与时间任务需要联合分散证据，受益更大。

单跳变化较小，开放域未改善。

符合整合摘要以连接对话证据为主的功能。

原文表 2，p.125。最后一行为加入跨事件整合后的百分点变化

记忆内容的忠实性

事件条目：三个评判模型报告的平均幻觉率为**2.36%**。

整合约束：引用历史时标注具体时间，保留人物和行动细节，建立具体、有依据的联系。

评判模型	有约束的错误关联率	移除约束后
GPT	0.61%	7.45%
Qwen	3.41%	20.00%
DeepSeek	3.63%	15.14%

观察：三个评判模型均报告错误关联增加，提示中保留时间与具体联系有实际作用。

条目幻觉与摘要关联采用不同统计单位；这些数值来自模型审核。

原文图 8、表 6–7，pp.130–131、137。错误关联率由模型分别评判

阅读结论与后续问题

方法贡献

事实与互动关系共同保存，时间锚支持事件重建，跨事件摘要组织相关历史。

实验支持

总分 76.82%；整合模块主要改善多跳与时间任务；相对图记忆降低构建开销。

值得继续研究的问题

计划或关系发生变化后，旧条目与摘要怎样同步更新？

可用带时间变更的对话，比较仅优先新记忆与显式修订的回答质量、来源可追溯性。

我的理解：记忆写入时的组织方式，会直接影响之后的证据联合。

论文：https://aclanthology.org/2026.acl-short.12/

代码：https://github.com/zjunlp/LightMem/blob/main/StructMem.md

原文 §3–5、Limitations；末项为阅读后提出的实验方向

专题论文阅读

Hindsight

结构化智能体记忆：保留、召回与反思

李金昊

7–9 分钟

问题：长对话中的记忆不只是“存下来”

智能体需要保留信息、跨会话找回它，并据此给出连贯回答。

- 历史不断增长，相关信息可能分散在不同会话。
- 用户陈述的事实与智能体形成的判断容易混在一起。
- 只取相似片段，回答可能局部合理、整体矛盾。

Hindsight 把写入、检索和推理分成可检查的操作。

Hindsight, §1；PDF p.1（印刷页 275）

四类网络把事实、摘要和意见分开

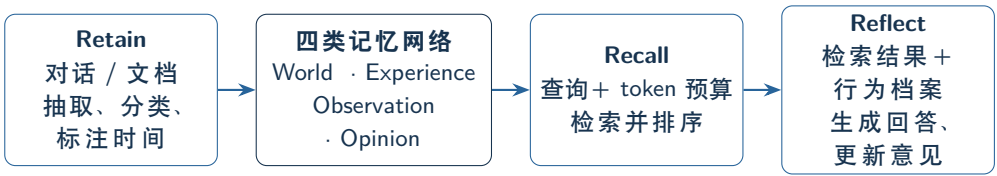
网络	记忆类型	例子或用途
World	外部世界事实	Alice 在 Google 的 Mountain View 团队工作。
Experience	智能体自己的经历	智能体曾向 Alice 推荐徒步旅行。
Observation	从事实归纳的实体摘要	Alice 是专长于机器学习的软件工程师。
Opinion	有置信度的主观判断	“Python 适合数据科学”；置信度随证据更新。

Observation 是证据摘要；Opinion 是带置信度的判断。

四类网络让开发者能检查智能体“知道什么”与“相信什么”。

Hindsight, §3.1；PDF pp.2–3，表 1

三种操作组成记忆生命周期



TEMPR 负责 retain / recall；CARA 负责 reflect。Reflect 的新证据可触发 Opinion 更新。

Hindsight, §3.2–3.3、图 1；PDF pp.3–4（印刷页 277–278）

Recall 将四种检索并行，再融合排序

{向量，关键词，图遍历，时间过滤} ⟶ RRF ⟶ 重排与预算裁剪

通道	找什么
向量相似度	语义相近的记忆；使用 HNSW 索引。
BM25	关键词或实体名称；使用 PostgreSQL 全文检索。
图遍历	沿实体、时间、因果关系扩展，通常限制在 2–3 跳。
时间过滤	按问题中的日期或时间区间匹配事件。

RRF 合并各通道排序，cross-encoder 再重排；token 预算限制返回上下文。

Hindsight, §3.2、§4.1；PDF pp.3、5（印刷页 277、279）

Reflect 让意见随证据变化

行为档案

- 怀疑程度、字面倾向、共情程度
- 每项取值 1–5，用于调节回答倾向
- Opinion 保存置信度和支持证据

论文中的三会话示例

- 用户开始用 Rust 改造支付服务。
- 之后询问下一季度应重点做什么。
- 后来表示 Rust 难维护、更怀念 Go。

新证据削弱先前的偏好判断；相关世界事实仍保留。

这是论文的定性案例，不是独立用户研究。

Hindsight, §3.2–3.3、§6.4；PDF pp.3–4、7（印刷页 277–278、281）

作者报告的结果有提升，也有比较边界

LongMemEval S，准确率（%）

Full-context GPT-4o	60.2
Hindsight OSS-20B	83.6
Hindsight OSS-120B	89.0
Hindsight Gemini-3	91.4
Supermemory Gemini-3	85.2

LoCoMo，准确率（%）

Zep	75.1
Memobase	75.8
Hindsight OSS-20B	83.2
Hindsight OSS-120B	85.7
Hindsight Gemini-3	89.6
Backboard	90.0

20B 在 LongMemEval 比全文 GPT-4o 高 23.4 个百分点；表中也有更高的其他系统分数。

LongMemEval S 为 500 题；两项基准的模型和系统条件并非完全一致。

Hindsight, §6.1–6.3、表 2；PDF pp.6–7（印刷页 280–281）

局限与证据边界

系统局限

- 抽取与实体消歧依赖 LLM，错误可能传播。
- 只评测英文数据；Opinion 置信度未做正式用户验证。
- 持续保存个人信息，且无内置 PII 自动脱敏。

报告证据需谨慎读

- 完整评估指向另一篇工作，本文引用编号仍是占位符。
- 正文与附录的部分类别基线数值不一致。
- 本文提供的是系统演示与结果摘要，不是本组复现。

Hindsight, Limitations、Ethics；PDF p.8（印刷页 282），§6.2 及附录 D

对长上下文结构化记忆课设的启发

- 分开事实、经历、实体摘要和意见，检查来源与置信度。
- 在固定 token 预算下，比较语义检索与时间 / 实体关联。
- 用消融区分各通道收益，并同步记录准确率、噪声和成本。

可借鉴的是可检查的记忆类型与操作；迁移效果仍要用同一条件验证。

以上是个人阅读推导的实验问题，不是已经完成的本组实验或团队共识。

阅读启发：据 Hindsight, §3、§6；PDF pp.3–8

专题论文阅读

Semantic XPath

结构化记忆的路径与语义访问

oioioi-521

7–9 分钟

长期任务中的记忆访问

全量上下文

保留完整历史，但输入随交互增长。

扁平 RAG

返回相关片段，但日期和版本范围可能混淆。

贯穿案例

在会议安排最密集的一天增加咖啡休息。

需要比较各天的活动，而不只是找到一条会议相关文本。

研究问题：怎样访问相关的记忆子结构？

树形记忆与整体流程

计划 Itinerary ⟶ 版本 Version ⟶ 日期 Day ⟶ 活动 POI

1. 结合已有结构，把自然语言请求转成查询。
2. 执行结构匹配、位置筛选与语义评分。
3. 返回节点及子树，供下游回答或更新。

schema 来自已有记忆结构；查询负责定位，实际修改由下游步骤完成。

原文 PDF 第 2–4 页，图 2、§3.1–3.3；层级与流程按原文整理

查询语法与访问范围

$$S = A\,N[R]\,[P]$$

组成	写法	含义
路径 A	`/`、`//`	子节点或后代
类型 N	`Day` / `POI` / `*`	类型或任意节点
位置 R	`[i]` / `[-i]` / `[i:j]`	顺序、倒序或区间
语义 P	`[node~="workshop"]`	连续相关性评分

```
//Day[3]/POI[node~="workshop"]
```

多个行程或历史版本共存时，先限定目标范围；第三个匹配日期未必是当前计划第三天。

原文 PDF 第 3–4 页，§3.2；第 10 页，附录 A

语义评分与查询执行

```
//Day[avg(/POI[node~="conference"])]
```

执行阶段	候选与分数
初始化	根节点，权重为 1
路径与类型筛选	找到日期及其活动
第二天活动局部评分	0.603、0.482、0.608
日期聚合评分	$(0.603 + 0.482 + 0.608)/3 \approx 0.565$
与其他日期比较	选中第二天，再交给下游更新

$$w_{\text{new}} = w_{\text{old}} \times \mathrm{Rel}(u, P)$$

平均相关性反映密集程度，不直接等同于会议数量最多。

原文 PDF 第 4 页，§3.3、图 2；第 10 页，附录 A

旅行示例中的日期范围

用户：第七天下雨，找出当天需要调整的户外活动。

日期	活动	是否属于目标
第 2 天	海滨公园	否，日期不符
第 5 天	山地徒步	否，日期不符
第 7 天	植物园、海港游船	是

先限定第七天，再判断活动语义。

普通 RAG 加入日期元数据过滤也能改善简单范围错误，应纳入公平比较。

实验设置与指标口径

旅行、待办、配餐：每场景 20 个单轮和 5 个多轮对话，另测 LoCoMo。

指标或模型	含义与口径
任务通过率	检索正确，且输出满足任务约束
LoCoMo 得分	LLM 裁判与参考答案对照
平均 tokens	表 2–3 口径；未完整说明全部组成
平均输入 tokens	表 1 口径；XPath 包含查询生成输入
模型	GPT-5 mini / Gemini 3 Flash；Qwen3 嵌入 / BART 蕴含评分

不同任务指标不直接混比；tokens 不包含本地评分的全部计算开销。

原文 PDF 第 5 页，§4.1；第 7 页表 1；第 11 页表 2–3

单轮结果与准确性权衡

回答模型	方法	通过率	平均 tokens
GPT-5 mini	In-context	70.0%	26 216
	Flat RAG	30.0%	3 250
	XPath Entail	83.0%	5 691
Gemini 3 Flash	In-context	79.0%	25 387
	Flat RAG	37.7%	3 361
	XPath Entail	70.7%	5 830

GPT-5 mini：比 Flat RAG 提高 53 个百分点。

相对增幅 176.7%；tokens 为全量上下文的 21.7%。Gemini 准确性仍低于全量上下文。

原文 PDF 第 11 页，附录 B 表 2；作者单轮平均结果

多轮结果与评分器比较

回答模型	方法	通过率	平均 tokens
GPT-5 mini	In-context	80.0%	69 097
	Flat RAG	26.7%	3 327
	XPath Entail	83.3%	5 850
Gemini 3 Flash	In-context	56.7%	76 603
	Flat RAG	26.7%	3 240
	XPath Entail	80.0%	5 993

Entail 在两种模型下取得最高平均通过率。

tokens 约为全量上下文的 8.5% 和 7.8%；平均优势不代表每个子场景均提升。

原文 PDF 第 6 页图 6–7；第 11 页表 3；作者多轮平均结果

LoCoMo 上的泛化结果

回答模型	方法	回答得分	输入 tokens
GPT-5 mini	In-context	74.55	24 857
	Flat RAG	35.71	1 341
	Semantic XPath	65.19	3 032
Gemini 3 Flash	In-context	87.01	27 499
	Flat RAG	41.49	1 996
	Semantic XPath	73.25	3 870

总体得分高于 Flat RAG，低于全量上下文。

输入约为全量上下文的 12.2% 和 14.1%；保留准确性和证据完整性的代价。

原文 PDF 第 7 页表 1；回答得分与平均输入 tokens，XPath 含查询生成

优点局限与失败来源

失败阶段	典型表现
查询生成	语法不合法，无法执行
检索	无命中、证据不全、选错节点或发言
回答生成	所需证据已取回，但答案仍错误

- 优点：结构与语义结合，路径及评分轨迹可追溯。
- 作者分析：检索仍是主要剩余失败来源。
- 阅读局限：层级依赖、多跳、小规模评测和本地评分开销。

原文 PDF 第 6–7 页，§4.3、图 8：局限部分为个人阅读分析

个人总结与团队关联

- 长期记忆访问同时考虑内容、所属范围和历史版本。
- 阅读启发：明确查询范围，保留节点路径与证据标识。
- 评测启发：区分检索与回答错误，加入元数据过滤基线。
- 本组 C 已完成事件记忆构建；Semantic XPath 尚未端到端复现。

原录制稿的拟议角色属于 10 月 17 日计划；当前分工按 C 结项记录表述，贡献比例由全组确认。

个人阅读总结：本组 C 事件记忆结项另见 Issue#32 及 PR#43/#50

参考资料

主要论文

Liu et al. Semantic XPath: Structured Agentic Memory Access for Conversational AI. ACL 2026 System Demonstrations, pp.286–296.

https://aclanthology.org/2026.acl-demo.28/

作者项目

https://github.com/D3Mlab/SemanticXpath-Chat

语法与评分见 §3、附录 A；结果见表 1–3；旅行下雨案例为教学示例。

论文与数值：Liu et al., 2026；教学示例和个人推测分别标识

专题论文阅读

HyMEM

电脑操作智能体的混合自演化记忆

lanshuheng9-oss

7–9 分钟

问题：经验既要保留细节，也要跟上任务变化

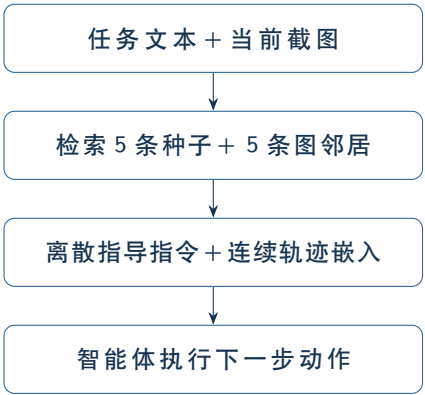
截图与动作难以只靠文本总结；一次检索也会过时。

- 输入：任务描述、当前截图、历史成功操作轨迹。
- 输出：指导智能体选择下一步网页操作。
- 例：搜索商品转入结账后，保留预算，更新操作指导。

混合表示解决“存什么”；自演化解决“何时更新”。

HyMEM，PDF 第 1–3 页，表 1；下例为机制说明

混合记忆：策略指导规划，连续表示保留细节



一条经验的三个层次

$$v_i = (c_i, A_i, m_i)$$

- c_i：可复用的高层策略。
- A_i：动作、界面及领域属性。
- m_i：8 个连续轨迹嵌入。

CLIP 检索索引与连续记忆是不同表示。

HyMEM，PDF 第 3–5 页，式 (1)、图 1、Structured Retrieval

自演化：长期图与当前工作记忆分别更新

全局：跨任务积累经验

- ADD：出现新策略或属性。
- MERGE：同一策略的互补证据。
- REPLACE：同条件下更优的轨迹。

局部：跟随当前任务阶段

1. 比较动作前后观测，检测阶段变化。
2. 保留长期目标及约束，删除过时指导。
3. 重新检索，刷新文本与连续嵌入。

先检索候选，再由视觉语言模型判断信息增量。

全局改变长期经验库；局部更新当前执行上下文。

HyMEM，PDF 第 4–5 页，Memory Update、Working Memory Refresh；图 1

实验：网页操作成功率，包含记忆编码器训练

项目	作者实验条件
三个基准	WebVoyager、Multimodal-Mind2Web、MMInA
记忆来源	2883 条成功轨迹；主图 1858 个节点，超过 100 万条边
模型与接口	7B/8B 视觉语言模型；ReAct、SOM 及定位回退
训练	Q-Former + LoRA；约 1.2% 参数可训练，通常 1 个 epoch
评价	任务成功率；Overall 按可用领域取平均

前两个基准根据任务和截图轨迹判分；MMInA 比较最终回答与标准答案。

HyMEM，PDF 第 5–6 页，§4.1；第 7 页，表 2 表注

结果：混合记忆有收益，单一记忆并非总有帮助

作者表 2：Overall 任务成功率（%）

基础模型	无记忆	离散	连续	HyMEM
Qwen2.5-VL-7B	12.5	17.0	21.7	**35.0**
Qwen3-VL-8B	21.9	21.3	23.3	**33.8**
UI-TARS-1.5-7B	17.1	15.4	28.7	**31.2**

12.5% 到 35.0%：提高 22.5 个百分点。

Qwen3 的离散记忆低于无记忆；总体提升不代表每个领域都改善。

图 2 另支持全局演化与局部刷新的作用；两种收益不能直接相加。以上均非本组结果。

HyMEM，PDF 第 7 页，表 2；图 2 为不同分析设置，不与本表混合

阅读判断：借鉴组织机制，迁移收益仍需验证

贡献与局限

- 离散策略与视觉细节互补。
- 长期积累与任务内刷新形成闭环。
- 依赖训练、标签与模型判断，存在额外调用成本。

与本组 StructMem D 的联系

- 可研究种子检索与结构扩展的分工。
- 固定预算，比较覆盖、噪声及成本。
- 文本问答与截图操作口径不同，不能直接排名。

本组尚未复现 HyMEM；迁移建议不是团队共识或已完成实验。

HyMEM，PDF 第 3–7 页；右侧为本节阅读分析与待验证假设

专题论文阅读

MetaMem

让模型正确使用已取回的事实

YaoYang-123456

约 8 分钟核心讲解

检索到了事实，为什么还会答错？

问题：**四次旅行共走了多少英里？**

事实 A	前三次旅行合计**1800**英里
事实 B	第四次旅行总计**1200**英里
事实 C	第四次旅行第一天走了**300**英里

正确：$1800 + 1200 = \mathbf{3000}$　**错误**：$1800 + 1200 + 300 = 3300$

错误未必来自检索：事实可能全部存在，模型却把“总量”和“部分”重复相加。

原文 PDF p.1，图 1；图中里程数字按论文示例整理

事实记忆 M 与元记忆 E

对象	保存什么	例子
事实记忆 M	具体经历、数字、时间、人物	第四次旅行总计 1200 英里
元记忆 E	可迁移的知识使用策略	总量与部分不可重复计数

$$\hat{y} = \mathrm{LLM}(\mathrm{Prompt}(q, M, E))$$

训练对象：自然语言规则集合 E；不通过反向传播更新基础模型权重。

信息不足时，规则也不能补出原本没有检索到的关键事实。

原文 PDF p.3，§3.1，式 (1)–(3)

从候选回答到反思与规则更新

1. **多次回答**：在同一事实记忆下采样若干候选回答。
2. **评价与反思**：使用训练标准答案判断对错并归纳原因。
3. **编辑规则**：提出 ADD / DEL / MOD，处理重复与冲突。
4. **验证与冻结**：用验证集选取规则版本；测试时不再更新。

回答 → 反馈 → 反思 → 规则 → 新回答

训练时可以看到标准答案；测试回答时不能看到答案，更不能用测试答案改规则。

原文 PDF pp.3–5，Figure 2，式 (4)–(10)

一次自然语言规则编辑

原规则：把所有出现的数字相加。

反思：第一天属于第四次旅行，重复计入会多算。

MOD 提案：求和前核对对象、事件和包含关系，只合并互不重复的数量。

ADD	新增缺失的经验；从空集合开始时先添加
DEL	删除错误或过时的经验
MOD	修改已有编号的经验

提案先处理重复和冲突，再执行到 E；例子不代表本组真实学出的规则。

原文 PDF pp.4–5，Figure 2、式 (4)–(10)；以下规则文字为教学构造

实验设置与数据隔离

数据和划分	LongMemEval 500 题；每折 350 训练＋ 50 验证＋ 100 测试，共五折
事实记忆	LightMem；规则以外还存在检索模块
生成模型	Qwen3-30B-A3B-Instruct、Llama3.1-70B-Instruct
评价模型	Qwen3-235B-A22B；判分是实验的一部分
学习设置	5 epochs，每批 50 题，每题采样 5 次

模型、数据划分、评价标准不一致时，不能直接把准确率差异归因到元记忆。

原文 PDF pp.5、11，§4，附录 A.3、A.5

主结果与消融的解释

原论文 LongMemEval 平均值（%）

生成模型	LightMem	MetaMem	提升（点）
Qwen3-30B-A3B	67.50	**71.90**	+4.40
Llama3.1-70B	66.17	**69.08**	+2.91

Qwen 消融：完整方法 71.90；无反思 70.02；无演化 68.33。

两组模型的增幅不同，整体提升不等于所有题型改善；这些数字不是本组试点成绩。

原文 PDF p.6 Table 1、p.7 Table 2；均为论文结果

局限、适用条件与 StructMem 的联系

优势与价值

- 分离“检索缺失”和“利用错误”
- 规则可读、可修改，无须微调权重
- 消融实验提供一定证据

限制与风险

- 依赖带答案数据与评判质量
- 多次采样和反思有成本
- 过度泛化、冲突与事实缺失

StructMem 侧重组织和检索证据；MetaMem 侧重检索后的事实利用。两者不可直接混算实验成绩。

原文 PDF §Limitations、附录 A.6；本组方案 docs/project-plan.md

专题论文阅读

Text2Mem

统一的记忆操作语言与状态验证

ngocnamd93-spec

7–9 分钟

记忆控制需要说明“对哪些记录做什么”

用户说：“暂时不要再提午餐。”

降低显著性、设置到期规则与删除记录，会产生不同状态。

- 检索解决“找回什么”；记忆控制还要明确动作、范围与时间。
- 输入是自然语言请求与上下文；输出是操作 Schema 或有序操作列表。
- Text2Mem 提供操作规范与基准，主实验在 SQL/SQLite 参考后端进行。

把意图显式表达，再核验实际状态变化

原论文 PDF 第 1–3 页，图 1：动机案例为教学概述

十二个操作由五字段契约组织

阶段	操作
编码 ENC	Encode
存储 STO	Update、Label、Promote、Demote、Merge、Split、Delete、Lock、Expire
检索 RET	Retrieve、Summarize

stage / op / target / args / meta

阶段、动作、目标、参数、执行上下文；各操作的必填条件不同。

需要定位已有条目时，target 选择 ids、filter、search 或 all 之一。
Demote 降权或归档而不删除；Delete 与 Expire 另有语义。

原论文 PDF 第 4 页表 1、第 4–5 页 §3.2；附录 A 第 11 页

校验、解析与适配各自解决一层问题



格式合法、动作可执行、效果符合意图，需要分别判断

锁定与到期等规则可提前检查；复杂目标理解仍依赖模型。

依据原论文 PDF 第 3 页图 2、第 5 页 §3.3、第 6 页图 3 重绘；非运行记录

案例：提高进度笔记权重，也要检查无关记录

请求与已明确的目标

“提高本周课设进度笔记的重要性，其他记录不变。”目标 ID：17。

结构化操作

```
stage: STO
op: Promote
target: ids=[17]
args: weight=0.9
```

字段摘要，省略非必要项；
不是经过执行的 JSON 结果。

执行后检查

1. ID 17 的权重是否达到要求？
2. ID 17 的内容是否保持不变？
3. 非目标条目是否保持不变？

若最初选错目标，合法操作也会改错记录。

改写自原论文 PDF 第 12 页附录 B.1.1；本页是未执行的教学案例

评测分开衡量结构、执行与状态效果

指标	回答的问题
SMA	操作与参考结构有多相似？使用编辑距离或余弦相似度。
ESR	操作能否通过校验，并无运行错误地执行？
EMR	全部期望 SQL 断言中，有多少得到满足？

$$\mathrm{EMR} = \frac{\text{满足的状态断言数}}{\text{期望状态断言总数}}$$

作者比较五个模型，中/英文、直接/间接指令、单操作/工作流。
EMR 不是整任务全通过率，也不是 LoCoMo 问答准确率。

原论文 PDF 第 6–8 页 §4.1–4.3；EMR 公式在第 7 页

操作容易运行，预期状态仍难实现

模型	ESR (%)	EMR (%)
GPT-4o	94.84	25.32
Qwen2.5-72B-Instruct	95.10	25.35
Claude-4-Sonnet	95.94	31.32
Gemini-2.5-Pro	94.79	28.97
GPT-5	96.62	28.26

GPT-5 工作流：ESR 100%，EMR 11.90%

原表 Avg 直接转为百分数，不重算操作均值。

Split 的 EMR 在五个模型中均为 0，仅限该基准。论文未做组件移除消融。

原论文 PDF 第 8 页表 2 Avg 列、表 3；全部为作者结果

对本组的启发是明确契约，再核对效果

论文价值与局限

- 统一动作、范围和生命周期参数。
- 规划与状态效果分开评测。
- 缺少复杂语义保证；跨真实后端和长期任务证据有限。

与本组课设的联系

- StructMem 研究事件记忆与问答，任务和指标不同。
- A 的字段白名单与哈希属于数据校验，不能称 Text2Mem 复现。
- 借鉴显式输入、影响范围与非目标状态检查。

系统能调用成功，还要证明它做对了事

原论文 PDF 第 9 页 Limitations、第 15 页附录 F；课设联系为阅读分析

跨论文比较

系统性总结

从记忆表示追踪到证据与状态

第 8 队

计划 10 分钟

六篇工作改变的是不同处理环节

工作	主要表示	着力点	成立条件
StructMem	事件条目、综合摘要	保留绑定和跨事件联系	抽取、时间与来源准确
Hindsight	四类记忆网络	写入、多路召回、反思	实体和时间处理可靠
Semantic XPath	已有层级树	结构范围＋语义访问	树与查询对应正确
HyMEM	策略＋连续轨迹	混合经验与两层更新	截图、轨迹和编码器训练
MetaMem	事实＋利用规则	改善取回后的推理	学习反馈与测试隔离
Text2Mem	操作 Schema	目标、动作与状态验证	后端语义及断言明确

表中是各篇的主要着力点，不表示它只具有这一项能力。

StructMem 图 2；Hindsight 图 1；XPath §3；HyMEM 图 1；MetaMem 图 2；Text2Mem 图 2、表 1

机制可以互补，接口与代价需要另行验证

联系	分别检查什么	组合前要明确什么
StructMem + XPath	存储关系是否保真；读取范围是否正确	事件到树的映射、版本边界、查询成本
Hindsight + MetaMem	证据是否取回；取回后是否用对	固定证据的诊断、规则反馈来源、推理预算
HyMEM + Text2Mem	何时维护经验；操作实际改变了什么	连续表示与后端契约、目标范围、状态断言

更完整的结构可能增加抽取误差；扩大召回可能增加噪声；更新与反思也有调用成本。

机制依据见各个人章节；组合条件为本报告阅读分析，未经组合实验验证

共同案例：旧计划不能混入当前路线

来源记录	用户陈述
s_1：10 月 20 日	10 月 23 日去 A 地。
s_2：10 月 21 日	取消 A 地，改为 10 月 24 日去 B 地。
s_3：10 月 22 日	10 月 24 日先到 B 地，再去 C 地，仍按新计划。

问题：当前计划哪天出行，经过哪些地点？

依据 s_2, s_3：10 月 24 日，先 B 地后 C 地。

记录日期不等于出行日期；A 地已取消；新旧记录都需要保留其来源和状态。

自拟教学案例：日期为记录内容，不是六系统运行结果

同一个错误，要沿证据定位到具体环节

视角	在案例中检查	不自动保证什么
StructMem	事件绑定与 s_2, s_3 的联系	综合摘要必然保留取消关系
Hindsight	实体、事件时间与多路召回	新旧事实可仅按意见置信度处理
XPath	同一行程、正确版本与节点	查询会自动建立版本或维护状态
MetaMem	新旧陈述与事件关系的使用	缺失证据可由规则补出

Text2Mem：若再要求“暂时别提”，先明确降权、关闭提醒还是删除，再检查状态。
HyMEM：本例没有截图或动作轨迹，无法验证其多模态机制。

各机制的原文依据见前六部分；本页是对自拟案例的解释性推演

先对齐实验条件，再解释性能差异

原文中的对照	能支持的观察	不能扩大为
StructMem（多跳） 66.31%→68.77%	同设置下，跨事件综合改善多跳；开放域均 46.88%	所有题型都提高
XPath（LoCoMo） 74.55→65.19	GPT-5 mini 输入 24,857→3,032 tokens，准确性有代价	全部计算成本都按输入比例下降
Text2Mem（工作流） ESR 100% EMR 11.90%	GPT-5 的 ESR 与 EMR 不同：可执行不保证状态效果	两数相减就是失败任务比例

共同核对：任务与数据、模型与反馈、检索 / 回答预算、指标与裁判。
构建、查询、规则学习和评价成本分别计量。

StructMem PDF p.4 表 2；XPath p.7 表 1；Text2Mem p.8 表 3；均为作者结果

课设以 StructMem 为主线，其他工作用于诊断

任务与对照

- LoCoMo 小子集、一个回答模型。
- 原始对话 Flat RAG。
- 事件记忆，去掉跨事件综合。
- 完整 StructMem。

从其他论文借鉴什么

- Hindsight / XPath：时间、实体与范围。
- MetaMem：取回失败与利用失败分开。
- HyMEM：长期维护与当前上下文分开。
- Text2Mem：影响范围与结果核验。

选择依据是任务匹配与可解释对照，不是宣称 StructMem 在所有条件下最好。

本组既定范围：docs/project-plan.md（1862df9）；此处说明设计，不表示实验均已完成

结论：结构服务于明确问题，验证覆盖结果

1. **保留依据**：人物、事件、时间、来源和状态要能对应。
2. **分层诊断**：存得对、找得到、用得对、执行符合意图分别检查。
3. **控制取舍**：结构、召回和更新都有误差与成本，收益须在相同条件下验证。

来源 ID 不替代内容核对；检索命中不替代推理正确；调用成功不替代状态满足。

讨论与问题

长上下文场景结构化记忆建模

第 8 队

备用：共同参加活动的案例

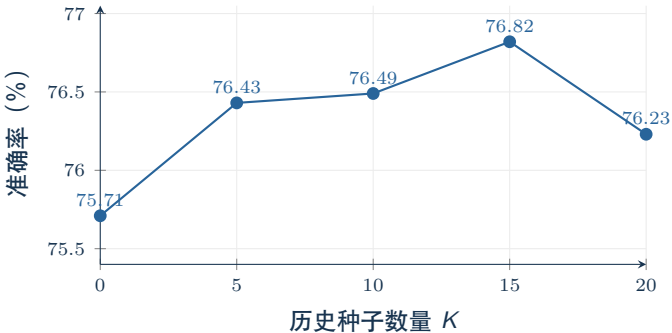
方法	回答
Flat Memory	两人没有一起去过。
Graph Memory	上个月，2023 年 6 月。
StructMem	去年，2022 年 8 月。
参考答案	2022 年

互动语境连接共同经历，来源日期帮助解析“去年”

表中参考答案验证到年份，额外的月份没有得到单独验证。

原文表 8，p.132。案例预测为论文报告值

备用：历史种子数量



$K = 15$ 时达到最高值。

$K = 0$ 仍整合当前缓存，只是不引入历史。

更多历史不保证继续提升。

原文图 3(d)，p.126。纵轴截取 75.4–77.05 以显示细小差异

备用：更换评判模型后的结果

评判模型	StructMem	Memobase	分差
gpt-4o-mini	76.82	75.78	+1.04
Qwen2.5-32B	77.01	76.36	+0.65
DeepSeek-V3.2	79.35	79.29	+0.06

Fleiss' $\kappa = 0.8341$，**模型间判断较一致**。

分差随评判模型变化，DeepSeek 下两者十分接近。

一致性指标衡量评判模型之间的共识，论文未报告系统分差的显著性检验。

备用页：原文表 4–5，p.130。表 1 口径复核详见阅读总结末页

备用：几个方法细节

为什么不用图也能称为结构化记忆？
同源条目的时间绑定和跨事件摘要，已经提供了层次与关系组织。

整合摘要会覆盖原来的记忆吗？
事件条目与摘要共同保留，回答时同时检索。

是否需要训练新模型？
论文核心流程使用提示调用、向量检索与记忆组织，没有新的参数训练步骤。

怎样处理相互冲突的记忆？
问答提示优先较新信息，存储层的显式修订仍是待解决的问题。

备用页：原文 §3，附录 A.3、A.7，Limitations