天津大学 NLP　第 8 队

长上下文场景结构化记忆建模

六篇论文阅读与系统性总结

汇报成员与日期：待填写

共同的研究问题

长历史持续增长时，如何保存、找到并正确使用相关记忆？

- 组织：保留哪些事实、关系、时间与任务状态？
- 访问：怎样定位相关证据，并保留必要上下文？
- 维护与利用：如何处理更新、操作和证据使用？

汇报结构与时间安排

环节	内容	参考时间
开场	研究背景与共同问题	3 分钟
六篇论文	StructMem、Hindsight、Semantic XPath HyMEM、MetaMem、Text2Mem	每人 7–9 分钟
系统性总结	统一比较、共同案例、取舍与小组结论	10–15 分钟

默认：3 + 6×8 + 12 = 63 分钟

各篇讲解先建立依据，最后集中讨论论文之间的关系。

专题论文阅读

StructMem

面向长程对话的结构化记忆

讲解人待填写

7–9 分钟

长程对话中的证据组织

问题：Caroline 和 Melanie 什么时候一起参加过 Pride festival？

2023 年 8 月的回忆	两人在交流中提到去年的活动经历，以及与朋友共同参与的记忆。
回答需要的证据	将人物互动与活动经历关联起来，并由来源时间把“去年”换算为 2022 年。

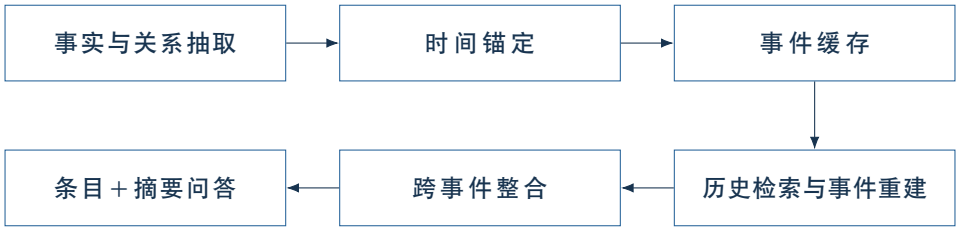
三种组织方式

方法	保存形式	需要处理的问题
平面记忆	独立条目＋向量	检索后补齐分散的事件语境
图记忆	实体、关系与图结构	实体消歧、关系去重与维护
StructMem	时间绑定的条目＋整合摘要	在写入时组织相关事件

关键词相似能找到相关片段，完整回答还需要人物、事件与时间之间的联系。

原文 §1–2；附录 A.8，表 8，p.132。案例证据简化为中文

StructMem 的两层记忆



记忆层次	保存内容	回答时的作用
事件级记忆	事实、互动关系、来源时间	提供可核对的具体细节
跨事件记忆	当前事件与相关历史的整合摘要	提供跨越多次交流的联系

两层共同保留。核心流程由提示调用与向量检索组成，无需训练新的语言模型。

原文图 2、§3，pp.123–124；流程据原文重绘

双视角抽取与时间锚定

对话示例：Alice 分享研究生录取和机器学习方向，Bob 祝贺她、询问计划并表达支持。

事实视角 Φ_i	Alice 被研究生项目录取，计划研究机器学习。
关系视角 Ψ_i	Bob 为 Alice 感到高兴，支持她的选择并关注研究计划。

$$\text{记忆条目} = \langle x, e_x, \tau_i \rangle, \qquad x \in \Phi_i \cup \Psi_i$$

x：自然语言内容　e_x：检索向量　τ_i：来源话语时间

时间示例：2023 年 8 月说“去年参加过活动”。

来源时间保留为 2023 年 8 月，回答时将事件年份换算为**2022 年**。

抽取结果附带 source_id；事件重建按相同来源时间聚合事实与关系条目。

原文 §3.1，式 (1)–(2)；图 4–7、13，pp.133–136、139

历史检索与跨事件整合

1. **积累当前事件**：条目按对话时间排序，以 1 小时窗口触发整合。
2. **检索历史种子**：拼接缓存文本并编码，按余弦相似度取 top-15。
3. **恢复事件语境**：取回每个种子同时间锚的其他事实与关系条目。
4. **生成整合摘要**：当前缓存与恢复后的历史事件共同进入整合模型。

$$E_\tau(x^*) = \{x' \in M \mid \tau(x') = \tau(x^*)\}$$

摘要要求：200–350 个英文词，保留人物、具体时间和行动，组织有依据的事件联系。

关键区别：15 是历史种子数，展开后的上下文可能包含更多条目。

1 小时指对话时间窗口。整合摘要与事件条目共同保留。

原文 §3.2，式 (3)–(5)；A.3；图 8，pp.124、129、137

回答阶段的证据组合

检索内容	提供的信息	回答中的用途
60 条事件记忆	具体事实、人物互动、来源时间	核对人物身份与细节
5 条整合摘要	已整理的相关历史与事件联系	联合多段证据

回答提示中的处理规则

- 同时检查两位说话人的记忆，区分说话人与记忆中提到的人物。
- 依据来源日期换算“去年”“两个月前”等时间表达。
- 信息冲突时优先较新的记忆，最终输出简短、具体的答案。

构建阶段的 15 条种子与回答阶段的 60 + 5 分别控制不同环节。

原文 A.3；图 13，pp.129、139；案例参考表 8，p.132

实验设置与比较范围

LoCoMo 长期对话问答

10 段对话，平均 588 轮、16,618 Token。

任务	数量	需要的能力
单跳	841	定位单一事实
多跳	282	连接多条证据
时间	321	推理时间关系
开放域	96	对话结合背景知识
合计	1,540	单跳占 54.6%

模型与指标

生成：gpt-4o-mini
向量：text-embedding-3-small

正确率：LLM 评判回答
构建成本：Token、调用数、耗时

主要对比：全文上下文、RAG、图记忆及长期记忆系统。

读表方式：总分结合分类结果看；检索预算各异，主表反映整套系统表现。

原文 §4.1；A.2–A.4、表 3，pp.125、128–129

总分提升与能力差异

方法	总分	单跳	多跳	时间	开放域
FullContext	73.83	**86.56**	68.79	50.16	56.25
Zep	75.14	79.79	**74.11**	67.71	**66.04**
Memobase	75.78	77.17	70.92	**85.05**	46.88
StructMem	**76.82**	81.09	68.77	81.62	46.88

主要收益

总分比 Memobase 高**1.04**。

相对 FullContext，时间推理提高**31.46**，总分提高 2.99。

能力取舍

相对 FullContext，单跳下降 5.47，多跳接近。

Zep 多跳、开放域更高；Memobase 时间任务更高。

时间相关任务受益明显；跨事件整合的具体作用，需要进一步看组件消融。

原文表 1，p.125。粗体为所列方法中最高值；差值单位为百分点

构建成本与运行时间

完整实验的构建统计

方法	Token(M)	调用数	时间 (s)
MiniRAG	10.103	2,508	2,566
StructMem	1.937	1,056	22,854
Mem0g	35.825	53,514	115,670

相对 Mem0g：Token 减少**94.6%**，调用减少**98.0%**，耗时减少 80.2%。

同框架，首段对话

平面记忆	77.6k
StructMem	226.1k
图记忆	402.3k

StructMem 约为平面记忆的 2.91 倍，比图记忆少 43.8%。

成本来自哪里：双视角抽取和摘要增加调用；批量整合减少图维护的多阶段开销。

MiniRAG 运行更快。调用量、Token 消耗与墙钟时间需要分别评价。

原文表 1、图 3(b)，pp.125–126。M 为百万 Token，k 为千 Token

跨事件整合的消融结果

配置	单跳	多跳	时间	开放域
Flat Memory	78.83	66.31	78.50	46.88
Graph Memory	80.50	66.67	76.64	48.96
去掉跨事件整合	80.86	66.31	79.44	46.88
StructMem	81.09	68.77	81.62	46.88
整合带来的变化	+0.23	**+2.46**	**+2.18**	0.00

进一步实验可分别去掉关系抽取和时间锚定，定位每个设计的贡献。

结果解释

多跳与时间任务需要联合分散证据，受益更大。

单跳变化较小，开放域未改善。

符合整合摘要以连接对话证据为主的功能。

原文表 2，p.125。最后一行为加入跨事件整合后的百分点变化

记忆内容的忠实性

事件条目：三个评判模型报告的平均幻觉率为**2.36%**。

整合约束：引用历史时标注具体时间，保留人物和行动细节，建立具体、有依据的联系。

评判模型	有约束的错误关联率	移除约束后
GPT	0.61%	7.45%
Qwen	3.41%	20.00%
DeepSeek	3.63%	15.14%

观察：三个评判模型均报告错误关联增加，提示中保留时间与具体联系有实际作用。

条目幻觉与摘要关联采用不同统计单位；这些数值来自模型审核。

原文图 8、表 6–7，pp.130–131、137。错误关联率由模型分别评判

阅读结论与后续问题

方法贡献

事实与互动关系共同保存，时间锚支持事件重建，跨事件摘要组织相关历史。

实验支持

总分 76.82%；整合模块主要改善多跳与时间任务；相对图记忆降低构建开销。

值得继续研究的问题

计划或关系发生变化后，旧条目与摘要怎样同步更新？

可用带时间变更的对话，比较仅优先新记忆与显式修订的回答质量、来源可追溯性。

我的理解：记忆写入时的组织方式，会直接影响之后的证据联合。

论文：https://aclanthology.org/2026.acl-short.12/

代码：https://github.com/zjunlp/LightMem/blob/main/StructMem.md

原文 §3–5、Limitations；末项为阅读后提出的实验方向

专题论文阅读

Hindsight

保留、召回与反思的结构化记忆

讲解人待填写

7–9 分钟

研究问题与任务范围

待补充：论文解决的具体问题

- 任务、输入与预期输出是什么？
- 既有方法在哪种情形下失败？
- 论文提出什么可检验的改进目标？

https://aclanthology.org/2026.acl-demo.27/；逐页补充原文页码与图表编号

核心方法与整体流程

核心流程图：待替换

放入原论文核心图或可编辑重绘图。
保留关键标签，标明输入、操作与输出。

需要解释的机制

1. 待补充：信息如何进入系统。
2. 待补充：核心操作与设计原因。
3. 待补充：结果如何被后续使用。

https://aclanthology.org/2026.acl-demo.27/；逐页补充原文页码与图表编号

关键机制与方法细节

输入 $\longrightarrow$ 核心操作 $\longrightarrow$ 输出

- 待补充：关键公式、结构或操作，说明符号与含义。
- 待补充：一个小例子，解释机制怎样改变处理结果。
- 待补充：与基线的具体差别，以及依赖的条件。

https://aclanthology.org/2026.acl-demo.27/；逐页补充原文页码与图表编号

实验设置与评价范围

项目	依据原论文补充
任务与数据	待填写：数据来源、划分与任务范围
模型与基线	待填写：模型角色、基线与主要配置
评价指标	待填写：指标含义、评价者与计分方式
预算与成本	待填写：上下文预算、构建或推理开销

实验条件解释到足以理解结果；训练、优化与测试时可用信息分别说明。

https://aclanthology.org/2026.acl-demo.27/；逐页补充原文页码与图表编号

关键结果与证据

待补充：这一页数据支持的一项结论

配置	主指标	关键分项	成本
基线	待填	待填	待填
本文方法	待填	待填	待填
关键消融	待填	待填	待填

待补充：提升出现在哪些条件下，哪里没有改善

用原表数值或图表替换占位，写清单位；论文结果与本组实验分开。

https://aclanthology.org/2026.acl-demo.27/；逐页补充原文页码与图表编号

局限、阅读判断与后续问题

论文支持的结论

- 待补充：最重要的贡献与证据。
- 待补充：尚未解决的局限。

个人阅读思考

- 待补充：最值得借鉴的设计。
- 待补充：需要进一步验证的问题。

与后续讲解的衔接：待各成员填写完成后统一整理。

https://aclanthology.org/2026.acl-demo.27/；逐页补充原文页码与图表编号

专题论文阅读

Semantic XPath

结构化记忆的路径与语义访问

oioioi-521

7–9 分钟

长期任务中的记忆访问

全量上下文

保留完整历史，但输入随交互增长。

扁平 RAG

返回相关片段，但日期和版本范围可能混淆。

贯穿案例

在会议安排最密集的一天增加咖啡休息。

需要比较各天的活动，而不只是找到一条会议相关文本。

研究问题：怎样访问相关的记忆子结构？

原文 PDF 第 1–2 页，图 1–2；沿用原个人 PPT 第 2 页

树形记忆与整体流程

计划 Itinerary → 版本 Version → 日期 Day → 活动 POI

1. 结合已有结构，把自然语言请求转成查询。
2. 执行结构匹配、位置筛选与语义评分。
3. 返回节点及子树，供下游回答或更新。

schema 来自已有记忆结构；查询负责定位，实际修改由下游步骤完成。

原文 PDF 第 2–4 页，图 2、§3.1–3.3；层级与流程按原文整理

查询语法与访问范围

$$S = A\,N[R]\,[P]$$

组成	写法	含义
路径 A	`/`、`//`	子节点或后代
类型 N	`Day / POI / *`	类型或任意节点
位置 R	`[i] / [-i] / [i:j]`	顺序、倒序或区间
语义 P	`[node~="workshop"]`	连续相关性评分

```
//Day[3]/POI[node~="workshop"]
```

多个行程或历史版本共存时，先限定目标范围；第三个匹配日期未必是当前计划第三天。

原文 PDF 第 3–4 页，§3.2；第 10 页，附录 A

语义评分与查询执行

```
//Day[avg(/POI[node~="conference"])]
```

执行阶段	候选与分数
初始化	根节点，权重为 1
路径与类型筛选	找到日期及其活动
第二天活动局部评分	0.603、0.482、0.608
日期聚合评分	$(0.603 + 0.482 + 0.608)/3 \approx 0.565$
与其他日期比较	选中第二天，再交给下游更新

$$w_{\text{new}} = w_{\text{old}} \times \mathrm{Rel}(u, P)$$

平均相关性反映密集程度，不直接等同于会议数量最多。

原文 PDF 第 4 页，§3.3、图 2；第 10 页，附录 A

旅行示例中的日期范围

用户：第七天下雨，找出当天需要调整的户外活动。

日期	活动	是否属于目标
第 2 天	海滨公园	否，日期不符
第 5 天	山地徒步	否，日期不符
第 7 天	植物园、海港游船	是

先限定第七天，再判断活动语义。

普通 RAG 加入日期元数据过滤也能改善简单范围错误，应纳入公平比较。

实验设置与指标口径

旅行、待办、配餐：每场景 20 个单轮和 5 个多轮对话，另测 LoCoMo。

指标或模型	含义与口径
任务通过率	检索正确，且输出满足任务约束
LoCoMo 得分	LLM 裁判与参考答案对照
平均 tokens	表 2–3 口径；未完整说明全部组成
平均输入 tokens	表 1 口径；XPath 包含查询生成输入
模型	GPT-5 mini / Gemini 3 Flash；Qwen3 嵌入 / BART 蕴含评分

不同任务指标不直接混比；tokens 不包含本地评分的全部计算开销。

原文 PDF 第 5 页，§4.1；第 7 页表 1；第 11 页表 2–3

单轮结果与准确性权衡

回答模型	方法	通过率	平均 tokens
GPT-5 mini	In-context	70.0%	26 216
	Flat RAG	30.0%	3 250
	XPath Entail	83.0%	5 691
Gemini 3 Flash	In-context	79.0%	25 387
	Flat RAG	37.7%	3 361
	XPath Entail	70.7%	5 830

GPT-5 mini：比 Flat RAG 提高 53 个百分点。

相对增幅 176.7%；tokens 为全量上下文的 21.7%。Gemini 准确性仍低于全量上下文。

原文 PDF 第 11 页，附录 B 表 2；作者单轮平均结果

多轮结果与评分器比较

回答模型	方法	通过率	平均 tokens
GPT-5 mini	In-context	80.0%	69 097
	Flat RAG	26.7%	3 327
	XPath Entail	83.3%	5 850
Gemini 3 Flash	In-context	56.7%	76 603
	Flat RAG	26.7%	3 240
	XPath Entail	80.0%	5 993

Entail 在两种模型下取得最高平均通过率。

tokens 约为全量上下文的 8.5% 和 7.8%；平均优势不代表每个子场景均提升。

原文 PDF 第 6 页图 6–7；第 11 页表 3；作者多轮平均结果

LoCoMo 上的泛化结果

回答模型	方法	回答得分	输入 tokens
GPT-5 mini	In-context	74.55	24 857
	Flat RAG	35.71	1 341
	Semantic XPath	65.19	3 032
Gemini 3 Flash	In-context	87.01	27 499
	Flat RAG	41.49	1 996
	Semantic XPath	73.25	3 870

总体得分高于 Flat RAG，低于全量上下文。

输入约为全量上下文的 12.2% 和 14.1%；保留准确性和证据完整性的代价。

原文 PDF 第 7 页表 1；回答得分与平均输入 tokens，XPath 含查询生成

优点局限与失败来源

失败阶段	典型表现
查询生成	语法不合法，无法执行
检索	无命中、证据不全、选错节点或发言
回答生成	所需证据已取回，但答案仍错误

- 优点：结构与语义结合，路径及评分轨迹可追溯。
- 作者分析：检索仍是主要剩余失败来源。
- 阅读局限：层级依赖、多跳、小规模评测和本地评分开销。

原文 PDF 第 6–7 页，§4.3、图 8；局限部分为个人阅读分析

个人总结与团队关联

- 长期记忆访问同时考虑内容、所属范围和历史版本。
- 阅读启发：明确查询范围，保留节点路径与证据标识。
- 评测启发：区分检索与回答错误，加入元数据过滤基线。
- 本组 C 已完成事件记忆构建；Semantic XPath 尚未端到端复现。

原录制稿的拟议角色属于 10 月 17 日计划；当前分工按 C 结项记录表述，贡献比例由全组确认。

个人阅读总结；本组 C 事件记忆结项另见 Issue#32 及 PR#43/#50

参考资料

主要论文

Liu et al. Semantic XPath: Structured Agentic Memory Access for Conversational AI. ACL 2026 System Demonstrations, pp.286–296.

https://aclanthology.org/2026.acl-demo.28/

作者项目

https://github.com/D3Mlab/SemanticXpath-Chat

语法与评分见 §3、附录 A；结果见表 1–3；旅行下雨案例为教学示例。

论文与数值：Liu et al., 2026；教学示例和个人推测分别标识

专题论文阅读

HyMEM

电脑操作智能体的混合自演化记忆

lanshuheng9-oss

7–9 分钟

问题：经验既要保留细节，也要跟上任务变化

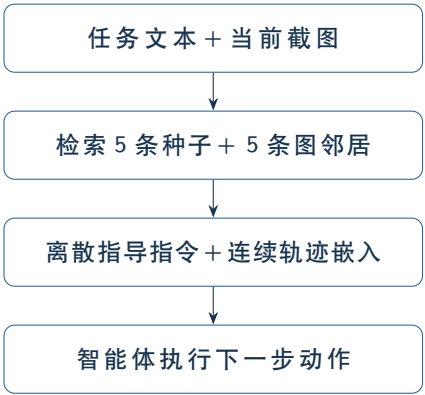
截图与动作难以只靠文本总结；一次检索也会过时。

- 输入：任务描述、当前截图、历史成功操作轨迹。
- 输出：指导智能体选择下一步网页操作。
- 例：搜索商品转入结账后，保留预算，更新操作指导。

混合表示解决“存什么”；自演化解决“何时更新”。

HyMEM，PDF 第 1–3 页，表 1；下例为机制说明

混合记忆：策略指导规划，连续表示保留细节



一条经验的三个层次

$$v_i = (c_i, A_i, m_i)$$

- c_i：可复用的高层策略。
- A_i：动作、界面及领域属性。
- m_i：8 个连续轨迹嵌入。

CLIP 检索索引与连续记忆是不同表示。

HyMEM，PDF 第 3–5 页，式 (1)、图 1、Structured Retrieval

自演化：长期图与当前工作记忆分别更新

全局：跨任务积累经验

- ADD：出现新策略或属性。
- MERGE：同一策略的互补证据。
- REPLACE：同条件下更优的轨迹。

局部：跟随当前任务阶段

1. 比较动作前后观测，检测阶段变化。
2. 保留长期目标及约束，删除过时指导。
3. 重新检索，刷新文本与连续嵌入。

先检索候选，再由视觉语言模型判断信息增量。

全局改变长期经验库；局部更新当前执行上下文。

HyMEM，PDF 第 4–5 页，Memory Update、Working Memory Refresh；图 1

实验：网页操作成功率，包含记忆编码器训练

项目	作者实验条件
三个基准	WebVoyager、Multimodal-Mind2Web、MMInA
记忆来源	2883 条成功轨迹；主图 1858 个节点，超过 100 万条边
模型与接口	7B/8B 视觉语言模型；ReAct、SOM 及定位回退
训练	Q-Former + LoRA；约 1.2% 参数可训练，通常 1 个 epoch
评价	任务成功率；Overall 按可用领域取平均

前两个基准根据任务和截图轨迹判分；MMInA 比较最终回答与标准答案。

HyMEM，PDF 第 5–6 页，§4.1；第 7 页，表 2 表注

结果：混合记忆有收益，单一记忆并非总有帮助

作者表 2：Overall 任务成功率（%）

基础模型	无记忆	离散	连续	HyMEM
Qwen2.5-VL-7B	12.5	17.0	21.7	**35.0**
Qwen3-VL-8B	21.9	21.3	23.3	**33.8**
UI-TARS-1.5-7B	17.1	15.4	28.7	**31.2**

12.5% 到 35.0%：提高 22.5 个百分点。

Qwen3 的离散记忆低于无记忆；总体提升不代表每个领域都改善。

图 2 另支持全局演化与局部刷新的作用；两种收益不能直接相加。以上均非本组结果。

HyMEM，PDF 第 7 页，表 2；图 2 为不同分析设置，不与本表混合

阅读判断：借鉴组织机制，迁移收益仍需验证

贡献与局限

- 离散策略与视觉细节互补。
- 长期积累与任务内刷新形成闭环。
- 依赖训练、标签与模型判断，存在额外调用成本。

与本组 StructMem D 的联系

- 可研究种子检索与结构扩展的分工。
- 固定预算，比较覆盖、噪声及成本。
- 文本问答与截图操作口径不同，不能直接排名。

本组尚未复现 HyMEM；迁移建议不是团队共识或已完成实验。

HyMEM，PDF 第 3–7 页；右侧为本节阅读分析与待验证假设

专题论文阅读

MetaMem

让模型正确使用已取回的事实

讲解人待填写

7–9 分钟

检索到了事实，为什么还会答错？

问题：**四次旅行共走了多少英里？**

事实 A	前三次旅行合计**1800**英里
事实 B	第四次旅行总计**1200**英里
事实 C	第四次旅行第一天走了**300**英里

正确：$1800 + 1200 = \mathbf{3000}$　**错误**：$1800 + 1200 + 300 = 3300$

错误未必来自检索：事实可能全部存在，模型却把“总量”和“部分”重复相加。

原文 PDF p.1，图 1；图中里程数字按论文示例整理

事实记忆 M 与元记忆 E

对象	保存什么	例子
事实记忆 M	具体经历、数字、时间、人物	第四次旅行总计 1200 英里
元记忆 E	可迁移的知识使用策略	总量与部分不可重复计数

$$\hat{y} = \mathrm{LLM}(\mathrm{Prompt}(q, M, E))$$

训练对象：自然语言规则集合 E；不通过反向传播更新基础模型权重。

信息不足时，规则也不能补出原本没有检索到的关键事实。

元记忆如何学出来？

1. **多次回答**：在同一事实记忆下采样若干候选回答。
2. **评价与反思**：使用训练标准答案判断对错并归纳原因。
3. **编辑规则**：提出 ADD / DEL / MOD，处理重复与冲突。
4. **验证与冻结**：用验证集选取规则版本；测试时不再更新。

回答 → 反馈 → 反思 → 规则 → 新回答

训练时可以看到标准答案；测试回答时不能看到答案，更不能用测试答案改规则。

原文 PDF pp.3–5，Figure 2，式 (4)–(10)

实验条件决定结果能否比较

数据和划分	LongMemEval 500 题；每折 350 训练＋ 50 验证＋ 100 测试，共五折
事实记忆	LightMem；规则以外还存在检索模块
生成模型	Qwen3-30B-A3B-Instruct、Llama3.1-70B-Instruct
评价模型	Qwen3-235B-A22B；判分是实验的一部分
学习设置	5 epochs，每批 50 题，每题采样 5 次

模型、数据划分、评价标准不一致时，不能直接把准确率差异归因到元记忆。

原文 PDF pp.5、11，§4，附录 A.3、A.5

结果：有提升，但不是每项都好

原论文 LongMemEval 平均值（%）

生成模型	LightMem	MetaMem	提升（点）
Qwen3-30B-A3B	67.50	**71.90**	+4.40
Llama3.1-70B	66.17	**69.08**	+2.91

Qwen 消融：完整方法 71.90；无反思 70.02；无演化 68.33。

两组模型的增幅不同，整体提升不等于所有题型改善；这些数字不是本组试点成绩。

原文 PDF p.6 Table 1、p.7 Table 2；均为论文结果

优点、局限与本组课设联系

优势与价值

- 分离“检索缺失”和“利用错误”
- 规则可读、可修改，无须微调权重
- 消融实验提供一定证据

限制与风险

- 依赖带答案数据与评判质量
- 多次采样和反思有成本
- 过度泛化、冲突与事实缺失

StructMem 侧重组织和检索证据；MetaMem 侧重检索后的事实利用。两者不可直接混算实验成绩。

原文 PDF §Limitations、附录 A.6；本组方案 docs/project-plan.md

专题论文阅读

Text2Mem

统一的记忆操作语言

讲解人待填写

7–9 分钟

研究问题与任务范围

待补充：论文解决的具体问题

- 任务、输入与预期输出是什么？
- 既有方法在哪种情形下失败？
- 论文提出什么可检验的改进目标？

https://aclanthology.org/2026.findings-acl.100/；逐页补充原文页码与图表编号

核心方法与整体流程

核心流程图：待替换

放入原论文核心图或可编辑重绘图。
保留关键标签，标明输入、操作与输出。

需要解释的机制

1. 待补充：信息如何进入系统。
2. 待补充：核心操作与设计原因。
3. 待补充：结果如何被后续使用。

https://aclanthology.org/2026.findings-acl.100/；逐页补充原文页码与图表编号

关键机制与方法细节

输入 $\longrightarrow$ 核心操作 $\longrightarrow$ 输出

- 待补充：关键公式、结构或操作，说明符号与含义。
- 待补充：一个小例子，解释机制怎样改变处理结果。
- 待补充：与基线的具体差别，以及依赖的条件。

https://aclanthology.org/2026.findings-acl.100/；逐页补充原文页码与图表编号

实验设置与评价范围

项目	依据原论文补充
任务与数据	待填写：数据来源、划分与任务范围
模型与基线	待填写：模型角色、基线与主要配置
评价指标	待填写：指标含义、评价者与计分方式
预算与成本	待填写：上下文预算、构建或推理开销

实验条件解释到足以理解结果；训练、优化与测试时可用信息分别说明。

https://aclanthology.org/2026.findings-acl.100/；逐页补充原文页码与图表编号

关键结果与证据

待补充：这一页数据支持的一项结论

配置	主指标	关键分项	成本
基线	待填	待填	待填
本文方法	待填	待填	待填
关键消融	待填	待填	待填

待补充：提升出现在哪些条件下，哪里没有改善

用原表数值或图表替换占位，写清单位；论文结果与本组实验分开。

https://aclanthology.org/2026.findings-acl.100/；逐页补充原文页码与图表编号

局限、阅读判断与后续问题

论文支持的结论

- 待补充：最重要的贡献与证据。
- 待补充：尚未解决的局限。

个人阅读思考

- 待补充：最值得借鉴的设计。
- 待补充：需要进一步验证的问题。

与后续讲解的衔接：待各成员填写完成后统一整理。

https://aclanthology.org/2026.findings-acl.100/；逐页补充原文页码与图表编号

共同讨论

系统性总结

从六篇工作形成统一认识

讲解人待填写

10–15 分钟

统一比较：研究对象、机制与边界

工作	记忆表示与对象	核心干预环节	适用条件与局限
StructMem	待共同整理	待共同整理	待共同整理
Hindsight	待共同整理	待共同整理	待共同整理
Semantic XPath	待共同整理	待共同整理	待共同整理
HyMEM	待共同整理	待共同整理	待共同整理
MetaMem	待共同整理	待共同整理	待共同整理
Text2Mem	待共同整理	待共同整理	待共同整理

填写各论文实际处理的问题，避免把不同研究层次视为可直接替换的方法。

本部分为结构模板；待六篇个人讲解完成后共同填写

机制之间的联系与取舍

可能互补的环节

- 待填写：哪些问题需要联合处理？
- 待填写：两种机制的接口是什么？
- 待填写：原文或实验依据是什么？

组合的条件与代价

- 待填写：表示与信息边界是否一致？
- 待填写：增加了什么成本或风险？
- 待填写：哪些效果还需要验证？

本部分为结构模板；待六篇个人讲解完成后共同填写

共同案例：不同方法分别解释什么

共同场景与问题

待讨论后选定：给出同一段历史、同一个查询，以及需要保留的关键证据。

比较内容	待填写的分析
组织与检索	记忆如何形成，哪些证据能被取回？
更新与使用	新旧信息如何处理，回答或操作如何形成？
解释边界	哪些是论文直接支持，哪些是推演或尚待验证？

本部分为结构模板：待六篇个人讲解完成后共同填写

实验结果的可比条件

条件	共同核对后填写
任务与数据	数据划分、题型与有效样本是否一致？
模型与信息	基础模型、优化反馈、测试可用信息有何差异？
检索与预算	上下文数量、token 预算与构建成本如何计量？
指标与评价	各指标测什么，裁判与评价提示是否一致？

待填写：哪些结果可以比较，哪些只能分别解释

本部分为结构模板；待六篇个人讲解完成后共同填写

小组结论与课设选择

1. **共同认识**：待填写一项有依据的结论。
2. **研究取舍**：待填写主线选择，以及借鉴或暂不采用的机制。
3. **仍待验证**：待填写关键分歧、失败情形和后续验证方式。

本部分为结构模板；待六篇个人讲解完成后共同填写

讨论与问题

长上下文场景结构化记忆建模

第 8 队

备用：共同参加活动的案例

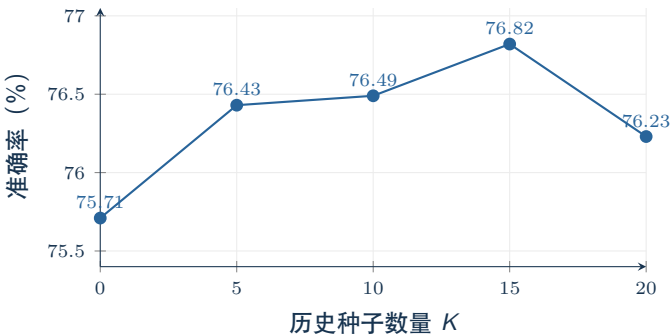
方法	回答
Flat Memory	两人没有一起去过。
Graph Memory	上个月，2023 年 6 月。
StructMem	去年，2022 年 8 月。
参考答案	2022 年

互动语境连接共同经历，来源日期帮助解析“去年”

表中参考答案验证到年份，额外的月份没有得到单独验证。

原文表 8，p.132。案例预测为论文报告值

备用：历史种子数量



$K = 15$ 时达到最高值。

$K = 0$ 仍整合当前缓存，只是不引入历史。

更多历史不保证继续提升。

原文图 3(d)，p.126。纵轴截取 75.4–77.05 以显示细小差异

备用：更换评判模型后的结果

评判模型	StructMem	Memobase	分差
gpt-4o-mini	76.82	75.78	+1.04
Qwen2.5-32B	77.01	76.36	+0.65
DeepSeek-V3.2	79.35	79.29	+0.06

Fleiss' $\kappa = 0.8341$，**模型间判断较一致**。

分差随评判模型变化，DeepSeek **下两者十分接近**。

一致性指标衡量评判模型之间的共识，论文未报告系统分差的显著性检验。

备用页：原文表 4–5，p.130。表 1 口径复核详见阅读总结末页

备用：几个方法细节

为什么不用图也能称为结构化记忆？
同源条目的时间绑定和跨事件摘要，已经提供了层次与关系组织。

整合摘要会覆盖原来的记忆吗？
事件条目与摘要共同保留，回答时同时检索。

是否需要训练新模型？
论文核心流程使用提示调用、向量检索与记忆组织，没有新的参数训练步骤。

怎样处理相互冲突的记忆？
问答提示优先较新信息，存储层的显式修订仍是待解决的问题。

备用页：原文 §3，附录 A.3、A.7，Limitations