天津大学 NLP　第 8 队

长上下文场景结构化记忆建模

六篇论文阅读与系统性比较

组织、访问、更新、利用与操作验证

长历史中的关系、范围与状态

长期记忆需要保留关系、定位证据，并跟随新信息更新。

环节	需要回答的问题
组织	人物、事件、时间和来源关系是否保留下来？
访问	如何定位正确的人物、事件与版本？
更新与利用	新旧状态如何区分，已取回的证据如何解释？
操作验证	改了哪条记忆，执行后的状态是否符合意图？

汇报安排

环节	内容	计划时间
开场	共同问题与阅读范围	2 分钟
六篇论文	StructMem、Hindsight、Semantic XPath HyMEM、MetaMem、Text2Mem	每人约 8 分钟
系统性总结	机制比较、共同案例、实验结果与课设选择	10 分钟

$2 + 6\times8 + 10 = 60$ 分钟

专题论文阅读

StructMem

面向长期对话的结构化记忆

hycx233

长期对话中的证据组织

问题：Caroline 和 Melanie 什么时候一起参加过 Pride festival？

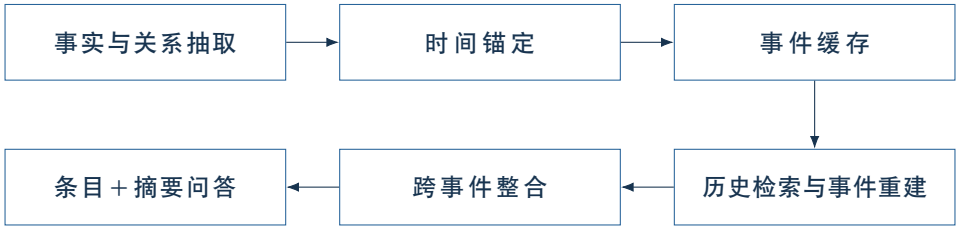
2023 年 8 月的回忆	两人在交流中提到去年的活动经历，以及与朋友共同参与的记忆。
回答需要的证据	将人物互动与活动经历关联起来，并由来源时间把“去年”换算为 2022 年。

三种组织方式

方法	保存形式	需要处理的问题
平面记忆	独立条目 + 向量	检索后补齐分散的事件语境
图记忆	实体、关系与图结构	实体消歧、关系去重与维护
StructMem	时间绑定的条目 + 整合摘要	在写入时组织相关事件

回答需要同时关联人物、事件与时间。

StructMem 的两层记忆



记忆层次	保存内容	回答时的作用
事件级记忆	事实、互动关系、来源时间	提供可核对的具体细节
跨事件记忆	当前事件与相关历史的整合摘要	提供跨越多次交流的联系

事件条目与摘要共同保留；写入和检索使用现成的语言模型。

双视角抽取与时间锚定

对话示例：Alice 分享研究生录取和机器学习方向，Bob 祝贺她、询问计划并表达支持。

事实视角 Φ_i	Alice 被研究生项目录取，计划研究机器学习。
关系视角 Ψ_i	Bob 为 Alice 感到高兴，支持她的选择并关注研究计划。

$$\text{记忆条目} = \langle x, e_x, \tau_i \rangle, \qquad x \in \Phi_i \cup \Psi_i$$

x：自然语言内容　e_x：检索向量　τ_i：来源话语时间

时间示例：2023 年 8 月说“去年参加过活动”。

来源时间保留为 2023 年 8 月，回答时将事件年份换算为**2022 年**。

source_id 标记原始证据；相同时间锚连接事实与关系条目。

历史检索与跨事件整合

1. **积累当前事件**：条目按对话时间排序，以 1 小时窗口触发整合。
2. **检索历史种子**：拼接缓存文本并编码，按余弦相似度取 top-15。
3. **恢复事件语境**：取回每个种子同时间锚的其他事实与关系条目。
4. **生成整合摘要**：当前缓存与恢复后的历史事件共同进入整合模型。

$$E_\tau(x^*) = \{x' \in M \mid \tau(x') = \tau(x^*)\}$$

摘要要求：200–350 个英文词，保留人物、具体时间和行动，组织有依据的事件联系。

关键区别：15 是历史种子数，展开后的上下文可能包含更多条目。

回答阶段的证据组合

检索内容	提供的信息	回答中的用途
60 条事件记忆	具体事实、人物互动、来源时间	核对人物身份与细节
5 条整合摘要	已整理的相关历史与事件联系	联合多段证据

回答提示中的处理规则

- 同时检查两位说话人的记忆，区分说话人与记忆中提到的人物。
- 依据来源日期换算“去年”“两个月前”等时间表达。
- 信息冲突时优先较新的记忆，最终输出简短、具体的答案。

实验设置与比较范围

LoCoMo 长期对话问答

10 段对话，平均 588 轮、16,618 tokens。

任务	数量	需要的能力
单跳	841	定位单一事实
多跳	282	连接多条证据
时间	321	推理时间关系
开放域	96	对话结合背景知识
合计	1,540	单跳占 54.6%

模型与指标

生成：gpt-4o-mini
向量：text-embedding-3-small

正确率：LLM 评判回答
构建成本：tokens、调用数、耗时

主要对比：全文上下文、RAG、图记忆及长期记忆系统。

各基线的检索预算不同；主表比较整体系统，消融实验分析组件作用。

总分提升与能力差异

方法	总分	单跳	多跳	时间	开放域
FullContext	73.83	**86.56**	68.79	50.16	56.25
Zep	75.14	79.79	**74.11**	67.71	**66.04**
Memobase	75.78	77.17	70.92	**85.05**	46.88
StructMem	**76.82**	81.09	68.77	81.62	46.88

主要收益

总分比 Memobase 高**1.04 个百分点**。

相对 FullContext，时间推理提高**31.46 个百分点**，总分提高 2.99 个百分点。

能力取舍

相对 FullContext，单跳下降 5.47 个百分点，多跳接近。

Zep 多跳、开放域更高；Memobase 时间任务更高。

构建成本与运行时间

完整实验的构建统计

方法	tokens(M)	调用数	时间 (s)
MiniRAG	10.103	2,508	2,566
StructMem	1.937	1,056	22,854
Mem0g	35.825	53,514	115,670

相对 Mem0g：tokens 减少**94.6%**，调用减少**98.0%**，耗时减少 80.2%。

同框架，首段对话

平面记忆	77.6k
StructMem	226.1k
图记忆	402.3k

StructMem 约为平面记忆的 2.91 倍，比图记忆少 43.8%。

单位：M 为百万 tokens，k 为千 tokens。

成本来自哪里：双视角抽取和摘要增加调用；批量整合减少图维护的多阶段开销。

跨事件整合的消融结果

配置	单跳	多跳	时间	开放域
Flat Memory	78.83	66.31	78.50	46.88
Graph Memory	80.50	66.67	76.64	48.96
去掉跨事件整合	80.86	66.31	79.44	46.88
StructMem	81.09	68.77	81.62	46.88
整合带来的变化	+0.23	**+2.46**	**+2.18**	0.00

后续可分别消融关系抽取与时间锚定，分析各组件的作用。

结果解释

多跳与时间任务需要联合分散证据，受益更大。

单跳变化较小，开放域未改善。

符合整合摘要以连接对话证据为主的功能。

记忆内容的忠实性

事件条目：三个评判模型报告的平均幻觉率为**2.36%**。

整合约束：引用历史时标注具体时间，保留人物和行动细节，建立具体、有依据的联系。

评判模型	有约束的错误关联率	移除约束后
GPT	0.61%	7.45%
Qwen	3.41%	20.00%
DeepSeek	3.63%	15.14%

观察：三个评判模型均报告错误关联增加，提示中保留时间与具体联系有实际作用。

条目抽取与摘要整合分别评价；表中结果由三个模型判定。

总结与后续研究

方法贡献

事实与互动关系共同保存，时间锚支持事件重建，跨事件摘要组织相关历史。

实验支持

总分 76.82%；整合模块主要改善多跳与时间任务；相对图记忆降低构建开销。

值得继续研究的问题

计划或关系发生变化后，旧条目与摘要怎样同步更新？

可用带时间变更的对话，比较仅优先新记忆与显式修订的回答质量、来源可追溯性。

写入时保留事件联系，有助于回答时联合证据。

专题论文阅读

Hindsight

结构化智能体记忆：保留、召回与反思

李金昊

长对话中的信息保留与使用

智能体需要保留信息、跨会话找回它，并据此给出连贯回答。

- 历史不断增长，相关信息可能分散在不同会话。
- 用户陈述的事实与智能体形成的判断容易混在一起。
- 只取相似片段，回答可能局部合理、整体矛盾。

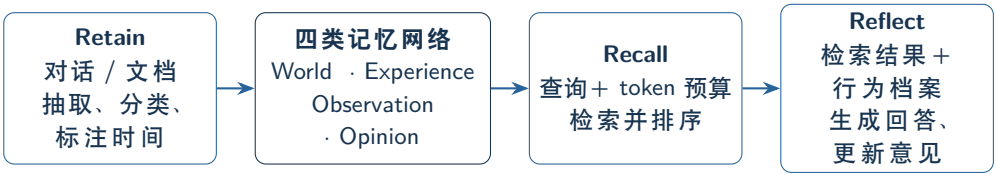
Hindsight 把写入、检索和推理分成可检查的操作。

四类网络把事实、摘要和意见分开

网络	记忆类型	例子或用途
World	外部世界事实	Alice 在 Google 的 Mountain View 团队工作。
Experience	智能体自己的经历	智能体曾向 Alice 推荐徒步旅行。
Observation	从事实归纳的实体摘要	Alice 是专长于机器学习的软件工程师。
Opinion	有置信度的主观判断	“Python 适合数据科学”；置信度随证据更新。

Observation 是证据摘要；Opinion 是带置信度的判断。

写入、检索与反思



TEMPR 负责写入和检索；CARA 负责反思，并依据新证据更新意见。

四路检索与融合排序

{向量，关键词，图遍历，时间过滤} ⟶ RRF ⟶ 重排与预算裁剪

通道	找什么
向量相似度	语义相近的记忆；使用 HNSW 索引。
BM25	关键词或实体名称；使用 PostgreSQL 全文检索。
图遍历	沿实体、时间、因果关系扩展，通常限制在 2–3 跳。
时间过滤	按问题中的日期或时间区间匹配事件。

RRF 合并各通道排序，cross-encoder 再重排；token 预算限制返回上下文。

Reflect 让意见随证据变化

行为档案

- 怀疑程度、字面倾向、共情程度
- 每项取值 1–5，用于调节回答倾向
- Opinion 保存置信度和支持证据

论文中的三会话示例

- 用户开始用 Rust 改造支付服务。
- 之后询问下一季度应重点做什么。
- 后来表示 Rust 难维护、更怀念 Go。

新证据削弱先前的偏好判断；相关世界事实仍保留。

长期对话问答结果

LongMemEval S，准确率（%）

Full-context GPT-4o	60.2
Hindsight OSS-20B	83.6
Hindsight OSS-120B	89.0
Hindsight Gemini-3	91.4
Supermemory Gemini-3	85.2

LoCoMo，准确率（%）

Zep	75.1
Memobase	75.8
Hindsight OSS-20B	83.2
Hindsight OSS-120B	85.7
Hindsight Gemini-3	89.6
Backboard	90.0

20B 在 LongMemEval 比全文 GPT-4o 高 23.4 个百分点。

LongMemEval S 共 500 题；表中各系统使用的模型配置不同。

系统局限与评测范围

系统局限

- 抽取与实体消歧依赖 LLM，错误可能传播。
- 只评测英文数据；Opinion 置信度未做正式用户验证。
- 持续保存个人信息，且无内置 PII 自动脱敏。

评测记录的缺口

- 完整评估指向另一篇工作，本文引用编号仍是占位符。
- 正文与附录的部分类别基线数值不一致。

对课设的启发

- 分开事实、经历、实体摘要和意见，检查来源与置信度。
- 在固定 token 预算下，比较语义检索与时间 / 实体关联。
- 用消融区分各通道收益，并同步记录准确率、噪声和成本。

按记忆类型和检索通道设计对照，观察准确率与成本变化。

专题论文阅读

Semantic XPath

结构化记忆的路径与语义访问

oioioi-521

长期任务中的记忆访问

全量上下文

保留完整历史，但输入随交互增长。

扁平 RAG

返回相关片段，但日期和版本范围可能混淆。

贯穿案例

在会议安排最密集的一天增加咖啡休息。

需要比较各天的活动，而不只是找到一条会议相关文本。

研究问题：怎样访问相关的记忆子结构？

树形记忆与整体流程

计划 Itinerary ⟶ 版本 Version ⟶ 日期 Day ⟶ 活动 POI

1. 结合已有结构，把自然语言请求转成查询。
2. 执行结构匹配、位置筛选与语义评分。
3. 返回节点及子树，供下游回答或更新。

树结构定义可访问的范围，查询定位节点，下游模块执行修改。

查询语法与访问范围

$$S = A\,N\,[R]\,[P]$$

组成	写法	含义
路径 A	`/`、`//`	子节点或后代
类型 N	`Day / POI / *`	类型或任意节点
位置 R	`[i] / [-i] / [i:j]`	顺序、倒序或区间
语义 P	`[node~="workshop"]`	连续相关性评分

```
//Day[3]/POI[node~="workshop"]
```

多个行程或版本共存时，先选定目标，再按位置访问日期。

语义评分与查询执行

```
//Day[avg(/POI[node~="conference"])]
```

执行阶段	候选与分数
初始化	根节点，权重为 1
路径与类型筛选	找到日期及其活动
第二天活动局部评分	0.603、0.482、0.608
日期聚合评分	$(0.603 + 0.482 + 0.608)/3 \approx 0.565$
与其他日期比较	选中第二天，再交给下游更新

$w_{\text{new}} = w_{\text{old}} \times \mathrm{Rel}(u, P)$

这里按会议相关性的平均分选择日期。

教学示例：限定日期范围

用户：第七天下雨，找出当天需要调整的户外活动。

日期	活动	是否属于目标
第 2 天	海滨公园	否，日期不符
第 5 天	山地徒步	否，日期不符
第 7 天	植物园、海港游船	是

先限定第七天，再判断活动语义。

对照方法：为普通 RAG 加入日期过滤，比较范围选择的效果。

实验设置与评价指标

旅行、待办、配餐：每场景 20 个单轮和 5 个多轮对话，另测 LoCoMo。

指标或模型	含义与口径
任务通过率	检索正确，且输出满足任务约束
LoCoMo 得分	LLM 裁判与参考答案对照
平均 tokens	单轮 / 多轮任务的用量；组成披露有限
平均输入 tokens	LoCoMo 用量，含 XPath 查询生成输入
模型	GPT-5 mini / Gemini 3 Flash；Qwen3 嵌入 / BART 蕴含评分

本地嵌入与语义评分的计算开销需另行统计。

单轮任务结果

回答模型	方法	通过率	平均 tokens
GPT-5 mini	In-context	70.0%	26 216
	Flat RAG	30.0%	3 250
	XPath Entail	83.0%	5 691
Gemini 3 Flash	In-context	79.0%	25 387
	Flat RAG	37.7%	3 361
	XPath Entail	70.7%	5 830

GPT-5 mini：比 Flat RAG 提高 53 个百分点。

GPT-5 mini 的 tokens 为全量上下文的 21.7%；Gemini 较全量上下文低 8.3 个百分点。

多轮任务结果

回答模型	方法	通过率	平均 tokens
GPT-5 mini	In-context	80.0%	69 097
	Flat RAG	26.7%	3 327
	XPath Entail	83.3%	5 850
Gemini 3 Flash	In-context	56.7%	76 603
	Flat RAG	26.7%	3 240
	XPath Entail	80.0%	5 993

Entail 在两种模型下取得最高平均通过率。

两种模型的 tokens 分别为全量上下文的 8.5% 和 7.8%。

LoCoMo 上的泛化结果

回答模型	方法	回答得分	输入 tokens
GPT-5 mini	In-context	74.55	24 857
	Flat RAG	35.71	1 341
	Semantic XPath	65.19	3 032
Gemini 3 Flash	In-context	87.01	27 499
	Flat RAG	41.49	1 996
	Semantic XPath	73.25	3 870

总体得分高于 Flat RAG，低于全量上下文。

输入分别为全量上下文的 12.2% 和 14.1%，回答得分也有所下降。

检索错误与方法局限

失败阶段	典型表现
查询生成	语法不合法，无法执行
检索	无命中、证据不全、选错节点或发言
回答生成	所需证据已取回，但答案仍错误

- 优点：结构与语义结合，路径及评分轨迹可追溯。
- 作者分析：检索仍是主要剩余失败来源。
- 局限：依赖已有层级；多跳检索与评分开销仍需改进。

总结与课设应用

- 长期记忆访问同时考虑内容、所属范围和历史版本。
- 阅读启发：明确查询范围，保留节点路径与证据标识。
- 评测启发：区分检索与回答错误，加入元数据过滤基线。
- 在事件记忆检索中，比较范围约束与纯语义检索的效果。

专题论文阅读

HyMEM

电脑操作智能体的混合自演化记忆

lanshuheng9-oss

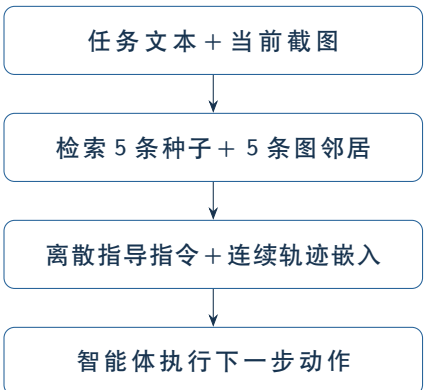
网页操作中的经验表示与更新

网页操作需要视觉细节，任务推进也会改变所需经验。

- 输入：任务描述、当前截图、历史成功操作轨迹。
- 输出：指导智能体选择下一步网页操作。
- 例：搜索商品转入结账后，保留预算，更新操作指导。

混合表示解决“存什么”；自演化解决“何时更新”。

混合记忆：策略与轨迹表示



一条经验的三个层次

$$v_i = (c_i, A_i, m_i)$$

- c_i：可复用的高层策略。
- A_i：动作、界面及领域属性。
- m_i：8 个连续轨迹嵌入。

CLIP 用于检索；连续轨迹嵌入供智能体使用。

长期经验与工作记忆的更新

全局：跨任务积累经验

- ADD：出现新策略或属性。
- MERGE：同一策略的互补证据。
- REPLACE：同条件下更优的轨迹。

先检索候选，再判断新轨迹提供了哪些信息。

局部：跟随当前任务阶段

1. 比较动作前后观测，检测阶段变化。
2. 保留长期目标及约束，删除过时指导。
3. 重新检索，刷新文本与连续嵌入。

全局改变长期经验库；局部更新当前执行上下文。

实验设置与编码器训练

项目	作者实验条件
三个基准	WebVoyager、Multimodal-Mind2Web、MMInA
记忆来源	2883 条成功轨迹；主图 1858 个节点，超过 100 万条边
模型与接口	7B/8B 视觉语言模型；ReAct、SOM 及定位回退
训练	Q-Former + LoRA；约 1.2% 参数可训练，通常 1 个 epoch
评价	任务成功率；Overall 按可用领域取平均

前两个基准评价截图与操作轨迹；MMInA 评价最终回答。

混合记忆的任务成功率

任务成功率（%），按可用领域取平均

基础模型	无记忆	离散	连续	HyMEM
Qwen2.5-VL-7B	12.5	17.0	21.7	**35.0**
Qwen3-VL-8B	21.9	21.3	23.3	**33.8**
UI-TARS-1.5-7B	17.1	15.4	28.7	**31.2**

12.5% 到 35.0%：提高 22.5 个百分点。

Qwen3 的离散记忆为 21.3%，低于无记忆时的 21.9%。

方法总结与课设启发

贡献与局限

- 离散策略与视觉细节互补。
- 跨任务积累经验，任务内刷新上下文。
- 依赖训练、标签与模型判断，存在额外调用成本。

对事件记忆检索的启发

- 可研究种子检索与结构扩展的分工。
- 固定预算，比较覆盖、噪声及成本。
- 区分文本证据检索与多模态轨迹使用。

专题论文阅读

MetaMem

让模型正确使用已取回的事实

YaoYang-123456

检索到了事实，为什么还会答错？

问题：**四次旅行共走了多少英里？**

事实 A	前三次旅行合计**1800**英里
事实 B	第四次旅行总计**1200**英里
事实 C	第四次旅行第一天走了**300**英里

正确：$1800 + 1200 = \mathbf{3000}$　**错误**：$1800 + 1200 + 300 = 3300$

错误来自重复计数：第一天的 300 英里已包含在第四次的 1200 英里中。

事实记忆 M 与元记忆 E

对象	保存什么	例子
事实记忆 M	具体经历、数字、时间、人物	第四次旅行总计 1200 英里
元记忆 E	可迁移的知识使用策略	总量与部分不可重复计数

$$\hat{y} = \mathrm{LLM}(\mathrm{Prompt}(q, M, E))$$

学习对象：自然语言规则集合 E，基础模型权重保持固定。

从候选回答到反思与规则更新

1. **多次回答**：在同一事实记忆下采样若干候选回答。
2. **评价与反思**：使用训练标准答案判断对错并归纳原因。
3. **编辑规则**：提出 ADD / DEL / MOD，处理重复与冲突。
4. **验证与冻结**：用验证集选取规则版本；测试时不再更新。

回答 → 反馈 → 反思 → 规则 → 新回答

一次自然语言规则编辑

原规则：把所有出现的数字相加。

反思：第一天属于第四次旅行，重复计入会多算。

MOD 提案：求和前核对对象、事件和包含关系，只合并互不重复的数量。

ADD	新增缺失的经验；从空集合开始时先添加
DEL	删除错误或过时的经验
MOD	修改已有编号的经验

规则编辑示例：先筛选重复和冲突提案，再更新 E。

实验设置与数据隔离

数据和划分	LongMemEval 500 题；每折 350 训练＋ 50 验证＋ 100 测试，共五折
事实记忆	LightMem 构建，每次检索 20 条
生成模型	Qwen3-30B-A3B-Instruct、Llama3.1-70B-Instruct
评价模型	Qwen3-235B-A22B
学习设置	5 epochs，每批 50 题，每题采样 5 次

问答结果与组件消融

LongMemEval 平均准确率（%）

生成模型	LightMem	MetaMem	提升（百分点）
Qwen3-30B-A3B	67.50	**71.90**	+4.40
Llama3.1-70B	66.17	**69.08**	+2.91

Qwen 消融：完整方法 71.90；无反思 70.02；无演化 68.33。

方法局限与课设启发

优势与价值

- 分离“检索缺失”和“利用错误”
- 规则可读、可修改，无须微调权重
- 反思与规则更新均带来收益

限制与风险

- 依赖带答案数据与评判质量
- 多次采样和反思有成本
- 过度泛化、冲突与事实缺失

StructMem 组织和检索证据；MetaMem 改进检索后的事实利用。

专题论文阅读

Text2Mem

统一的记忆操作语言与状态验证

ngocnamd93-spec

记忆操作的目标、动作与效果

用户说：“暂时不要再提午餐。”

降低显著性、设置到期规则与删除记录，会产生不同状态。

- 检索解决“找回什么”；记忆控制还要明确动作、范围与时间。
- 输入是自然语言请求与上下文；输出是操作 Schema 或有序操作列表。
- Text2Mem 提供操作规范与基准，主实验在 SQL/SQLite 参考后端进行。

明确目标与动作，检查状态变化

十二种操作与五个字段

阶段	操作
编码 ENC	Encode
存储 STO	Update、Label、Promote、Demote、Merge、Split、Delete、Lock、Expire
检索 RET	Retrieve、Summarize

stage / op / target / args / meta

阶段、动作、目标、参数、执行上下文；各操作的必填条件不同。

target 支持 ids、filter、search 或 all。
Demote 调整优先级，Delete 删除记录，Expire 设置到期规则。

从操作生成到状态核验



格式合法、动作可执行、效果符合意图，需要分别判断

锁定、到期与字段约束由校验器检查；目标理解依赖模型。

操作示例：提高进度笔记的权重

请求与已明确的目标

“提高本周课设进度笔记的重要性，其他记录不变。”目标 ID：17。

结构化操作

```
stage: STO
op: Promote
target: ids=[17]
args: weight=0.9
```

执行后检查

1. ID 17 的权重是否达到要求？
2. ID 17 的内容是否保持不变？
3. 非目标条目是否保持不变？

若最初选错目标，合法操作也会改错记录。

结构、执行与状态评价

指标	回答的问题
SMA	操作与参考结构有多相似？使用编辑距离或余弦相似度。
ESR	操作能否通过校验，并无运行错误地执行？
EMR	全部期望 SQL 断言中，有多少得到满足？

$$\mathrm{EMR} = \frac{\text{满足的状态断言数}}{\text{期望状态断言总数}}$$

评测覆盖五个模型，以及中英文、直接 / 间接指令、单操作 / 工作流。

执行成功率与状态匹配结果

模型	ESR (%)	EMR (%)
GPT-4o	94.84	25.32
Qwen2.5-72B-Instruct	95.10	25.35
Claude-4-Sonnet	95.94	31.32
Gemini-2.5-Pro	94.79	28.97
GPT-5	96.62	28.26

GPT-5 工作流：ESR 100%，EMR 11.90%

该基准中，五个模型在 Split 操作上的 EMR 均为 0。

方法局限与课设启发

论文价值与局限

- 统一动作、范围和生命周期参数。
- 规划与状态效果分开评测。
- 缺少复杂语义保证；跨真实后端和长期任务证据有限。

与本组课设的联系

- StructMem 研究事件记忆与问答，任务和指标不同。
- 在数据校验之外，增加操作后的状态检查。
- 借鉴显式输入、影响范围与非目标状态检查。

按目标记录与非目标记录分别核验操作效果

跨论文比较

系统性总结

表示、检索、更新与使用

第 8 队

六篇方法的研究重点

工作	主要表示	着力点	成立条件
StructMem	事件条目、整合摘要	保留绑定和跨事件联系	抽取、时间与来源准确
Hindsight	四类记忆网络	写入、多路召回、反思	实体和时间处理可靠
Semantic XPath	已有层级树	结构范围＋语义访问	树与查询对应正确
HyMEM	策略＋连续轨迹	混合经验与两层更新	截图、轨迹和编码器训练
MetaMem	事实＋利用规则	改善取回后的推理	学习反馈与测试隔离
Text2Mem	操作 Schema	目标、动作与状态验证	后端语义及断言明确

机制联系与组合条件

联系	分别检查什么	组合前要明确什么
StructMem + XPath	存储关系是否保真；读取范围是否正确	事件到树的映射、版本边界、查询成本
Hindsight + MetaMem	证据是否取回；取回后是否用对	固定证据的诊断、规则反馈来源、推理预算
HyMEM + Text2Mem	何时维护经验；操作实际改变了什么	连续表示与后端契约、目标范围、状态断言

主要代价：结构抽取误差、检索噪声，以及更新与反思的调用开销。

行程变更示例

来源记录	用户陈述
s_1：10 月 20 日	10 月 23 日去 A 地。
s_2：10 月 21 日	取消 A 地，改为 10 月 24 日去 B 地。
s_3：10 月 22 日	10 月 24 日先到 B 地，再去 C 地，仍按新计划。

问题：当前计划哪天出行，经过哪些地点？

依据 s_2, s_3：10 月 24 日，先 B 地后 C 地。

记录时间、出行时间与计划状态分别保存。

行程案例中的机制作用

视角	在案例中检查	需要处理的问题
StructMem	事件绑定与 s_2, s_3 的联系	摘要保留取消关系与来源
Hindsight	实体、事件时间与多路召回	区分计划变更与偏好判断
XPath	同一行程、正确版本与节点	建立并维护行程版本树
MetaMem	新旧陈述与事件关系的使用	取回取消和改期的关键记录

Text2Mem：将“暂时别提”明确为降权、关闭提醒或删除，再检查状态。
HyMEM：面向截图和操作轨迹，分别维护长期经验与当前上下文。

实验中的收益与代价

论文中的对照	主要观察	解释要点
StructMem（多跳） 66.31%→68.77%	同设置下，跨事件整合改善多跳；开放域均 46.88%	收益集中在部分题型
XPath（LoCoMo） 74.55→65.19	GPT-5 mini 输入 24,857→3,032 tokens，准确性有代价	嵌入与语义评分另有开销
Text2Mem（工作流） ESR 100% EMR 11.90%	GPT-5 的 ESR 与 EMR 不同：可执行不保证状态效果	ESR 按操作、EMR 按断言计数

比较时统一任务、模型、预算与评价方式；分别记录构建、查询和学习成本。

课设主线与比较设计

任务与对照

- LoCoMo 小子集、一个回答模型。
- 原始对话 Flat RAG。
- 事件记忆，去掉跨事件整合。
- 完整 StructMem。

从其他论文借鉴什么

- Hindsight / XPath：时间、实体与范围。
- MetaMem：取回失败与利用失败分开。
- HyMEM：长期维护与当前上下文分开。
- Text2Mem：影响范围与结果核验。

选择依据：长对话任务匹配，事件记忆与综合模块便于分别对照。

总结：关系保留、证据使用与状态更新

1. **保留依据**：人物、事件、时间、来源和状态要能对应。
2. **定位错误**：分别检查记忆内容、检索范围、事实使用和操作效果。
3. **比较成本**：结合抽取、检索和更新开销，评估准确率的变化。

讨论与问题

长上下文场景结构化记忆建模

第 8 队