天津大学 NLP　第 8 队

# 长上下文场景结构化记忆建模

## 六篇论文阅读与系统性总结

---

汇报成员与日期：待填写

# 共同的研究问题

长历史持续增长时，如何保存、找到并正确使用相关记忆？

- 组织：保留哪些事实、关系、时间与任务状态？
- 访问：怎样定位相关证据，并保留必要上下文？
- 维护与利用：如何处理更新、操作和证据使用？

# 汇报结构与时间安排

| 环节 | 内容 | 参考时间 |
| --- | --- | --- |
| 开场 | 研究背景与共同问题 | 3 分钟 |
| 六篇论文 | StructMem、Hindsight、Semantic XPath<br>HyMEM、MetaMem、Text2Mem | 每人 7–9 分钟 |
| 系统性总结 | 统一比较、共同案例、取舍与小组结论 | 10–15 分钟 |

**默认：3 + 6×8 + 12 = 63 分钟**

各篇讲解先建立依据，最后集中讨论论文之间的关系。

专题论文阅读

# StructMem

## 面向长程对话的结构化记忆

hycx233

7–9 分钟

# 长程对话中的证据组织

**问题**：Caroline 和 Melanie 什么时候一起参加过 Pride festival？

| | |
|---|---|
| 2023 年 8 月的回忆 | 两人在交流中提到去年的活动经历，以及与朋友共同参与的记忆。 |
| 回答需要的证据 | 将人物互动与活动经历关联起来，并由来源时间把“去年”换算为 2022 年。 |

**三种组织方式**

| 方法 | 保存形式 | 需要处理的问题 |
|---|---|---|
| 平面记忆 | 独立条目＋向量 | 检索后补齐分散的事件语境 |
| 图记忆 | 实体、关系与图结构 | 实体消歧、关系去重与维护 |
| StructMem | 时间绑定的条目＋整合摘要 | 在写入时组织相关事件 |

关键词相似能找到相关片段，完整回答还需要人物、事件与时间之间的联系。

原文 §1–2；附录 A.8，表 8，p.132。案例证据简化为中文

# StructMem 的两层记忆




| 记忆层次 | 保存内容 | 回答时的作用 |
| --- | --- | --- |
| 事件级记忆 | 事实、互动关系、来源时间 | 提供可核对的具体细节 |
| 跨事件记忆 | 当前事件与相关历史的整合摘要 | 提供跨越多次交流的联系 |

两层共同保留。核心流程由提示调用与向量检索组成，无需训练新的语言模型。

原文图 2、§3，pp.123–124；流程据原文重绘

# 双视角抽取与时间锚定

**对话示例**：Alice 分享研究生录取和机器学习方向，Bob 祝贺她、询问计划并表达支持。

| | |
|---|---|
| 事实视角 $\Phi_i$ | Alice 被研究生项目录取，计划研究机器学习。 |
| 关系视角 $\Psi_i$ | Bob 为 Alice 感到高兴，支持她的选择并关注研究计划。 |

$$\text{记忆条目} = \langle x, e_x, \tau_i \rangle, \qquad x \in \Phi_i \cup \Psi_i$$

$x$：自然语言内容　$e_x$：检索向量　$\tau_i$：来源话语时间

**时间示例**：2023 年 8 月说“去年参加过活动”。
来源时间保留为 2023 年 8 月，回答时将事件年份换算为**2022 年**。

抽取结果附带 source_id；事件重建按相同来源时间聚合事实与关系条目。

原文 §3.1，式 (1)–(2)；图 4–7、13，pp.133–136、139

# 历史检索与跨事件整合

1. **积累当前事件**：条目按对话时间排序，以 1 小时窗口触发整合。
2. **检索历史种子**：拼接缓存文本并编码，按余弦相似度取 top-15。
3. **恢复事件语境**：取回每个种子同时间锚的其他事实与关系条目。
4. **生成整合摘要**：当前缓存与恢复后的历史事件共同进入整合模型。

$$E_\tau(x^*) = \{x' \in M \mid \tau(x') = \tau(x^*)\}$$

**摘要要求**：200–350 个英文词，保留人物、具体时间和行动，组织有依据的事件联系。

**关键区别**：15 是历史种子数，展开后的上下文可能包含更多条目。

1 小时指对话时间窗口。整合摘要与事件条目共同保留。

原文 §3.2，式 (3)–(5)；A.3；图 8，pp.124、129、137

# 回答阶段的证据组合

| 检索内容 | 提供的信息 | 回答中的用途 |
| --- | --- | --- |
| **60 条事件记忆** | 具体事实、人物互动、来源时间 | 核对人物身份与细节 |
| **5 条整合摘要** | 已整理的相关历史与事件联系 | 联合多段证据 |

**回答提示中的处理规则**

- 同时检查两位说话人的记忆，区分说话人与记忆中提到的人物。
- 依据来源日期换算“去年”“两个月前”等时间表达。
- 信息冲突时优先较新的记忆，最终输出简短、具体的答案。

构建阶段的 15 条种子与回答阶段的 60 + 5 分别控制不同环节。

原文 A.3；图 13，pp.129、139；案例参考表 8，p.132

# 实验设置与比较范围

**LoCoMo 长期对话问答**

10 段对话，平均 588 轮、16,618 Token。

| 任务 | 数量 | 需要的能力 |
|---|---|---|
| 单跳 | 841 | 定位单一事实 |
| 多跳 | 282 | 连接多条证据 |
| 时间 | 321 | 推理时间关系 |
| 开放域 | 96 | 对话结合背景知识 |
| 合计 | 1,540 | 单跳占 54.6% |

**模型与指标**

生成：gpt-4o-mini
向量：text-embedding-3-small

正确率：LLM 评判回答
构建成本：Token、调用数、耗时

主要对比：全文上下文、RAG、图记忆及长期记忆系统。

**读表方式**：总分结合分类结果看；检索预算各异，主表反映整套系统表现。

原文 §4.1；A.2–A.4、表 3，pp.125、128–129

# 总分提升与能力差异

| 方法 | 总分 | 单跳 | 多跳 | 时间 | 开放域 |
|---|---|---|---|---|---|
| FullContext | 73.83 | **86.56** | 68.79 | 50.16 | 56.25 |
| Zep | 75.14 | 79.79 | **74.11** | 67.71 | **66.04** |
| Memobase | 75.78 | 77.17 | 70.92 | **85.05** | 46.88 |
| StructMem | **76.82** | 81.09 | 68.77 | 81.62 | 46.88 |

**主要收益**

总分比 Memobase 高**1.04**。

相对 FullContext，时间推理提高**31.46**，总分提高 2.99。

**能力取舍**

相对 FullContext，单跳下降 5.47，多跳接近。

Zep 多跳、开放域更高；Memobase 时间任务更高。

时间相关任务受益明显；跨事件整合的具体作用，需要进一步看组件消融。

原文表 1，p.125。粗体为所列方法中最高值；差值单位为百分点

# 构建成本与运行时间

**完整实验的构建统计**

| 方法 | Token(M) | 调用数 | 时间 (s) |
|---|---|---|---|
| MiniRAG | 10.103 | 2,508 | 2,566 |
| StructMem | 1.937 | 1,056 | 22,854 |
| Mem0g | 35.825 | 53,514 | 115,670 |

**相对 Mem0g：Token 减少94.6%，调用减少98.0%，耗时减少 80.2%。**

**同框架，首段对话**

| | |
|---|---|
| 平面记忆 | 77.6k |
| StructMem | 226.1k |
| 图记忆 | 402.3k |

StructMem 约为平面记忆的 2.91 倍，比图记忆少 43.8%。

**成本来自哪里**：双视角抽取和摘要增加调用；批量整合减少图维护的多阶段开销。

MiniRAG 运行更快。调用量、Token 消耗与墙钟时间需要分别评价。

原文表 1、图 3(b)，pp.125–126。M 为百万 Token，k 为千 Token

# 跨事件整合的消融结果

| 配置 | 单跳 | 多跳 | 时间 | 开放域 |
|---|---|---|---|---|
| Flat Memory | 78.83 | 66.31 | 78.50 | 46.88 |
| Graph Memory | 80.50 | 66.67 | 76.64 | 48.96 |
| 去掉跨事件整合 | 80.86 | 66.31 | 79.44 | 46.88 |
| StructMem | 81.09 | 68.77 | 81.62 | 46.88 |
| **整合带来的变化** | +0.23 | **+2.46** | **+2.18** | 0.00 |

进一步实验可分别去掉关系抽取和时间锚定，定位每个设计的贡献。

**结果解释**

多跳与时间任务需要联合分散证据，受益更大。

单跳变化较小，开放域未改善。

符合整合摘要以连接对话证据为主的功能。

原文表 2，p.125。最后一行为加入跨事件整合后的百分点变化

# 记忆内容的忠实性

**事件条目**：三个评判模型报告的平均幻觉率为**2.36%**。

**整合约束**：引用历史时标注具体时间，保留人物和行动细节，建立具体、有依据的联系。

| 评判模型 | 有约束的错误关联率 | 移除约束后 |
|---|---|---|
| GPT | 0.61% | 7.45% |
| Qwen | 3.41% | 20.00% |
| DeepSeek | 3.63% | 15.14% |

**观察**：三个评判模型均报告错误关联增加，提示中保留时间与具体联系有实际作用。

条目幻觉与摘要关联采用不同统计单位；这些数值来自模型审核。

原文图 8、表 6–7，pp.130–131、137。错误关联率由模型分别评判

# 阅读结论与后续问题

**方法贡献**

事实与互动关系共同保存，时间锚支持事件重建，跨事件摘要组织相关历史。

**实验支持**

总分 76.82%；整合模块主要改善多跳与时间任务；相对图记忆降低构建开销。

**值得继续研究的问题**

计划或关系发生变化后，旧条目与摘要怎样同步更新？

可用带时间变更的对话，比较仅优先新记忆与显式修订的回答质量、来源可追溯性。

**我的理解：记忆写入时的组织方式，会直接影响之后的证据联合。**

论文：https://aclanthology.org/2026.acl-short.12/

代码：https://github.com/zjunlp/LightMem/blob/main/StructMem.md

原文 §3–5、Limitations；末项为阅读后提出的实验方向

专题论文阅读

# Hindsight

## 结构化智能体记忆：保留、召回与反思

李金昊

7–9 分钟

# 问题：长对话中的记忆不只是“存下来”

**智能体需要保留信息、跨会话找回它，并据此给出连贯回答。**

- 历史不断增长，相关信息可能分散在不同会话。
- 用户陈述的事实与智能体形成的判断容易混在一起。
- 只取相似片段，回答可能局部合理、整体矛盾。

**Hindsight 把写入、检索和推理分成可检查的操作。**

Hindsight, §1；PDF p.1（印刷页 275）

# 四类网络把事实、摘要和意见分开

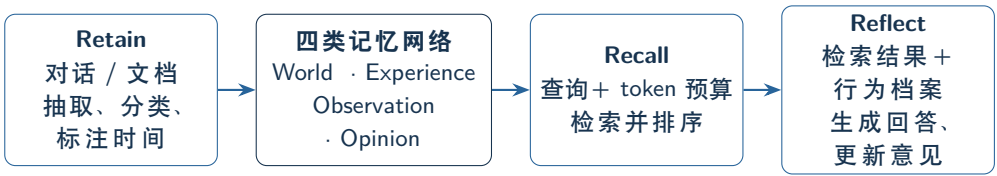
| 网络 | 记忆类型 | 例子或用途 |
|---|---|---|
| World | 外部世界事实 | Alice 在 Google 的 Mountain View 团队工作。 |
| Experience | 智能体自己的经历 | 智能体曾向 Alice 推荐徒步旅行。 |
| Observation | 从事实归纳的实体摘要 | Alice 是专长于机器学习的软件工程师。 |
| Opinion | 有置信度的主观判断 | “Python 适合数据科学”；置信度随证据更新。 |

**Observation 是证据摘要；Opinion 是带置信度的判断。**

四类网络让开发者能检查智能体“知道什么”与“相信什么”。

Hindsight, §3.1；PDF pp.2–3，表 1

# 三种操作组成记忆生命周期




TEMPR 负责 retain / recall；CARA 负责 reflect。Reflect 的新证据可触发 Opinion 更新。

Hindsight, §3.2–3.3、图 1；PDF pp.3–4（印刷页 277–278）

# Recall 将四种检索并行，再融合排序

{向量，关键词，图遍历，时间过滤} ⟶ RRF ⟶ 重排与预算裁剪

| 通道 | 找什么 |
|---|---|
| 向量相似度 | 语义相近的记忆；使用 HNSW 索引。 |
| BM25 | 关键词或实体名称；使用 PostgreSQL 全文检索。 |
| 图遍历 | 沿实体、时间、因果关系扩展，通常限制在 2–3 跳。 |
| 时间过滤 | 按问题中的日期或时间区间匹配事件。 |

**RRF 合并各通道排序，cross-encoder 再重排；token 预算限制返回上下文。**

Hindsight, §3.2、§4.1；PDF pp.3、5（印刷页 277、279）

# Reflect 让意见随证据变化

### 行为档案

- 怀疑程度、字面倾向、共情程度
- 每项取值 1–5，用于调节回答倾向
- Opinion 保存置信度和支持证据

### 论文中的三会话示例

- 用户开始用 Rust 改造支付服务。
- 之后询问下一季度应重点做什么。
- 后来表示 Rust 难维护、更怀念 Go。

**新证据削弱先前的偏好判断；相关世界事实仍保留。**

这是论文的定性案例，不是独立用户研究。

Hindsight, §3.2–3.3、§6.4；PDF pp.3–4、7（印刷页 277–278、281）

# 作者报告的结果有提升，也有比较边界

**LongMemEval S，准确率（%）**

| | |
|---|---|
| Full-context GPT-4o | 60.2 |
| Hindsight OSS-20B | 83.6 |
| Hindsight OSS-120B | 89.0 |
| Hindsight Gemini-3 | 91.4 |
| Supermemory Gemini-3 | 85.2 |

**LoCoMo，准确率（%）**

| | |
|---|---|
| Zep | 75.1 |
| Memobase | 75.8 |
| Hindsight OSS-20B | 83.2 |
| Hindsight OSS-120B | 85.7 |
| Hindsight Gemini-3 | 89.6 |
| Backboard | 90.0 |

**20B 在 LongMemEval 比全文 GPT-4o 高 23.4 个百分点；表中也有更高的其他系统分数。**

LongMemEval S 为 500 题；两项基准的模型和系统条件并非完全一致。

Hindsight, §6.1–6.3、表 2；PDF pp.6–7（印刷页 280–281）

# 局限与证据边界

## 系统局限

- 抽取与实体消歧依赖 LLM，错误可能传播。
- 只评测英文数据；Opinion 置信度未做正式用户验证。
- 持续保存个人信息，且无内置 PII 自动脱敏。

## 报告证据需谨慎读

- 完整评估指向另一篇工作，本文引用编号仍是占位符。
- 正文与附录的部分类别基线数值不一致。
- 本文提供的是系统演示与结果摘要，不是本组复现。

Hindsight, Limitations、Ethics；PDF p.8（印刷页 282），§6.2 及附录 D

# 对长上下文结构化记忆课设的启发

- 分开事实、经历、实体摘要和意见，检查来源与置信度。
- 在固定 token 预算下，比较语义检索与时间 / 实体关联。
- 用消融区分各通道收益，并同步记录准确率、噪声和成本。

**可借鉴的是可检查的记忆类型与操作；迁移效果仍要用同一条件验证。**

以上是个人阅读推导的实验问题，不是已经完成的本组实验或团队共识。

阅读启发：据 Hindsight, §3、§6；PDF pp.3–8

专题论文阅读

# Semantic XPath

## 结构化记忆的路径与语义访问

oioioi-521

7–9 分钟

# 长期任务中的记忆访问

**全量上下文**

保留完整历史，但输入随交互增长。

**扁平 RAG**

返回相关片段，但日期和版本范围可能混淆。

**贯穿案例**

在会议安排最密集的一天增加咖啡休息。

需要比较各天的活动，而不只是找到一条会议相关文本。

**研究问题：怎样访问相关的记忆子结构？**

# 树形记忆与整体流程

计划 Itinerary ⟶ 版本 Version ⟶ 日期 Day ⟶ 活动 POI

1. 结合已有结构，把自然语言请求转成查询。
2. 执行结构匹配、位置筛选与语义评分。
3. 返回节点及子树，供下游回答或更新。

schema 来自已有记忆结构；查询负责定位，实际修改由下游步骤完成。

原文 PDF 第 2–4 页，图 2、§3.1–3.3；层级与流程按原文整理

# 查询语法与访问范围

$$S = A\,N[R]\,[P]$$

| 组成 | 写法 | 含义 |
|---|---|---|
| 路径 $A$ | `/`、`//` | 子节点或后代 |
| 类型 $N$ | `Day` / `POI` / `*` | 类型或任意节点 |
| 位置 $R$ | `[i]` / `[-i]` / `[i:j]` | 顺序、倒序或区间 |
| 语义 $P$ | `[node~="workshop"]` | 连续相关性评分 |

```
//Day[3]/POI[node~="workshop"]
```

多个行程或历史版本共存时，先限定目标范围；第三个匹配日期未必是当前计划第三天。

原文 PDF 第 3–4 页，§3.2；第 10 页，附录 A

# 语义评分与查询执行

```
//Day[avg(/POI[node~="conference"])]
```

| 执行阶段 | 候选与分数 |
| --- | --- |
| 初始化 | 根节点，权重为 1 |
| 路径与类型筛选 | 找到日期及其活动 |
| 第二天活动局部评分 | 0.603、0.482、0.608 |
| 日期聚合评分 | $(0.603 + 0.482 + 0.608)/3 \approx 0.565$ |
| 与其他日期比较 | 选中第二天，再交给下游更新 |

$$w_{\text{new}} = w_{\text{old}} \times \mathrm{Rel}(u, P)$$

平均相关性反映密集程度，不直接等同于会议数量最多。

原文 PDF 第 4 页，§3.3、图 2；第 10 页，附录 A

# 旅行示例中的日期范围

用户：第七天下雨，找出当天需要调整的户外活动。

| 日期 | 活动 | 是否属于目标 |
| --- | --- | --- |
| 第 2 天 | 海滨公园 | 否，日期不符 |
| 第 5 天 | 山地徒步 | 否，日期不符 |
| 第 7 天 | 植物园、海港游船 | 是 |

**先限定第七天，再判断活动语义。**

普通 RAG 加入日期元数据过滤也能改善简单范围错误，应纳入公平比较。

# 实验设置与指标口径

旅行、待办、配餐：每场景 20 个单轮和 5 个多轮对话，另测 LoCoMo。

| 指标或模型 | 含义与口径 |
| --- | --- |
| 任务通过率 | 检索正确，且输出满足任务约束 |
| LoCoMo 得分 | LLM 裁判与参考答案对照 |
| 平均 tokens | 表 2–3 口径；未完整说明全部组成 |
| 平均输入 tokens | 表 1 口径；XPath 包含查询生成输入 |
| 模型 | GPT-5 mini / Gemini 3 Flash；Qwen3 嵌入 / BART 蕴含评分 |

不同任务指标不直接混比；tokens 不包含本地评分的全部计算开销。

原文 PDF 第 5 页，§4.1；第 7 页表 1；第 11 页表 2–3

# 单轮结果与准确性权衡

| 回答模型 | 方法 | 通过率 | 平均 tokens |
|---|---|---|---|
| GPT-5 mini | In-context | 70.0% | 26 216 |
| | Flat RAG | 30.0% | 3 250 |
| | XPath Entail | 83.0% | 5 691 |
| Gemini 3 Flash | In-context | 79.0% | 25 387 |
| | Flat RAG | 37.7% | 3 361 |
| | XPath Entail | 70.7% | 5 830 |

**GPT-5 mini：比 Flat RAG 提高 53 个百分点。**

相对增幅 176.7%；tokens 为全量上下文的 21.7%。Gemini 准确性仍低于全量上下文。

原文 PDF 第 11 页，附录 B 表 2；作者单轮平均结果

# 多轮结果与评分器比较

| 回答模型 | 方法 | 通过率 | 平均 tokens |
|---|---|---|---|
| GPT-5 mini | In-context | 80.0% | 69 097 |
| | Flat RAG | 26.7% | 3 327 |
| | XPath Entail | 83.3% | 5 850 |
| Gemini 3 Flash | In-context | 56.7% | 76 603 |
| | Flat RAG | 26.7% | 3 240 |
| | XPath Entail | 80.0% | 5 993 |

**Entail 在两种模型下取得最高平均通过率。**

tokens 约为全量上下文的 8.5% 和 7.8%；平均优势不代表每个子场景均提升。

原文 PDF 第 6 页图 6–7；第 11 页表 3；作者多轮平均结果

# LoCoMo 上的泛化结果

| 回答模型 | 方法 | 回答得分 | 输入 tokens |
|---|---|---|---|
| GPT-5 mini | In-context | 74.55 | 24 857 |
| | Flat RAG | 35.71 | 1 341 |
| | Semantic XPath | 65.19 | 3 032 |
| Gemini 3 Flash | In-context | 87.01 | 27 499 |
| | Flat RAG | 41.49 | 1 996 |
| | Semantic XPath | 73.25 | 3 870 |

**总体得分高于 Flat RAG，低于全量上下文。**

输入约为全量上下文的 12.2% 和 14.1%；保留准确性和证据完整性的代价。

原文 PDF 第 7 页表 1；回答得分与平均输入 tokens，XPath 含查询生成

# 优点局限与失败来源

| 失败阶段 | 典型表现 |
| --- | --- |
| 查询生成 | 语法不合法，无法执行 |
| 检索 | 无命中、证据不全、选错节点或发言 |
| 回答生成 | 所需证据已取回，但答案仍错误 |

- 优点：结构与语义结合，路径及评分轨迹可追溯。
- 作者分析：检索仍是主要剩余失败来源。
- 阅读局限：层级依赖、多跳、小规模评测和本地评分开销。

原文 PDF 第 6–7 页，§4.3、图 8：局限部分为个人阅读分析

# 个人总结与团队关联

- 长期记忆访问同时考虑内容、所属范围和历史版本。
- 阅读启发：明确查询范围，保留节点路径与证据标识。
- 评测启发：区分检索与回答错误，加入元数据过滤基线。
- 本组 C 已完成事件记忆构建；Semantic XPath 尚未端到端复现。

原录制稿的拟议角色属于 10 月 17 日计划；当前分工按 C 结项记录表述，贡献比例由全组确认。

个人阅读总结：本组 C 事件记忆结项另见 Issue#32 及 PR#43/#50

# 参考资料

## 主要论文

Liu et al. Semantic XPath: Structured Agentic Memory Access for Conversational AI. ACL 2026 System Demonstrations, pp.286–296.

https://aclanthology.org/2026.acl-demo.28/

## 作者项目

https://github.com/D3Mlab/SemanticXpath-Chat

语法与评分见 §3、附录 A；结果见表 1–3；旅行下雨案例为教学示例。

论文与数值：Liu et al., 2026；教学示例和个人推测分别标识

专题论文阅读

# HyMEM

## 电脑操作智能体的混合自演化记忆

lanshuheng9-oss

7–9 分钟

# 问题：经验既要保留细节，也要跟上任务变化

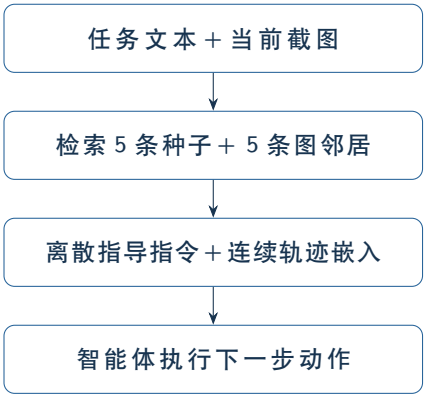
**截图与动作难以只靠文本总结；一次检索也会过时。**

- 输入：任务描述、当前截图、历史成功操作轨迹。
- 输出：指导智能体选择下一步网页操作。
- 例：搜索商品转入结账后，保留预算，更新操作指导。

**混合表示解决“存什么”；自演化解决“何时更新”。**

HyMEM，PDF 第 1–3 页，表 1；下例为机制说明

# 混合记忆：策略指导规划，连续表示保留细节




**一条经验的三个层次**

$$v_i = (c_i, A_i, m_i)$$

- $c_i$：可复用的高层策略。
- $A_i$：动作、界面及领域属性。
- $m_i$：8 个连续轨迹嵌入。

CLIP 检索索引与连续记忆是不同表示。

HyMEM，PDF 第 3–5 页，式 (1)、图 1、Structured Retrieval

# 自演化：长期图与当前工作记忆分别更新

### 全局：跨任务积累经验

- ADD：出现新策略或属性。
- MERGE：同一策略的互补证据。
- REPLACE：同条件下更优的轨迹。

### 局部：跟随当前任务阶段

1. 比较动作前后观测，检测阶段变化。
2. 保留长期目标及约束，删除过时指导。
3. 重新检索，刷新文本与连续嵌入。

先检索候选，再由视觉语言模型判断信息增量。

**全局改变长期经验库；局部更新当前执行上下文。**

HyMEM，PDF 第 4–5 页，Memory Update、Working Memory Refresh；图 1

# 实验：网页操作成功率，包含记忆编码器训练

| 项目 | 作者实验条件 |
| --- | --- |
| 三个基准 | WebVoyager、Multimodal-Mind2Web、MMInA |
| 记忆来源 | 2883 条成功轨迹；主图 1858 个节点，超过 100 万条边 |
| 模型与接口 | 7B/8B 视觉语言模型；ReAct、SOM 及定位回退 |
| 训练 | Q-Former + LoRA；约 1.2% 参数可训练，通常 1 个 epoch |
| 评价 | 任务成功率；Overall 按可用领域取平均 |

前两个基准根据任务和截图轨迹判分；MMInA 比较最终回答与标准答案。

HyMEM，PDF 第 5–6 页，§4.1；第 7 页，表 2 表注

# 结果：混合记忆有收益，单一记忆并非总有帮助

**作者表 2：Overall 任务成功率（%）**

| 基础模型 | 无记忆 | 离散 | 连续 | HyMEM |
|---|---|---|---|---|
| Qwen2.5-VL-7B | 12.5 | 17.0 | 21.7 | **35.0** |
| Qwen3-VL-8B | 21.9 | 21.3 | 23.3 | **33.8** |
| UI-TARS-1.5-7B | 17.1 | 15.4 | 28.7 | **31.2** |

**12.5% 到 35.0%：提高 22.5 个百分点。**

Qwen3 的离散记忆低于无记忆；总体提升不代表每个领域都改善。

图 2 另支持全局演化与局部刷新的作用；两种收益不能直接相加。以上均非本组结果。

HyMEM，PDF 第 7 页，表 2；图 2 为不同分析设置，不与本表混合

# 阅读判断：借鉴组织机制，迁移收益仍需验证

## 贡献与局限

- 离散策略与视觉细节互补。
- 长期积累与任务内刷新形成闭环。
- 依赖训练、标签与模型判断，存在额外调用成本。

## 与本组 StructMem D 的联系

- 可研究种子检索与结构扩展的分工。
- 固定预算，比较覆盖、噪声及成本。
- 文本问答与截图操作口径不同，不能直接排名。

本组尚未复现 HyMEM；迁移建议不是团队共识或已完成实验。

HyMEM，PDF 第 3–7 页；右侧为本节阅读分析与待验证假设

专题论文阅读

# MetaMem

## 让模型正确使用已取回的事实

YaoYang-123456

约 8 分钟核心讲解

# 检索到了事实，为什么还会答错？

**问题**：**四次旅行共走了多少英里？**

| | |
|---|---|
| 事实 A | 前三次旅行合计**1800**英里 |
| 事实 B | 第四次旅行总计**1200**英里 |
| 事实 C | 第四次旅行第一天走了**300**英里 |

**正确**：$1800 + 1200 = \mathbf{3000}$　**错误**：$1800 + 1200 + 300 = 3300$

错误未必来自检索：事实可能全部存在，模型却把“总量”和“部分”重复相加。

原文 PDF p.1，图 1；图中里程数字按论文示例整理

# 事实记忆 $M$ 与元记忆 $E$

| 对象 | 保存什么 | 例子 |
| --- | --- | --- |
| 事实记忆 $M$ | 具体经历、数字、时间、人物 | 第四次旅行总计 1200 英里 |
| 元记忆 $E$ | 可迁移的知识使用策略 | 总量与部分不可重复计数 |

$$\hat{y} = \mathrm{LLM}(\mathrm{Prompt}(q, M, E))$$

**训练对象**：自然语言规则集合 $E$；不通过反向传播更新基础模型权重。

信息不足时，规则也不能补出原本没有检索到的关键事实。

# 从候选回答到反思与规则更新

1. **多次回答**：在同一事实记忆下采样若干候选回答。
2. **评价与反思**：使用训练标准答案判断对错并归纳原因。
3. **编辑规则**：提出 ADD / DEL / MOD，处理重复与冲突。
4. **验证与冻结**：用验证集选取规则版本；测试时不再更新。

**回答 → 反馈 → 反思 → 规则 → 新回答**

训练时可以看到标准答案；测试回答时不能看到答案，更不能用测试答案改规则。

原文 PDF pp.3–5，Figure 2，式 (4)–(10)

# 一次自然语言规则编辑

**原规则**：把所有出现的数字相加。

**反思**：第一天属于第四次旅行，重复计入会多算。

**MOD 提案**：求和前核对对象、事件和包含关系，只合并互不重复的数量。

| | |
|---|---|
| ADD | 新增缺失的经验；从空集合开始时先添加 |
| DEL | 删除错误或过时的经验 |
| MOD | 修改已有编号的经验 |

提案先处理重复和冲突，再执行到 $E$；例子不代表本组真实学出的规则。

原文 PDF pp.4–5，Figure 2、式 (4)–(10)；以下规则文字为教学构造

# 实验设置与数据隔离

| | |
|---|---|
| 数据和划分 | LongMemEval 500 题；每折 350 训练＋ 50 验证＋ 100 测试，共五折 |
| 事实记忆 | LightMem；规则以外还存在检索模块 |
| 生成模型 | Qwen3-30B-A3B-Instruct、Llama3.1-70B-Instruct |
| 评价模型 | Qwen3-235B-A22B；判分是实验的一部分 |
| 学习设置 | 5 epochs，每批 50 题，每题采样 5 次 |

模型、数据划分、评价标准不一致时，不能直接把准确率差异归因到元记忆。

原文 PDF pp.5、11，§4，附录 A.3、A.5

# 主结果与消融的解释

**原论文 LongMemEval 平均值（%）**

| 生成模型 | LightMem | MetaMem | 提升（点） |
|---|---|---|---|
| Qwen3-30B-A3B | 67.50 | **71.90** | +4.40 |
| Llama3.1-70B | 66.17 | **69.08** | +2.91 |

**Qwen 消融**：完整方法 71.90；无反思 70.02；无演化 68.33。

两组模型的增幅不同，整体提升不等于所有题型改善；这些数字不是本组试点成绩。

原文 PDF p.6 Table 1、p.7 Table 2；均为论文结果

# 局限、适用条件与 StructMem 的联系

**优势与价值**

- 分离“检索缺失”和“利用错误”
- 规则可读、可修改，无须微调权重
- 消融实验提供一定证据

**限制与风险**

- 依赖带答案数据与评判质量
- 多次采样和反思有成本
- 过度泛化、冲突与事实缺失

StructMem 侧重组织和检索证据；MetaMem 侧重检索后的事实利用。两者不可直接混算实验成绩。

原文 PDF §Limitations、附录 A.6；本组方案 docs/project-plan.md

专题论文阅读

# Text2Mem

## 统一的记忆操作语言与状态验证

ngocnamd93-spec

7–9 分钟

# 记忆控制需要说明“对哪些记录做什么”

用户说：“暂时不要再提午餐。”

降低显著性、设置到期规则与删除记录，会产生不同状态。

- 检索解决“找回什么”；记忆控制还要明确动作、范围与时间。
- 输入是自然语言请求与上下文；输出是操作 Schema 或有序操作列表。
- Text2Mem 提供操作规范与基准，主实验在 SQL/SQLite 参考后端进行。

**把意图显式表达，再核验实际状态变化**

原论文 PDF 第 1–3 页，图 1：动机案例为教学概述

# 十二个操作由五字段契约组织

| 阶段 | 操作 |
| --- | --- |
| 编码 ENC | Encode |
| 存储 STO | Update、Label、Promote、Demote、Merge、Split、Delete、Lock、Expire |
| 检索 RET | Retrieve、Summarize |

**stage / op / target / args / meta**

**阶段、动作、目标、参数、执行上下文；各操作的必填条件不同。**

需要定位已有条目时，target 选择 ids、filter、search 或 all 之一。
Demote 降权或归档而不删除；Delete 与 Expire 另有语义。

原论文 PDF 第 4 页表 1、第 4–5 页 §3.2；附录 A 第 11 页

# 校验、解析与适配各自解决一层问题




**格式合法、动作可执行、效果符合意图，需要分别判断**

锁定与到期等规则可提前检查；复杂目标理解仍依赖模型。

依据原论文 PDF 第 3 页图 2、第 5 页 §3.3、第 6 页图 3 重绘；非运行记录

# 案例：提高进度笔记权重，也要检查无关记录

## 请求与已明确的目标

“提高本周课设进度笔记的重要性，其他记录不变。”目标 ID：17。

### 结构化操作

```
stage: STO
op: Promote
target: ids=[17]
args: weight=0.9
```

字段摘要，省略非必要项；
不是经过执行的 JSON 结果。

### 执行后检查

1. ID 17 的权重是否达到要求？
2. ID 17 的内容是否保持不变？
3. 非目标条目是否保持不变？

若最初选错目标，合法操作也会改错记录。

改写自原论文 PDF 第 12 页附录 B.1.1；本页是未执行的教学案例

# 评测分开衡量结构、执行与状态效果

| 指标 | 回答的问题 |
| --- | --- |
| SMA | 操作与参考结构有多相似？使用编辑距离或余弦相似度。 |
| ESR | 操作能否通过校验，并无运行错误地执行？ |
| EMR | 全部期望 SQL 断言中，有多少得到满足？ |

$$\mathrm{EMR} = \frac{\text{满足的状态断言数}}{\text{期望状态断言总数}}$$

作者比较五个模型，中/英文、直接/间接指令、单操作/工作流。
EMR 不是整任务全通过率，也不是 LoCoMo 问答准确率。

原论文 PDF 第 6–8 页 §4.1–4.3；EMR 公式在第 7 页

# 操作容易运行，预期状态仍难实现

| 模型 | ESR (%) | EMR (%) |
|---|---|---|
| GPT-4o | 94.84 | 25.32 |
| Qwen2.5-72B-Instruct | 95.10 | 25.35 |
| Claude-4-Sonnet | 95.94 | 31.32 |
| Gemini-2.5-Pro | 94.79 | 28.97 |
| GPT-5 | 96.62 | 28.26 |

**GPT-5 工作流：ESR 100%，EMR 11.90%**

原表 Avg 直接转为百分数，不重算操作均值。

Split 的 EMR 在五个模型中均为 0，仅限该基准。论文未做组件移除消融。

原论文 PDF 第 8 页表 2 Avg 列、表 3；全部为作者结果

# 对本组的启发是明确契约，再核对效果

## 论文价值与局限

- 统一动作、范围和生命周期参数。
- 规划与状态效果分开评测。
- 缺少复杂语义保证；跨真实后端和长期任务证据有限。

## 与本组课设的联系

- StructMem 研究事件记忆与问答，任务和指标不同。
- A 的字段白名单与哈希属于数据校验，不能称 Text2Mem 复现。
- 借鉴显式输入、影响范围与非目标状态检查。

## 系统能调用成功，还要证明它做对了事

原论文 PDF 第 9 页 Limitations、第 15 页附录 F；课设联系为阅读分析

共同讨论

# 系统性总结

## 从六篇工作形成统一认识

讲解人待填写

10–15 分钟

# 统一比较：研究对象、机制与边界

| 工作 | 记忆表示与对象 | 核心干预环节 | 适用条件与局限 |
| --- | --- | --- | --- |
| StructMem | 待共同整理 | 待共同整理 | 待共同整理 |
| Hindsight | 待共同整理 | 待共同整理 | 待共同整理 |
| Semantic XPath | 待共同整理 | 待共同整理 | 待共同整理 |
| HyMEM | 待共同整理 | 待共同整理 | 待共同整理 |
| MetaMem | 待共同整理 | 待共同整理 | 待共同整理 |
| Text2Mem | 待共同整理 | 待共同整理 | 待共同整理 |

填写各论文实际处理的问题，避免把不同研究层次视为可直接替换的方法。

本部分为结构模板：待六篇个人讲解完成后共同填写

# 机制之间的联系与取舍

## 可能互补的环节

- 待填写：哪些问题需要联合处理？
- 待填写：两种机制的接口是什么？
- 待填写：原文或实验依据是什么？

## 组合的条件与代价

- 待填写：表示与信息边界是否一致？
- 待填写：增加了什么成本或风险？
- 待填写：哪些效果还需要验证？

本部分为结构模板：待六篇个人讲解完成后共同填写

# 共同案例：不同方法分别解释什么

## 共同场景与问题

待讨论后选定：给出同一段历史、同一个查询，以及需要保留的关键证据。

| 比较内容 | 待填写的分析 |
| --- | --- |
| 组织与检索 | 记忆如何形成，哪些证据能被取回？ |
| 更新与使用 | 新旧信息如何处理，回答或操作如何形成？ |
| 解释边界 | 哪些是论文直接支持，哪些是推演或尚待验证？ |

本部分为结构模板：待六篇个人讲解完成后共同填写

# 实验结果的可比条件

| 条件 | 共同核对后填写 |
| --- | --- |
| 任务与数据 | 数据划分、题型与有效样本是否一致？ |
| 模型与信息 | 基础模型、优化反馈、测试可用信息有何差异？ |
| 检索与预算 | 上下文数量、token 预算与构建成本如何计量？ |
| 指标与评价 | 各指标测什么，裁判与评价提示是否一致？ |

**待填写：哪些结果可以比较，哪些只能分别解释**

本部分为结构模板：待六篇个人讲解完成后共同填写

# 小组结论与课设选择

1. **共同认识**：待填写一项有依据的结论。
2. **研究取舍**：待填写主线选择，以及借鉴或暂不采用的机制。
3. **仍待验证**：待填写关键分歧、失败情形和后续验证方式。

本部分为结构模板：待六篇个人讲解完成后共同填写

# 讨论与问题

## 长上下文场景结构化记忆建模

第 8 队

# 备用：共同参加活动的案例

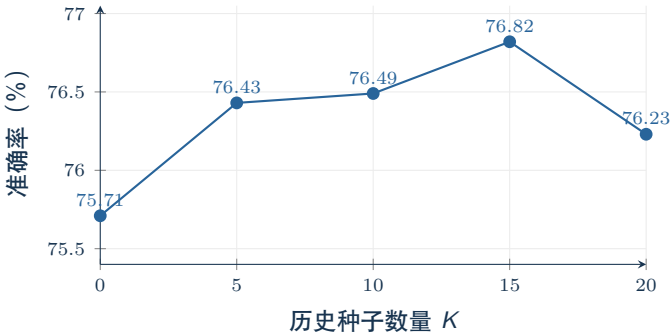
| 方法 | 回答 |
|---|---|
| Flat Memory | 两人没有一起去过。 |
| Graph Memory | 上个月，2023 年 6 月。 |
| StructMem | 去年，2022 年 8 月。 |
| 参考答案 | 2022 年 |

## 互动语境连接共同经历，来源日期帮助解析“去年”

表中参考答案验证到年份，额外的月份没有得到单独验证。

原文表 8，p.132。案例预测为论文报告值

# 备用：历史种子数量




$K = 15$ 时达到最高值。

$K = 0$ 仍整合当前缓存，只是不引入历史。

更多历史不保证继续提升。

原文图 3(d)，p.126。纵轴截取 75.4–77.05 以显示细小差异

# 备用：更换评判模型后的结果

| 评判模型 | StructMem | Memobase | 分差 |
|---|---|---|---|
| gpt-4o-mini | 76.82 | 75.78 | +1.04 |
| Qwen2.5-32B | 77.01 | 76.36 | +0.65 |
| DeepSeek-V3.2 | 79.35 | 79.29 | +0.06 |

Fleiss' $\kappa = 0.8341$，**模型间判断较一致**。

**分差随评判模型变化**，DeepSeek 下两者十分接近。

一致性指标衡量评判模型之间的共识，论文未报告系统分差的显著性检验。

备用页：原文表 4–5，p.130。表 1 口径复核详见阅读总结末页

# 备用：几个方法细节

**为什么不用图也能称为结构化记忆？**
同源条目的时间绑定和跨事件摘要，已经提供了层次与关系组织。

**整合摘要会覆盖原来的记忆吗？**
事件条目与摘要共同保留，回答时同时检索。

**是否需要训练新模型？**
论文核心流程使用提示调用、向量检索与记忆组织，没有新的参数训练步骤。

**怎样处理相互冲突的记忆？**
问答提示优先较新信息，存储层的显式修订仍是待解决的问题。

备用页：原文 §3，附录 A.3、A.7，Limitations