专题论文阅读

Semantic XPath

结构化记忆的路径与语义访问

oioioi-521

约 8 分钟

长期任务中的记忆访问

全量上下文

保留完整历史，但输入随交互增长。

扁平 RAG

返回相关片段，但日期和版本范围可能混淆。

贯穿案例

在会议安排最密集的一天增加咖啡休息。

需要比较各天的活动，而不只是找到一条会议相关文本。

研究问题：怎样访问相关的记忆子结构？

树形记忆与整体流程

计划 Itinerary ⟶ 版本 Version ⟶ 日期 Day ⟶ 活动 POI

1. 结合已有结构，把自然语言请求转成查询。
2. 执行结构匹配、位置筛选与语义评分。
3. 返回节点及子树，供下游回答或更新。

树结构定义可访问的范围，查询定位节点，下游模块执行修改。

查询语法与访问范围

$$S = A\,N\,[R]\,[P]$$

组成	写法	含义
路径 A	`/`、`//`	子节点或后代
类型 N	`Day / POI / *`	类型或任意节点
位置 R	`[i] / [-i] / [i:j]`	顺序、倒序或区间
语义 P	`[node~="workshop"]`	连续相关性评分

```
//Day[3]/POI[node~="workshop"]
```

多个行程或版本共存时，先选定目标，再按位置访问日期。

语义评分与查询执行

```
//Day[avg(/POI[node~="conference"])]
```

执行阶段	候选与分数
初始化	根节点，权重为 1
路径与类型筛选	找到日期及其活动
第二天活动局部评分	0.603、0.482、0.608
日期聚合评分	$(0.603 + 0.482 + 0.608)/3 \approx 0.565$
与其他日期比较	选中第二天，再交给下游更新

$$w_{\text{new}} = w_{\text{old}} \times \mathrm{Rel}(u, P)$$

这里按会议相关性的平均分选择日期。

教学示例：限定日期范围

用户：第七天下雨，找出当天需要调整的户外活动。

日期	活动	是否属于目标
第 2 天	海滨公园	否，日期不符
第 5 天	山地徒步	否，日期不符
第 7 天	植物园、海港游船	是

先限定第七天，再判断活动语义。

对照方法：为普通 RAG 加入日期过滤，比较范围选择的效果。

实验设置与评价指标

旅行、待办、配餐：每场景 20 个单轮和 5 个多轮对话，另测 LoCoMo。

指标或模型	含义与口径
任务通过率	检索正确，且输出满足任务约束
LoCoMo 得分	LLM 裁判与参考答案对照
平均 tokens	单轮 / 多轮任务的用量；组成披露有限
平均输入 tokens	LoCoMo 用量，含 XPath 查询生成输入
模型	GPT-5 mini / Gemini 3 Flash；Qwen3 嵌入 / BART 蕴含评分

本地嵌入与语义评分的计算开销需另行统计。

单轮任务结果

回答模型	方法	通过率	平均 tokens
GPT-5 mini	In-context	70.0%	26 216
	Flat RAG	30.0%	3 250
	XPath Entail	83.0%	5 691
Gemini 3 Flash	In-context	79.0%	25 387
	Flat RAG	37.7%	3 361
	XPath Entail	70.7%	5 830

GPT-5 mini：比 Flat RAG 提高 53 个百分点。

GPT-5 mini 的 tokens 为全量上下文的 21.7%；Gemini 较全量上下文低 8.3 个百分点。

多轮任务结果

回答模型	方法	通过率	平均 tokens
GPT-5 mini	In-context	80.0%	69 097
	Flat RAG	26.7%	3 327
	XPath Entail	83.3%	5 850
Gemini 3 Flash	In-context	56.7%	76 603
	Flat RAG	26.7%	3 240
	XPath Entail	80.0%	5 993

Entail 在两种模型下取得最高平均通过率。

两种模型的 tokens 分别为全量上下文的 8.5% 和 7.8%。

LoCoMo 上的泛化结果

回答模型	方法	回答得分	输入 tokens
GPT-5 mini	In-context	74.55	24 857
	Flat RAG	35.71	1 341
	Semantic XPath	65.19	3 032
Gemini 3 Flash	In-context	87.01	27 499
	Flat RAG	41.49	1 996
	Semantic XPath	73.25	3 870

总体得分高于 Flat RAG，低于全量上下文。

输入分别为全量上下文的 12.2% 和 14.1%，回答得分也有所下降。

检索错误与方法局限

失败阶段	典型表现
查询生成	语法不合法，无法执行
检索	无命中、证据不全、选错节点或发言
回答生成	所需证据已取回，但答案仍错误

- 优点：结构与语义结合，路径及评分轨迹可追溯。
- 作者分析：检索仍是主要剩余失败来源。
- 局限：依赖已有层级；多跳检索与评分开销仍需改进。

总结与课设应用

- 长期记忆访问同时考虑内容、所属范围和历史版本。
- 阅读启发：明确查询范围，保留节点路径与证据标识。
- 评测启发：区分检索与回答错误，加入元数据过滤基线。
- 在事件记忆检索中，比较范围约束与纯语义检索的效果。