专题论文阅读

Text2Mem

统一的记忆操作语言与状态验证

ngocnamd93-spec

7–9 分钟

记忆控制需要说明“对哪些记录做什么”

用户说：“暂时不要再提午餐。”

降低显著性、设置到期规则与删除记录，会产生不同状态。

- 检索解决“找回什么”；记忆控制还要明确动作、范围与时间。
- 输入是自然语言请求与上下文；输出是操作 Schema 或有序操作列表。
- Text2Mem 提供操作规范与基准，主实验在 SQL/SQLite 参考后端进行。

把意图显式表达，再核验实际状态变化

原论文 PDF 第 1–3 页，图 1：动机案例为教学概述

十二个操作由五字段契约组织

阶段	操作
编码 ENC	Encode
存储 STO	Update、Label、Promote、Demote、Merge、Split、Delete、Lock、Expire
检索 RET	Retrieve、Summarize

stage / op / target / args / meta

阶段、动作、目标、参数、执行上下文；各操作的必填条件不同。

需要定位已有条目时，target 选择 ids、filter、search 或 all 之一。
Demote 降权或归档而不删除；Delete 与 Expire 另有语义。

原论文 PDF 第 4 页表 1、第 4–5 页 §3.2；附录 A 第 11 页

校验、解析与适配各自解决一层问题



格式合法、动作可执行、效果符合意图，需要分别判断

锁定与到期等规则可提前检查；复杂目标理解仍依赖模型。

依据原论文 PDF 第 3 页图 2、第 5 页 §3.3、第 6 页图 3 重绘；非运行记录

案例：提高进度笔记权重，也要检查无关记录

请求与已明确的目标

“提高本周课设进度笔记的重要性，其他记录不变。”目标 ID：17。

结构化操作

```
stage: STO
op: Promote
target: ids=[17]
args: weight=0.9
```

字段摘要，省略非必要项；
不是经过执行的 JSON 结果。

执行后检查

1. ID 17 的权重是否达到要求？
2. ID 17 的内容是否保持不变？
3. 非目标条目是否保持不变？

若最初选错目标，合法操作也会改错记录。

改写自原论文 PDF 第 12 页附录 B.1.1；本页是未执行的教学案例

评测分开衡量结构、执行与状态效果

指标	回答的问题
SMA	操作与参考结构有多相似？使用编辑距离或余弦相似度。
ESR	操作能否通过校验，并无运行错误地执行？
EMR	全部期望 SQL 断言中，有多少得到满足？

$$\mathrm{EMR} = \frac{\text{满足的状态断言数}}{\text{期望状态断言总数}}$$

作者比较五个模型，中/英文、直接/间接指令、单操作/工作流。
EMR 不是整任务全通过率，也不是 LoCoMo 问答准确率。

原论文 PDF 第 6–8 页 §4.1–4.3；EMR 公式在第 7 页

操作容易运行，预期状态仍难实现

模型	ESR (%)	EMR (%)
GPT-4o	94.84	25.32
Qwen2.5-72B-Instruct	95.10	25.35
Claude-4-Sonnet	95.94	31.32
Gemini-2.5-Pro	94.79	28.97
GPT-5	96.62	28.26

GPT-5 工作流：ESR 100%，EMR 11.90%

原表 Avg 直接转为百分数，不重算操作均值。

Split 的 EMR 在五个模型中均为 0，仅限该基准。论文未做组件移除消融。

原论文 PDF 第 8 页表 2 Avg 列、表 3；全部为作者结果

对本组的启发是明确契约，再核对效果

论文价值与局限

- 统一动作、范围和生命周期参数。
- 规划与状态效果分开评测。
- 缺少复杂语义保证；跨真实后端和长期任务证据有限。

与本组课设的联系

- StructMem 研究事件记忆与问答，任务和指标不同。
- A 的字段白名单与哈希属于数据校验，不能称 Text2Mem 复现。
- 借鉴显式输入、影响范围与非目标状态检查。

系统能调用成功，还要证明它做对了事

原论文 PDF 第 9 页 Limitations、第 15 页附录 F；课设联系为阅读分析