专题论文阅读

Text2Mem

统一的记忆操作语言与状态验证

ngocnamd93-spec

约 8 分钟

记忆操作的目标、动作与效果

用户说：“暂时不要再提午餐。”

降低显著性、设置到期规则与删除记录，会产生不同状态。

- 检索解决“找回什么”；记忆控制还要明确动作、范围与时间。
- 输入是自然语言请求与上下文；输出是操作 Schema 或有序操作列表。
- Text2Mem 提供操作规范与基准，主实验在 SQL/SQLite 参考后端进行。

明确目标与动作，检查状态变化

十二种操作与五个字段

阶段	操作
编码 ENC	Encode
存储 STO	Update、Label、Promote、Demote、Merge、Split、Delete、Lock、Expire
检索 RET	Retrieve、Summarize

stage / op / target / args / meta

阶段、动作、目标、参数、执行上下文；各操作的必填条件不同。

target 支持 ids、filter、search 或 all。
Demote 调整优先级，Delete 删除记录，Expire 设置到期规则。

从操作生成到状态核验



格式合法、动作可执行、效果符合意图，需要分别判断

锁定、到期与字段约束由校验器检查；目标理解依赖模型。

操作示例：提高进度笔记的权重

请求与已明确的目标

“提高本周课设进度笔记的重要性，其他记录不变。”目标 ID：17。

结构化操作

```
stage: STO
op: Promote
target: ids=[17]
args: weight=0.9
```

执行后检查

1. ID 17 的权重是否达到要求？
2. ID 17 的内容是否保持不变？
3. 非目标条目是否保持不变？

若最初选错目标，合法操作也会改错记录。

结构、执行与状态评价

指标	回答的问题
SMA	操作与参考结构有多相似？使用编辑距离或余弦相似度。
ESR	操作能否通过校验，并无运行错误地执行？
EMR	全部期望 SQL 断言中，有多少得到满足？

$$\mathrm{EMR} = \frac{\text{满足的状态断言数}}{\text{期望状态断言总数}}$$

评测覆盖五个模型，以及中英文、直接 / 间接指令、单操作 / 工作流。

执行成功率与状态匹配结果

模型	ESR (%)	EMR (%)
GPT-4o	94.84	25.32
Qwen2.5-72B-Instruct	95.10	25.35
Claude-4-Sonnet	95.94	31.32
Gemini-2.5-Pro	94.79	28.97
GPT-5	96.62	28.26

GPT-5 工作流：ESR 100%，EMR 11.90%

该基准中，五个模型在 Split 操作上的 EMR 均为 0。

方法局限与课设启发

论文价值与局限

- 统一动作、范围和生命周期参数。
- 规划与状态效果分开评测。
- 缺少复杂语义保证；跨真实后端和长期任务证据有限。

与本组课设的联系

- StructMem 研究事件记忆与问答，任务和指标不同。
- 在数据校验之外，增加操作后的状态检查。
- 借鉴显式输入、影响范围与非目标状态检查。

按目标记录与非目标记录分别核验操作效果