专题论文阅读

# Text2Mem

## 统一的记忆操作语言与状态验证

ngocnamd93-spec

# 记忆操作的目标、动作与效果

用户说：“暂时不要再提午餐。”

降低显著性、设置到期规则与删除记录，会产生不同状态。

- 检索解决“找回什么”；记忆控制还要明确动作、范围与时间。
- 输入是自然语言请求与上下文；输出是操作 Schema 或有序操作列表。
- Text2Mem 提供操作规范与基准，主实验在 SQL/SQLite 参考后端进行。

**明确目标与动作，检查状态变化**

# 十二种操作与五个字段

| 阶段 | 操作 |
| --- | --- |
| 编码 ENC | Encode |
| 存储 STO | Update、Label、Promote、Demote、Merge、Split、Delete、Lock、Expire |
| 检索 RET | Retrieve、Summarize |

**stage / op / target / args / meta**

阶段、动作、目标、参数、执行上下文；各操作的必填条件不同。

target 支持 ids、filter、search 或 all。
Demote 调整优先级，Delete 删除记录，Expire 设置到期规则。

# 从操作生成到状态核验




**格式合法、动作可执行、效果符合意图，需要分别判断**

锁定、到期与字段约束由校验器检查；目标理解依赖模型。

# 操作示例：提高进度笔记的权重

## 请求与已明确的目标

“提高本周课设进度笔记的重要性，其他记录不变。”目标 ID：17。

### 结构化操作

```
stage: STO
op: Promote
target: ids=[17]
args: weight=0.9
```

### 执行后检查

1. ID 17 的权重是否达到要求？
2. ID 17 的内容是否保持不变？
3. 非目标条目是否保持不变？

若最初选错目标，合法操作也会改错记录。

# 结构、执行与状态评价

| 指标 | 回答的问题 |
| --- | --- |
| SMA | 操作与参考结构有多相似？使用编辑距离或余弦相似度。 |
| ESR | 操作能否通过校验，并无运行错误地执行？ |
| EMR | 全部期望 SQL 断言中，有多少得到满足？ |

$$\mathrm{EMR} = \frac{\text{满足的状态断言数}}{\text{期望状态断言总数}}$$

评测覆盖五个模型，以及中英文、直接 / 间接指令、单操作 / 工作流。

# 执行成功率与状态匹配结果

| 模型 | ESR (%) | EMR (%) |
|---|---|---|
| GPT-4o | 94.84 | 25.32 |
| Qwen2.5-72B-Instruct | 95.10 | 25.35 |
| Claude-4-Sonnet | 95.94 | 31.32 |
| Gemini-2.5-Pro | 94.79 | 28.97 |
| GPT-5 | 96.62 | 28.26 |

**GPT-5 工作流：ESR 100%，EMR 11.90%**

该基准中，五个模型在 Split 操作上的 EMR 均为 0。

# 方法局限与课设启发

## 论文价值与局限

- 统一动作、范围和生命周期参数。
- 规划与状态效果分开评测。
- 缺少复杂语义保证；跨真实后端和长期任务证据有限。

## 与本组课设的联系

- StructMem 研究事件记忆与问答，任务和指标不同。
- 在数据校验之外，增加操作后的状态检查。
- 借鉴显式输入、影响范围与非目标状态检查。

## 按目标记录与非目标记录分别核验操作效果