Text2Mem：统一记忆操作语言与状态验证

ngocnamd93-spec

(天津大学，第 8 队)

摘　要:Text2Mem 通过统一的记忆操作规范（Schema）连接自然语言指令与底层存储引擎。本文梳理其三阶段十二种操作、五字段 Schema 以及校验、解析与适配执行流水线，并结合结构匹配度、执行成功率与状态断言满足率分析主流模型的表现。实验表明，现有模型虽能生成语法合规的可执行操作，但在复杂存储操作与多步工作流的状态准确性上仍存明显瓶颈，凸显了后置状态核验的必要性。

关键词: 记忆操作；结构化规范；状态验证；论文阅读

中图法分类号: TP18

Text2Mem: Unified Memory Operations and State Verification

ngocnamd93-spec

(Tianjin University, Team 8)

1　Text2Mem：记忆操作的统一表达与状态验证

Text2Mem[1]面向自然语言驱动的记忆管理，提出统一的记忆操作规范（Schema）与配套评测基准。系统将更新、合并、降级或定期清理等自然语言指令解析为结构化操作对象，映射至底层存储执行，并通过后置状态断言核验执行效果。

1.1　研究问题与适用范围

长期交互不仅需要检索历史信息，还需对记忆的优先级、有效期、合并与删除进行精细控制。日常指令往往存在操作语义歧义，例如“暂时不要再提午餐”通常意指下调显著性权重，而非永久删除记录。若缺乏明确的操作类型、作用范围与时间参数约束，系统即便成功调用接口，也可能误改无关记忆。Text2Mem 因此在自然语言指令与底层存储引擎之间引入结构化操作中间层，将记忆生命周期语义与具体后端实现解耦（论文主实验基于 SQL/SQLite 环境评测）。

1.2　操作集合、Schema 与执行流程

论文围绕编码（ENC）、存储（STO）和检索（RET）三个阶段定义了十二种操作：编码阶段含 Encode；存储阶段含 Update、Label、Promote、Demote、Merge、Split、Delete、Lock 和 Expire 九种操作；检索阶段含 Retrieve 与 Summarize。其中，Encode 组织内容、语义标签、来源与治理属性（支持延迟生成向量）；Promote 与 Demote 调整记忆显著性（Demote 支持归档降权而不删除）；Delete 处理软 / 硬删除，Expire 设置到期规则，三者在生命周期语义上严格区分。

操作规范包含 stage、op、target、args 和 meta 五个字段，依次对应阶段、动作、目标、专属参数与执行元数据。不同操作对应特定的必填与跨字段约束：例如 Encode 新建记录时无需先选定已有目标；针对存量记忆的操作则需在 target 中从 ids、filter、search、all 四类选择器中择一明确范围，并受锁定保护与批量写入权限限制。

执行流水线中，Validator 首先校验结构完整性与跨字段约束；Parser 将合法实例解析为类型化操作并归一化时间与优先级参数；Adapter 最终将其映射为后端数据库动作，返回记录受影响条目和状态变化的 ExecutionResult。多步请求可表示为保留依赖顺序的 schema_list 依次执行。

例如，针对“提高本周课设进度笔记的重要性，其他记录不变”，系统对条目 17 执行 STO 阶段的 Promote 操作，将 ids=[17] 的 weight 设为 0.9，并在执行后同时核验目标权重、原有内容与非目标条目，确保仅改动指定范围。

1.3 基准、指标与主要结果

评测基准由自然语言指令、前置操作建立的初态、参考 Schema 和后置 SQL 状态断言组成，覆盖中英双语、直接与间接表达、单步操作与多步工作流，并在统一提示模板下评测了 GPT-4o、Qwen2.5-72B-Instruct、Claude-4-Sonnet、Gemini-2.5-Pro 与 GPT-5 五种模型。

评测包含三项指标：结构匹配度（SMA）用编辑距离或余弦相似度衡量生成 Schema 与参考 Schema 的一致性；执行成功率（ESR）统计通过校验且无运行错误的实例比例；执行匹配率（EMR）统计执行后满足的 SQL 状态断言占全部期望断言的比例：

$$\mathrm{EMR} = \frac{\sum_i \sum_{a \in A_i} \mathbb{I}(a)}{\sum_i |A_i|}. \tag{1}$$

其中 A_i 为第 i 个实例的断言集合，断言 a 满足时 $\mathbb{I}(a) = 1$，否则为 0。由于 EMR 按断言汇总，包含更多检查项的复杂实例对总体得分权重更高。

表 1 Text2Mem 总体评测指标

模型	$\mathrm{SMA}_{\mathrm{lev}}$	$\mathrm{SMA}_{\mathrm{cos}}$	ESR	EMR
GPT-4o	0.6776	0.8690	0.9484	0.2532
Qwen2.5-72B-Instruct	0.6195	0.8349	0.9510	0.2535
Claude-4-Sonnet	0.6230	0.8475	0.9594	0.3132
Gemini-2.5-Pro	0.6491	0.8560	0.9479	0.2897
GPT-5	0.6115	0.8396	0.9662	0.2826

表1显示，各模型的 ESR 均达 94.79%–96.62%（GPT-5 最高），但 EMR 仅为 25.32%–31.32%（Claude-4-Sonnet 最高）。这一落差说明当前模型虽能稳定生成语法合规、可执行的操作指令，但在准确锁定目标范围并达成预期存储状态上仍有明显瓶颈。

在复杂操作与多步工作流上差距尤为突出：五个模型的 Split EMR 均为 0，Merge 仅 GPT-4o 取得 0.0465，其余为 0；GPT-5 的单步操作 EMR 为 0.2930，而在多步工作流中尽管 ESR 为 1.0000，EMR 却降至 0.1190，表明跨步状态依赖传递是主要难点。

1.4 方法局限与课设启发

Text2Mem 将结构校验（ESR）与后置状态核验（EMR）分离，清晰揭示了“指令可执行”与“状态改得对”之间的差距。不过，现有实验主要在离线 SQL 环境中评测，尚未接入长程对话循环检验状态更新对后续问答的长期影响；若状态断言未充分覆盖非目标记录，也可能漏检误改旁支数据的副作用。在课程设计中，为 StructMem 补充计划变更与失效维护时，可借鉴 Text2Mem 将模糊变更要求显式化为 Update、Demote 或 Expire 操作，并在执行后同时核验目标事件与无关历史条目。

References

[1] Wang L, Yang L, Chen B, et al. Text2Mem: A unified memory operation language for memory operating system. In: Liakata M, Moreira V P, Zhang J, et al., editors, Findings of the Association for Computational Linguistics: ACL 2026, San Diego, California, United States: Association for Computational Linguistics, 2026. 2105–2119