Text2Mem：统一记忆操作语言与状态验证

ngocnamd93-spec

(天津大学，第 8 队)

摘　要:Text2Mem 通过统一操作规范连接自然语言指令与记忆后端。本文介绍十二种操作、五字段 Schema 以及校验、解析和适配流程，并分析结构相似性、执行成功率和状态断言满足率。实验显示，操作普遍能够执行，复杂存储与工作流的状态效果仍有较大提升空间。本文进一步讨论后端覆盖、断言设计和长期任务评测，为记忆更新的表达与验证提供参考。

关键词: 记忆操作；结构化规范；状态验证；论文阅读
中图法分类号: TP18

Text2Mem: Unified Memory Operations and State Verification

ngocnamd93-spec

(Tianjin University, Team 8)

1　Text2Mem：记忆操作的统一表达与状态验证

Text2Mem[1]面向自然语言驱动的记忆控制，提出统一操作语言及其基准。用户要求更新、合并或调整记忆时，系统通过结构化规范表达目标范围与参数，并检查执行后的状态是否符合预期。

1.1　研究问题与适用范围

长期交互不仅需要检索历史信息，还需要控制记忆的优先级、有效期、合并和删除。例如，“暂时不要再提午餐”可能意味着降低显著性，也可能被误解为删除记录。如果动作、范围与时间未被明确表达，系统即使调用成功，也可能改变错误的记忆。论文因此在自然语言与具体后端之间引入结构化操作规范。

中间规范用记忆生命周期操作表达意图，再由后端实现其语义，为不同后端提供共同的操作接口。论文主实验采用 SQL/SQLite 参考环境。

1.2　操作集合、Schema 与执行流程

十二个操作。论文将操作分为编码、存储和检索三阶段。编码阶段仅有 Encode；存储阶段包括 Update、Label、Promote、Demote、Merge、Split、Delete、Lock、Expire 九个操作；检索阶段包含 Retrieve、Summarize。Encode 组织内容、语义、来源与治理属性，向量生成可以延迟。Promote 与 Demote 调整显著性，Demote 可以归档而不删除；Delete 处理软/硬删除，Expire 设置到期规则，三者具有不同语义。

五字段契约。操作由 `stage`、`op`、`target`、`args`、`meta` 描述，分别对应阶段、动作、目标、专属参数和执行上下文。不同操作的必填条件不同，例如 Encode 创建新记忆时不必先选择已有目标。对于需要定位已有条目的操作，`target` 在 `ids`、`filter`、`search`、`all` 四种选择方式中择一；跨字段约束限制锁定、到期和大范围写入等行为。

Validator–Parser–Adapter。Validator 检查结构完整性与跨字段约束；Parser 把合法实例转换为类型化操作，归一化时间和优先级等参数；Adapter 再映射为具体后端动作。执行返回 `ExecutionResult`，记录受影响条目和状态变化。多步骤请求可表示为保留依赖顺序的 `schema_list`。该流程检查结构和治理约束；目标选择与意图理解则由执行后的状态检查评估。

教学案例：提高课设进度记忆的优先级。以请求“提高本周课设进度笔记的重要性，其他记录不变”为例，设目标条目为 17，可用 STO 阶段的 Promote，将 `ids=[17]` 的 `weight` 设为 0.9。状态检查同时覆盖目标权重、原有内容和非目标条目，确认操作只改变了指定范围。

1.3 基准、指标与主要结果

基准以自然语言指令、前置操作建立的初态、参考 Schema 和 SQL 状态断言组成评测实例，覆盖中英文、直接与间接指令、单操作与工作流。模型包括 GPT-4o、Qwen2.5-72B-Instruct、Claude-4-Sonnet、Gemini-2.5-Pro 与 GPT-5，使用相同自然语言指令与提示模板。

评测包含三个指标：SMA 用编辑距离或余弦相似度衡量生成 Schema 与参考的相似程度；ESR 统计通过验证且无运行错误地执行的实例比例；EMR 统计满足的 SQL 状态断言占全部期望断言的比例：

$$\mathrm{EMR} = \frac{\sum_i \sum_{a \in A_i} \mathbf{1}[a\text{满足}]}{\sum_i |A_i|}. \tag{1}$$

其中 A_i 为第 i 个实例的断言集合。EMR 以断言为统计单位，断言较多的实例对总体指标影响更大。

表 1 Text2Mem 总体评测指标

模型	$\mathrm{SMA}_{\mathrm{lev}}$	$\mathrm{SMA}_{\mathrm{cos}}$	ESR	EMR
GPT-4o	0.6776	0.8690	0.9484	0.2532
Qwen2.5-72B-Instruct	0.6195	0.8349	0.9510	0.2535
Claude-4-Sonnet	0.6230	0.8475	0.9594	0.3132
Gemini-2.5-Pro	0.6491	0.8560	0.9479	0.2897
GPT-5	0.6115	0.8396	0.9662	0.2826

表1列出各模型的总体指标。ESR 约为 94.79%–96.62%，EMR 约为 25.32%–31.32%，显示操作普遍可以执行，但状态效果与预期仍有较大差距。最高 ESR 与最高 EMR 分别对应 GPT-5 和 Claude-4-Sonnet。

复杂存储和工作流的表现较弱。五个模型的 Split EMR 均为 0；Merge 仅 GPT-4o 为 0.0465，其余为 0。GPT-5 的单操作 EMR 为 0.2930，工作流 EMR 为 0.1190，而工作流 ESR 为 1.0000。这表明多步骤操作中的状态正确性是该基准的主要难点。

现有实验主要比较模型、操作类型和任务分组。Validator、Parser 与 Adapter 的独立作用，以及指令复杂度对结果的影响，还需要组件消融和受控实验分析。

1.4 方法局限与课设启发

统一规范将动作、范围和生命周期参数显式化，便于执行前检查与执行后追踪。将结构相似、执行状态和实际效果分别计量，有助于定位目标选择、操作规划和后端执行中的问题。

方法的局限包括复杂记忆语义缺少形式保证、真实后端覆盖有限，以及尚未评测端到端长期智能体表现。状态断言的覆盖也会影响 EMR：只检查目标权重，可能遗漏非目标条目被误改的情况。实际应用需要同时考虑后端适配、长期效果和错误传播。

StructMem 关注事件绑定、整合与问答检索，Text2Mem 关注操作表达和状态核验。与 Semantic XPath 的目标定位、MetaMem 的事实利用结合比较，可以将记忆系统的错误依次定位到访问、推理和执行环节。

课程设计可借鉴显式输入约束与效果检查相结合的做法。若开展记忆更新实验，可固定初态、请求和模型，分别记录格式合法性、执行成功率、断言满足率与整任务通过率，并检查非目标记录是否保持完整。

References:

[1] Wang L, Yang L, Chen B, et al. Text2Mem: A unified memory operation language for memory operating system. In: Proceedings of Liakata M, Moreira V P, Zhang J, et al., editors, Findings of the Association for Computational Linguistics: ACL 2026, San Diego, California, United States: Association for Computational Linguistics, 2026. 2105–2119