长对话结构化记忆复现与初步诊断

第 8 队 · 第一次课设研讨 · 2026.10

研究问题：历史越来越长，如何保留并用对事件证据？

StructMem 小规模方法复现 | 固定 30 道开发题

提交候选：署名、贡献比例与出场日期待全组确认

相关事实被找到，不代表事件被理解

原始对话不断增长

同一人物在不同时间谈到不同事件

相似词容易召回“有关、但不是这一次”的片段

记录时间与事件发生时间未必相同

我们的研究切入点

把事实、关系和事件来源一起保存

先检索相关记忆，再让模型回答

比较回答质量，也报告输入与构建成本

目标是可解释、可复跑的课程复现；不预设必须超过简单基线。

两条回答路径，共用数据与调用入口

01 A 固定会话与问题：答案另存，只在评分阶段关联

02 S0：原始对话分块 → MiniLM 向量检索 top-60 → F 回答

03 S2：事实/关系抽取 → 事件绑定 → 跨事件综合 → 60 事件 + 5 综合 → F 回答

04 E：关联冻结参考 → 固定裁判 → 原始分数 + 独立证据复核

S0/S2 的记忆、输入形态和方法指令不同，是系统对照；S1 尚未运行。

A #38；B #37；C #43；D #41；F #35/#42/#44

已完成真实闭环；复现差异明确保留

阶段	已完成的真实产物	口径
A / B	3 会话 · 30 题 · 每题 60 原始块	5 题为 30 题子集
C	91 session · 1,973 消息 → 3,712 事件记忆	2,309 事实 + 1,403 关系
D	91 条真实综合 · S2 回答 30/30	60 事件 + 5 综合
F / E	S0 回答 30/30 · E 报告裁判 60/60	逐题裁判交接待完整复算

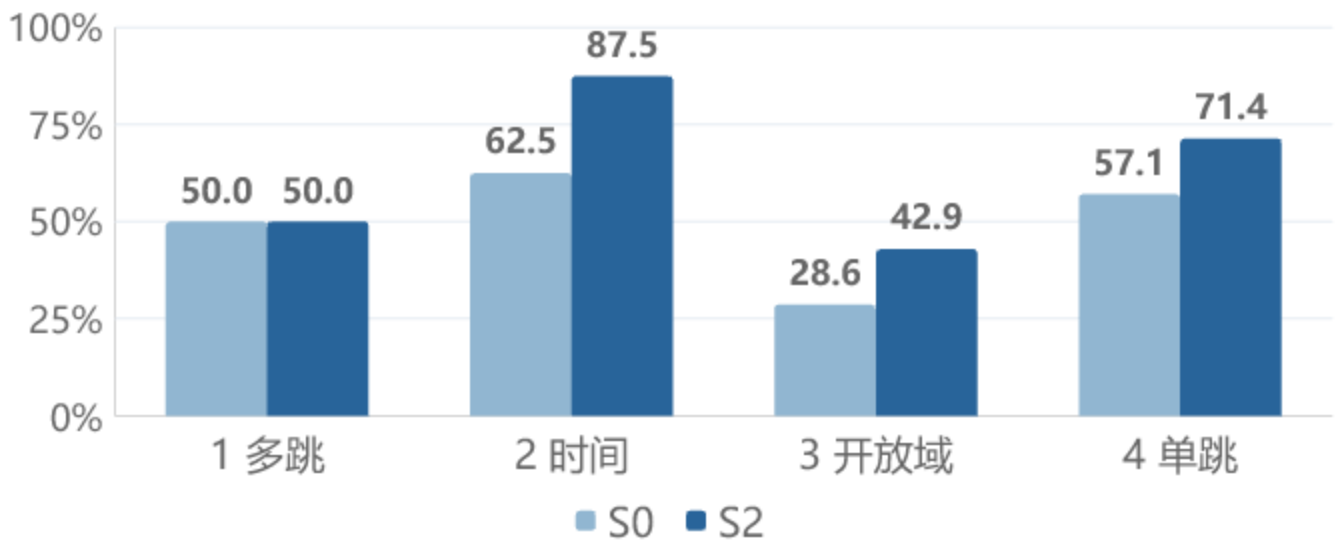
替换模型与嵌入；关闭压缩/话题切分；时间绑定含顺序构造。不是论文原设置逐字复现。

C 433de34；D 38214e5；F 49d8a67；E 1cfd177

开发集：S2 多答对 4 题，输入约为 4.42 倍

S0 50.0%　　**S2 63.3%**

复核后；原始为 53.3% / 63.3%



输入成本

132,531 → 586,282 tokens
约 4.42 倍
回答费用约 ¥0.27 → ¥1.17

分母：8 / 8 / 7 / 7；每组共 30 题

E 已报告；生成记录已逐条核验，60 条裁判尚待独立复算。开发集差异不代表稳定泛化。

E 1cfd177 汇总；本轮 answer-audit.json；成本未与账单核对

案例帮助解释结果，也暴露评分边界

相对时间：记录日期 ≠ 事件年份

conv-41/20：问太平洋西北旅行时间

2023-04-10 的 D11:3：“a road trip we took last year”（节选）

S0：10 April, 2023

S2：Last year (2022)

错误和参考都要检查

日期矛盾题 conv-42/28：S0 改判 1 次

conv-42/61：来源不足以证明具体游戏平台

conv-41/41：海景照片不能证明住址

保留参考和分母，单列证据不足

案例为 AI 辅助证据核查，人工验收未填写；观察到系统差异，不等于确定模块因果。

创新性论证：从可检验的问题出发

本轮已得到的研究依据

结构化路径在部分时间题表现不同

回答输入增加约 4.42 倍，质量与成本需一起看

仍存在证据不足、参考口径和判分可靠性问题

研讨后的验证顺序（未执行）

先补
S1：同事件库、同指令，关闭跨事件综合

再固定比较检索 30 与 60，综合数保持 5

按正确性、有效覆盖与输入成本决定是否保留

课程贡献是可复跑的适配、对照与证据分析；尚不声称提出学术新方法。

项目方案 §§3、6—7；S1 与检索预算实验均未运行

六人已交付内容与剩余协作事项

任务 / 账号	实际贡献	当前比例
A · ngocnamd93-spec	冻结题单、答案隔离、嵌入环境	待全组确认
B · YaoYang-123456	原始块 top-60、真实检索、MetaMem 阅读	待全组确认
C · oioioi-521	事实/关系抽取、事件绑定与持久化	待全组确认
D · lanshuheng9-oss	真实综合、S2 检索与回答	待全组确认
E · onlysonder	固定裁判、结果表与案例复核材料	待全组确认
F · hycx233	统一客户端、S0 回答、交接及全组整合	待全组确认

贡献比例不按发言时长或提交数推算。主讲、录制、上传负责人尚未确认。

项目方案 §8；Issues #19/#24/#26/#28/#31/#32；成员原稿

现在可以解释成果；下一步补齐验收与消融

已完成：固定数据 → 两套真实回答 → 自动评分报告与证据案例

当前观察：S2 在本开发集多答对 4 题，代价是更大的输入

提交前：逐题评分交接、成员署名与比例、排练及视频安排

研讨后：先做 S1 消融，再决定是否开展检索预算实验

按 10 月 21 日前可展示准备；实际场次以课程 Excel 为准。视频由组员提交。

备用：费用、计数与评价版本

阶段	请求 / token	已记录费用估算
C 事件抽取	182 成功；另 2 次连接失败、用量未知	单列，未纳入下方小计
D 跨事件综合	91 次；339,859 tokens	¥0.894722
F / D 回答	S0 30 次；S2 30 次	¥0.268430 / ¥1.173988
E 自动裁判	60 次；9,353 tokens	未核账，未纳入小计
回答 + 综合小计	不包含 C 抽取和 E 裁判	¥2.337140

不是项目总账单。S0 16→15 是一条复核修订，不能混写原始与修订成绩。

C/D/F/E 固定汇总；失败用量未知不按 0 处理

备用：对照边界与仍待确认的事项

S0：原始块向量检索；S1：仅事件记忆；S2：事件 + 跨事件综合

S1 未运行；S0/S2 还存在方法提示词与上下文体量差异

原始裁判 ≠ AI 证据复核 ≠ 成员人工验收

尚待：逐题裁判交接、真实署名/比例、Excel 顺序、场次、格式与视频负责人

8 分钟课设研讨视频与 11 月 1 日约 60 分钟阅读视频是不同交付。