天津大学自然语言处理课程设计

长对话结构化记忆复现与优化

StructMem 方法复现与固定开发集初步分析

第 8 队

第一次课设研讨 · 2026 年 10 月 22 日

研究问题：长对话中的事件证据如何被正确使用

任务：给定一个人的长期对话历史，回答与其经历、关系和时间有关的问题。

- **历史很长，相关信息分散**。同一人物会多次谈到相似活动，仅按关键词或语义相似度检索，可能找到另一件事。
- **事实有关联，时间有参照**。“谁、何时、做了什么”需要一起保留；“去年”的含义还依赖消息的记录日期。
- **结构更丰富，也可能更昂贵**。额外抽取和综合需要模型调用，回答时输入的记忆也可能明显增多。

本组研究问题：结构化记忆能带来怎样的回答变化？这些变化需要付出多少输入与构建成本？

六篇论文的共同主线：记忆怎样变成可靠答案

统一分析链条：组织信息 → 找对证据 → 正确使用 → 更新与验证

共同问题	相互补充的论文视角	对本组方案的具体作用
关系如何保留	StructMem：事件绑定与综合	选作实现主线，保存人物、时间和来源关系。
范围是否正确	Hindsight：时间与多路检索 Semantic XPath：层级范围	检查记忆是否来自正确会话，区分记录时间与事件时间。
证据是否用对	MetaMem：知识利用经验	将“没取到证据”与“取到但用错”分开分析。
更新能否验证	HyMEM：经验更新 Text2Mem：操作验证	比较更新策略与验证要求；动态更新留作后续研究。

本组取舍：StructMem 为实验主线，其他论文提供诊断与验证视角。

StructMem：把事件关系与跨事件联系保留下来

步骤	本组采用的处理方式
1. 抽取与绑定	分别抽取事实和关系，保留说话人、来源消息与时间绑定。相关条目可以追溯到原始事件。
2. 跨事件综合	汇集一个时间窗口内的新事件，检索历史种子并补齐事件上下文，再生成单独保存的综合记忆。
3. 检索与回答	问题到来时，检索事件条目和综合记忆，再交给回答模型；最终保留预测、来源与 token 用量。

本次参数：1 小时综合窗口，15 个历史种子；每题取 60 条事件记忆和 5 条综合记忆。

实验设计：固定题集，比较两套已完成的系统

数据：LoCoMo 固定 3 个开发会话、30 道题；四类题数量为 8/8/7/7。
另留 7 个会话供后续评价；标准答案单独保存，只在生成回答后用于评分。

方法	每道题的回答输入	进展
S0	原始对话块的向量检索，取前 60 条	已完成 30 题
S1	事件记忆，关闭跨事件综合	后续消融
S2	60 条事件记忆 + 5 条综合记忆	已完成 30 题

公共条件：DeepSeek-Flash、非思考模式、temperature=0；本地 MiniLM 嵌入。

实际进展：数据、记忆、回答与评分已经贯通

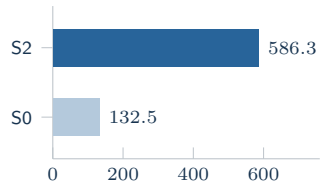
阶段	已完成的真实产物
数据与基线	3 个开发会话，91 个 session 时段，1,973 条原始消息；S0 完成固定 30 题检索。
事件记忆	3,712 条事件记忆，其中 2,309 条事实、1,403 条关系；保留来源绑定。
综合与回答	91 条综合记忆；S0 与 S2 各完成 30 条真实回答，生成记录均已核验。
评分与复核	60 条自动裁判记录；已核对 60 个输入指纹并离线复算，分类分数与汇总一致。

开发集结果：S2 多答对 4 题，输入约为 4.42 倍

应用既有证据裁决后的正确数

题型	S0	S2
多跳（8 题）	4/8	4/8
时间（8 题）	5/8	7/8
开放域（7 题）	2/7	3/7
单跳（7 题）	4/7	5/7
总体（30 题）	**15/30**	**19/30**
正确率	**50.0%**	**63.3%**

回答输入（千 tokens）



S0：132,531 tokens

S2：586,282 tokens

原始自动裁判为 S0 16/30、S2 19/30；一条日期回答经证据复核后改判。

结论范围：30 道开发题的系统对照，尚不能证明稳定提升。

案例：记录日期与事件发生时间需要区分

问题：John 什么时候去太平洋西北地区进行公路旅行？

原始证据：消息记录于 **2023 年 4 月 10 日**，其中说：

“*a road trip we took last year*” （节选）

相关对话同时确认了旅行地点。

系统	实际回答	证据解释
S0	10 April, 2023	把消息记录日期作为旅行日期。
S2	Last year (2022)	将“去年”与记录年份对应，得到 2022 年。

同一案例，贯通三种视角：StructMem 保留事件联系；Hindsight 提醒区分两种时间；MetaMem 提醒检查证据是否被正确使用。

创新性论证与后续方案

已完成的工作：适配并运行 StructMem，建立统一题集的系统对照，记录来源、用量与错误案例。

- **先检验综合模块的作用**。开展 S1 消融，与 S2 共享事件库、回答模型和方法指令，只关闭跨事件综合，观察分类正确率和输入变化。
- **再检验检索预算**。将事件条目数从 60 调为 30，综合记忆仍为 5 条，检查能否在质量接近时减少回答输入。
- **最后评价泛化**。开发集上确定配置后，再从留出会话分层抽取约 100 题；保留失败和负结果，不看成绩临时换题。

六人分工：围绕同一条实验链路交接

任务 / 成员账号	已完成的工作	目前大致贡献
A ngocnamd93-spec	冻结数据、开发/留出划分与题单；隔离答案，准备嵌入环境。	1/6
B YaoYang-123456	实现原始对话块的 top-60 检索；完成固定题集检索与 MetaMem 阅读。	1/6
C oioioi-521	完成事实/关系抽取、事件绑定与持久化，交付 3,712 条事件记忆。	1/6
D lanshuheng9-oss	生成 91 条综合记忆；完成 S2 检索与 30 题回答。	1/6
E onlysonder	完成 60 条自动评分、分类汇总与案例复核材料，交接逐题记录。	1/6
F hycx233	提供统一回答入口，完成 S0 回答、接口联调、评分复算与材料整合。	1/6

协作方式：GitHub、微信群与线下讨论

- **GitHub：管理任务与共同产物**。
  通过 Issue 和 PR 组织分工、代码与文档，记录进展、交接、审核和修改。

- **微信群：日常沟通与进度同步**。
  及时沟通接口、数据和材料问题，协调成员之间的交接与安排。

- **线下讨论：集中梳理与交流**。
  围绕论文之间的联系、实验方案、结果分析和汇报内容进行讨论。

协作重点：围绕同一研究问题，对齐论文理解、实验方案与汇报内容。

阶段结论与下一步

1. **用共同问题组织论文，用共同产物串联分工**。
   六篇论文提炼为统一分析框架；成员围绕同一题集、记忆库、回答与评分交接，并交叉核查。

2. **观察到质量变化，也看到了输入代价**。
   应用既有证据裁决后，S0 为 15/30，S2 为 19/30；S2 的回答输入约为 S0 的 4.42 倍。

3. **下一步明确收益来自哪里、能否降低成本**。
   开展 S1 消融与检索预算对照，并在留出题集上检验泛化表现。

预期交付：可复跑的配置与代码、结果表、成本记录，以及有原文依据的案例分析。